

Modelowanie i Identyfikacja

(MiI2023)

Materiał wykładowy: 4 – Modelowanie parametryczne – identyfikacja rekursywna

Wydział Elektrotechniki i Automatyki

Katedra Inteligentnych Systemów Sterowania i Wspomagania Decyzji

dr hab. inż. Kazimierz Duzinkiewicz

dr inż. Bartosz Puchalski

Metoda najmniejszych kwadratów- estymacja sekwencyjna

Dotychczas rozważaliśmy estymację w sytuacji: wszystkie możliwe pomiary-obserwacje dostępne jednocześnie

Teraz rozważymy estymację w sytuacji: pomiary pojawiają się kolejno, paczkami, co jakiś czas i jest pożądane określać nowe wartości estymowane parametrów w oparciu wszystkie dotychczasowe pomiary, włączając bieżące

Rozpocznijmy od sytuacji: dwie paczki pomiarów, uprzednia oznaczona indeksem 1 i bieżąca oznaczona indeksem 2

Przyjmiemy założenie: $n \leq m_1$ (1)

$$\tilde{\boldsymbol{y}}_1 = \underbrace{\left(\tilde{y}_{11}, \ldots, \tilde{y}_{1j_1}, \ldots, \tilde{y}_{1m_1}\right)^T}_{m_1}$$

- wektor1 (pierwsza paczka) wartości mierzonych y

$$\tilde{\boldsymbol{y}}_2 = \underbrace{\left(\tilde{y}_{21}, \ldots, \tilde{y}_{2j_2}, \ldots, \tilde{y}_{2m_2}\right)^T}_{m_2}$$

- wektor2 (druga paczka) wartości mierzonych y

Równania obserwacji:

$$\begin{cases} \tilde{\boldsymbol{y}}_1 = H_1 \boldsymbol{x} + \tilde{\boldsymbol{e}}_1 \\ \tilde{\boldsymbol{y}}_2 = H_2 \boldsymbol{x} + \tilde{\boldsymbol{e}}_2 \end{cases} \quad \text{lub} \quad \begin{cases} \tilde{\boldsymbol{y}}_1 = H_1 \hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}_1 \\ \tilde{\boldsymbol{y}}_2 = H_2 \hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}_2 \end{cases}$$

Estymata $\hat{\boldsymbol{x}}$ wartości nieznanych parametrów wyznaczona w oparciu o **pierwszą paczkę pomiarów**

$$\hat{\boldsymbol{x}}_1 = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 \qquad (2)$$

Teraz rozważmy estymację wartości nieznanych parametrów w oparciu o obie **połączone** paczki pomiarów-obserwacji

Równania obserwacji:

$$\tilde{\boldsymbol{y}} = H\,\boldsymbol{x} + \tilde{\boldsymbol{e}} \qquad \text{lub} \qquad \tilde{\boldsymbol{y}} = H\,\hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}$$

gdzie

$$\tilde{\boldsymbol{y}} = \begin{bmatrix} \tilde{\boldsymbol{y}}_1 \\ \hline \tilde{\boldsymbol{y}}_2 \end{bmatrix} \quad H = \begin{bmatrix} H_1 \\ \hline H_2 \end{bmatrix}$$

$$\tilde{\boldsymbol{e}} = \begin{bmatrix} \tilde{\boldsymbol{e}}_1 \\ \hline \tilde{\boldsymbol{e}}_2 \end{bmatrix} \qquad \hat{\boldsymbol{e}} = \begin{bmatrix} \hat{\boldsymbol{e}}_1 \\ \hline \hat{\boldsymbol{e}}_2 \end{bmatrix}$$

Założymy, że **łączna** macierz wag pomiarów jest blokowo-diagonalna

$$W = \left[\begin{array}{c|c} W_1 & 0 \\ \hline 0 & W_2 \end{array}\right]$$

Optymalne wartości estymowane nieznanych parametrów w oparciu o dwie kolejne paczki pomiarów:

$$\hat{\boldsymbol{x}}_2 = \left(H^T W H\right)^{-1} H^T W \tilde{\boldsymbol{y}} \tag{3}$$

Ponieważ W jest blokowo-diagonalna

$$\hat{\boldsymbol{x}}_2 = \left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1} \left[H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2\right] \tag{4}$$

Możnaby kontynuować:

$$\hat{\boldsymbol{x}}_{k+1} = \begin{bmatrix} H_1^T W_1 H_1 + H_2^T W_2 H_2 + \ldots \\ \ldots + H_k^T W_k H_k + H_{k+1}^T W_{k+1} H_{k+1} \end{bmatrix}^{-1} \begin{bmatrix} H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2 + \ldots \\ \ldots + H_k^T W_k \tilde{\boldsymbol{y}}_k + H_{k+1}^T W_{k+1} \tilde{\boldsymbol{y}}_{k+1} \end{bmatrix}$$

Ale .....

Zasadnicza cecha estymacji sekwencyjnej powinna być: zorganizować tak proces estymacji, aby wykorzystać poprzednie estymaty i poprzednie wyniki obliczeń

Zdefiniujmy tzw. macierze informacyjne

$$\hat{\boldsymbol{x}}_1 = \underbrace{\left(H_1^T W_1 H_1\right)^{-1}}_{\equiv P_1} H_1^T W_1 \tilde{\boldsymbol{y}}_1$$

$$\hat{\boldsymbol{x}}_2 = \underbrace{\left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1}}_{\equiv P_2} \left[H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2\right]$$

$$P_1 \equiv \left[H_1^T W_1 H_1\right]^{-1} \tag{4}$$

$$P_2 \equiv \left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1} \tag{5}$$

Z definicji:

$$P_1 \equiv \left[H_1^T W_1 H_1\right]^{-1} \quad \Rightarrow \quad P_1^{-1} = H_1^T W_1 H_1$$

$$P_2 \equiv \left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1} \quad \Rightarrow \quad P_2^{-1} = H_1^T W_1 H_1 + H_2^T W_2 H_2$$

$$= P_1^{-1} + H_2^T W_2 H_2$$

zakładając istnienie P_1^{-1} oraz P_2^{-1}, mamy zatem zależność

$$P_2^{-1} = P_1^{-1} + H_2^T W_2 H_2 \qquad (6)$$

Korzystając z

$$P_1 \equiv \left[H_1^T W_1 H_1\right]^{-1}$$

$$P_2 \equiv \left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1}$$

optymalne wartości estymowane po pierwszej serii pomiarów

$$\hat{\boldsymbol{x}}_1 = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1$$

i po drugiej serii pomiarów

$$\hat{\boldsymbol{x}}_2 = \left[H_1^T W_1 H_1 + H_2^T W_2 H_2\right]^{-1} \left[H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2\right]$$

zapiszemy

$$\hat{\boldsymbol{x}}_1 = P_1 H_1^T W_1 \tilde{\boldsymbol{y}}_1 \tag{7}$$

$$\hat{\boldsymbol{x}}_2 = P_2 \left[H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2\right] \tag{8}$$

Zależność (7)

$$\hat{\boldsymbol{x}}_1 = P_1 H_1^T W_1 \tilde{\boldsymbol{y}}_1$$

pozwala napisać (lewostronne mnożenie przez P_1^{-1})

$$P_1^{-1} \hat{\boldsymbol{x}}_1 = H_1^T W_1 \tilde{\boldsymbol{y}}_1$$

A zależność (6)

$$P_2^{-1} = P_1^{-1} + H_2^T W_2 H_2$$

pozwala napisać (po przeniesieniach między stronami)

$$P_1^{-1} = P_2^{-1} - H_2^T W_2 H_2$$

Ostatnią zależność podstawiamy do $P_1^{-1} \hat{\boldsymbol{x}}_1 = H_1^T W_1 \tilde{\boldsymbol{y}}_1$ otrzymując

$$H_1^T W_1 \tilde{\boldsymbol{y}}_1 = P_2^{-1} \hat{\boldsymbol{x}}_1 - H_2^T W_2 H_2 \hat{\boldsymbol{x}}_1$$

Otrzymaną zależność

$$H_1^T W_1 \tilde{\boldsymbol{y}}_1 = P_2^{-1} \hat{\boldsymbol{x}}_1 - H_2^T W_2 H_2 \hat{\boldsymbol{x}}_1$$

podstawiamy do (8)

$$\hat{\boldsymbol{x}}_2 = P_2 \left[H_1^T W_1 \tilde{\boldsymbol{y}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2 \right]$$

otrzymując

$$\hat{\boldsymbol{x}}_2 = P_2 \left[P_2^{-1} \hat{\boldsymbol{x}}_1 - H_2^T W_2 H_2 \hat{\boldsymbol{x}}_1 + H_2^T W_2 \tilde{\boldsymbol{y}}_2 \right]$$

$$\hat{\boldsymbol{x}}_2 = \hat{\boldsymbol{x}}_1 - P_2 H_2^T W_2 H_2 \hat{\boldsymbol{x}}_1 + P_2 H_2^T W_2 \tilde{\boldsymbol{y}}_2$$

$$\hat{\boldsymbol{x}}_2 = \hat{\boldsymbol{x}}_1 + P_2 H_2^T W_2 \left(\tilde{\boldsymbol{y}}_2 - H_2 \hat{\boldsymbol{x}}_1 \right)$$

$$\hat{\boldsymbol{x}}_2 = \hat{\boldsymbol{x}}_1 + P_2 H_2^T W_2 \left(\tilde{\boldsymbol{y}}_2 - H_2 \hat{\boldsymbol{x}}_1 \right)$$

Ostatecznie możemy napisać

$$\hat{\boldsymbol{x}}_2 = \hat{\boldsymbol{x}}_1 + K_2 \left(\tilde{\boldsymbol{y}}_2 - H_2 \hat{\boldsymbol{x}}_1 \right) \quad (9)$$

$$K_2 \equiv P_2 H_2^T W_2 \quad (10)$$

$$P_2^{-1} = P_1^{-1} + H_2^T W_2 H_2$$

Otrzymaliśmy sekwencyjny mechanizm otrzymywania uaktualnionej estymaty $\hat{\boldsymbol{x}}_2$ w oparciu o poprzednią estymatę $\hat{\boldsymbol{x}}_1$ i pewne dodatkowe obliczenia związane z pozyskaniem nowych pomiarów $\tilde{\boldsymbol{y}}_2$

Otrzymany wynik nietrudno uogólnić na przypadek wykorzystania k-tej estymaty dla otrzymania k+1 estymaty po uzyskaniu k+1 zestawu pomiarów

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right) \quad (11)$$

gdzie

$$K_{k+1} \equiv P_{k+1} H_{k+1}^T W_{k+1} \quad (12)$$

$$P_{k+1}^{-1} = P_k^{-1} + H_{k+1}^T W_{k+1} H_{k+1} \quad (13)$$

K – macierz wzmocnień Kalmana

Optymalne wartości estymowane nieznanych parametrów wyznaczone w oparciu o poprzednie k serii pomiarów

Wartości y zmierzone w k+1 serii pomiarów

Predykcja wartości y z wykorzystaniem wartości estymowanych nieznanych parametrów wyznaczonych w oparciu o poprzednie k serii pomiarów i aktualną macierz obserwacji z k+1 serii pomiarów

Podany wynik (11) – (13) stanowi najważniejszy rezultat sekwencyjnej teorii estymacji !!!

Równanie (11) modyfikuje poprzednią, najlepszą estymatę przez korekcję wykorzystującą informację zawartą w k+1 zestawie pomiarów. Równanie to nazywa się **równaniem aktualizacji Kalman'a** obliczania poprawionej estymaty

Równanie (12) jest wzmocnieniem członu korekcyjnego nazywanym **macierzą wzmocnień Kalman'a**

Równanie (11)

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right)$$

Liniowy (niestacjonarny) dyskretny system dynamiczny

$$\hat{\boldsymbol{x}}_{k+1} = \left[I - K_{k+1}H_{k+1}\right]\hat{\boldsymbol{x}}_k + K_{k+1}\tilde{\boldsymbol{y}}_{k+1}$$

Znane narzędzia analizy liniowych systemów dyskretnych mogą być zastosowane do badania stabilności, odpowiedzi czasowych itp..

Macierz P jest nazywana **macierzą informacyjną**, a sposób obliczania P^{-1} podany wzorem (13)

$$P_{k+1}^{-1} = P_k^{-1} + H_{k+1}^T W_{k+1} H_{k+1}$$

rekurencją macierzy informacyjnej

Podany w ten sposób przepis obliczania P_{k+1} wymaga obliczania odwrotności prawej strony równania (13) – brak przewagi nad obliczaniem kolejnych estymat w ujęciu jednorazowym (3), gdzie

$$\hat{\boldsymbol{x}}_2 = \left(H^T W H\right)^{-1} H^T W \tilde{\boldsymbol{y}}$$

- w dalszym ciągu potrzeba odwracać macierz nxn

Pożądana metoda pozwalająca obliczać P_{k+1} wykorzystująca fakt posiadania wcześniej obliczonej macierz P_k

Kiedy liczba nowych pomiarów m_{k+1} jest mała w porównaniu do liczby nieznanych parametrów n, aktualizacja P_{k+1} może być efektywnie obliczona wykorzystując lemat odwracania macierzy Sherman'a – Morrison'a – Woodbury'ego

Lemat Sherman'a – Morrison'a – Woodbury'ego

Jeżeli

$$F = \left[A + BCD\right]^{-1}$$

$$P_{k+1} = \left[P_k^{-1} + H_{k+1}^T W_{k+1} H_{k+1}\right]^{-1}$$

gdzie

$$F - macierz\ n \times n$$

$$A - macierz\ n \times n$$

$$B - macierz\ n \times m$$

$$C - macierz\ m \times m$$

$$D - macierz\ m \times n$$

to, jeżeli istnieją odpowiednie macierze odwrotne

$$F = A^{-1} - A^{-1}B\left(DA^{-1}B + C^{-1}\right)^{-1} DA^{-1}$$

Jeżeli podstawimy

$$F = P_{k+1}$$

$$A - P_k^{-1}$$

$$B - H_{k+1}^T$$

$$C - W_{k+1}$$

$$D - H_{k+1}$$

to, rekurencja macierzy informacyjnej przyjmie postać

$$P_{k+1} = P_k - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1} \right)^{-1} H_{k+1} P_k \tag{14}$$

! odwracanie macierzy o rzędzie mniejszym od n!

Równanie aktualizacji estymat (11)

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right)$$

też może być przedstawiane w wielu alternatywnych formach

Jedno z częściej stosowanych podejść – podstawienie (14)

$$P_{k+1} = P_k - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k$$

do równania macierzy wzmocnień Kalman'a (12)

$$K_{k+1} = P_{k+1} H_{k+1}^T W_{k+1}$$

Otrzymamy:

$$K_{k+1} = \left[P_k - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k\right] H_{k+1}^T W_{k+1}$$

$$= \left[P_k H_{k+1}^T - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k H_{k+1}^T\right] W_{k+1}$$

$$= P_k H_{k+1}^T \left[I - \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k H_{k+1}^T\right] W_{k+1}$$

„Wyłączając” przed nawias

$$\left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1}$$

$$K_{k+1} = P_k H_{k+1}^T \left[I - \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k H_{k+1}^T\right] W_{k+1}$$

$$= P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} \left[\left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right) - H_{k+1} P_k H_{k+1}^T\right] W_{k+1}$$

$$= P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} \left[H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1} - H_{k+1} P_k H_{k+1}^T\right] W_{k+1}$$

$$= P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1}$$

Doszliśmy do formy równania rekurencyjnego nazywanej kowariancyjną

Kowariancyjna forma równania rekurencyjnego (11)

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right) \tag{15}$$

gdzie

$$K_{k+1} = P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} \tag{16}$$

$$P_{k+1} = \left[I - K_{k+1} H_{k+1}\right] P_k \tag{17}$$

Równanie (17) otrzymujemy z (14)

$$\begin{aligned} P_{k+1} &= P_k - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1} P_k \\ &= \left[I - P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1} H_{k+1}\right] P_k \\ &= \left[I - K_{k+1} H_{k+1}\right] P_k \end{aligned}$$

Porównanie:

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right)$$

gdzie

$$K_{k+1} = P_{k+1}H_{k+1}^T W_{k+1}$$

$$P_{k+1}^{-1} = P_k^{-1} + H_{k+1}^T W_{k+1} H_{k+1}$$

$$\hat{\boldsymbol{x}}_{k+1} = \hat{\boldsymbol{x}}_k + K_{k+1}\left(\tilde{\boldsymbol{y}}_{k+1} - H_{k+1}\hat{\boldsymbol{x}}_k\right)$$

gdzie

$$K_{k+1} = P_k H_{k+1}^T \left(H_{k+1} P_k H_{k+1}^T + W_{k+1}^{-1}\right)^{-1}$$

$$P_{k+1} = \left[I - K_{k+1}H_{k+1}\right]P_k$$

Kowariancyjna forma równania estymacji sekwencyjnej metodą najmniejszych kwadratów jest najczęściej używaną ze względu na efektywność obliczeniową

Realizacja obliczeń estymacji sekwencyjnej

Trzy możliwości rozpoczęcia obliczeń:

1. posiadanie estymaty a priori $\hat{\boldsymbol{x}}_1$ oraz macierzy P_1

2. wykorzystanie pierwszego pakietu danych i przeprowadzenie estymacji jednokrotnej dla określenia $\hat{\boldsymbol{x}}_q$ oraz P_q

$$\hat{\boldsymbol{x}}_q = \left(H_q^T W_q H_q\right)^{-1} H_q^T W_q \tilde{\boldsymbol{y}}_q$$

$$P_q = \left[H_q^T W_q H_q\right]^{-1}$$

Warunek

$$n \leq q \tag{18}$$

Następnie estymacja sekwencyjna może być kontynuowana dla k ≥ q

3. Można rozpocząć też obliczenia, jeżeli warunek (18) nie jest spełniony (mała liczba pomiarów) dla k=1,2,...q-1 stosując

$$P_1 = \left[\frac{1}{\alpha} I + H_1^T W_1 H_1\right]^{-1} \qquad (19)$$

$$\hat{\boldsymbol{x}}_1 = P_1\left[\frac{1}{\alpha}\boldsymbol{\beta} + H_1^T W_1 \tilde{\boldsymbol{y}}_1\right] \qquad (20)$$

$$P_1 \equiv \left[H_1^T W_1 H_1\right]^{-1}$$

$$\hat{\boldsymbol{x}}_1 = P_1 H_1^T W_1 \tilde{\boldsymbol{y}}_1$$

gdzie, α jest bardzo „dużą” liczbą a β jest wektorem bardzo „małych” liczb

Przykład 1:

System

$$\dot{y} = ay + bu$$

Dyskretna aproksymacja systemu z przedziałem dyskretyzacji Δt

$$y(k+1) = A_D y(k) + B_D u(k)$$

gdzie:

$$A_D = e^{a\Delta t}$$

$$B_D = \int_0^{\Delta t} be^{at}\,dt = \frac{b}{a}\left(e^{a\Delta t} - 1\right)$$

Dla tego systemu wykonaliśmy estymację jednokrotną

Wynik tej estymacji

$$\begin{bmatrix} \widehat{A}_D \\ \widehat{B}_D \end{bmatrix} = \begin{bmatrix} 0.9048 \\ 0.0950 \end{bmatrix}$$

Przeprowadzimy dla tego systemu estymację sekwencyjną metodą najmniejszych kwadratów z jednym pomiarem $\widetilde{y}_k$ jednorazowo

$$\alpha = 1 \cdot 10^3 \qquad \beta = \begin{bmatrix} 1 \cdot 10^{-2} & 1 \cdot 10^{-2} \end{bmatrix}^T$$

Przypomnienie: Symulacja błędu pomiaru: generator szumu gaussowskiego o zerowej wartości średniej i odchyleniu standardowym σ = 0.08

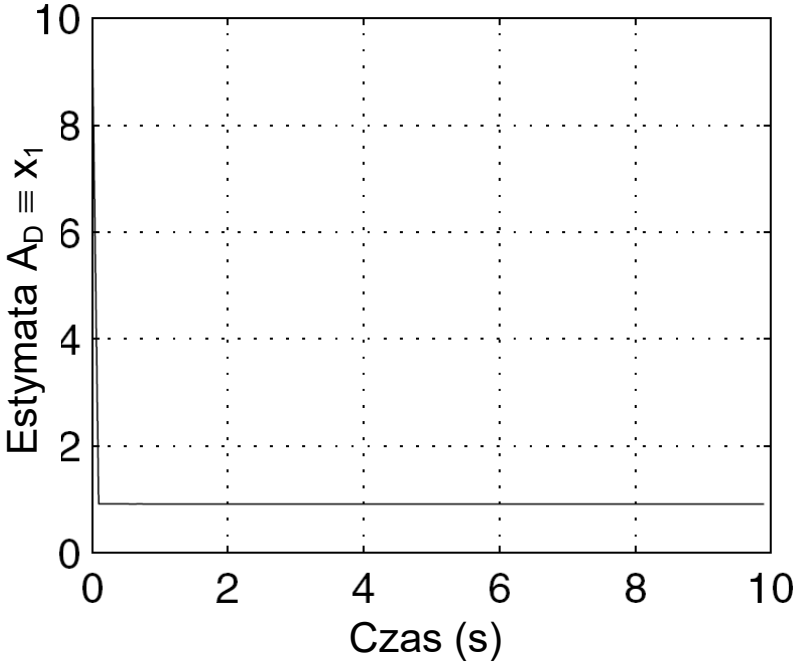
Przyjmiemy $W_k = \sigma^{-2} = 156.25$

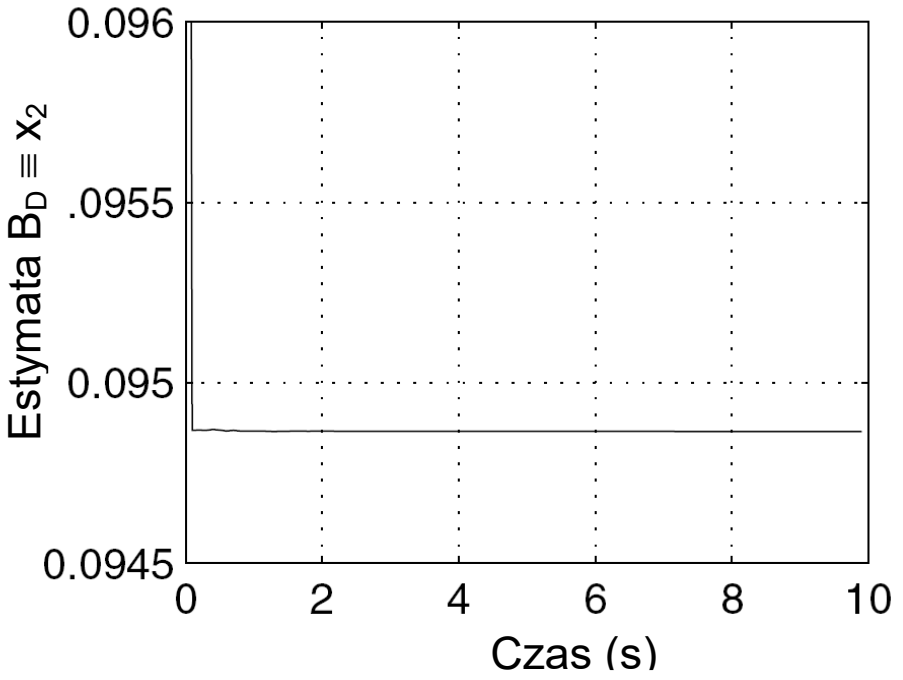
Początkowe:

$$P_1 = \left[\frac{1}{\alpha} I + H_1^T W_1 H_1\right]^{-1} = \begin{bmatrix} 1.000 \cdot 10^6 & 1.038 \cdot 10^3 \\ 1.038 \cdot 10^3 & 1.077 \cdot 10^0 \end{bmatrix}$$

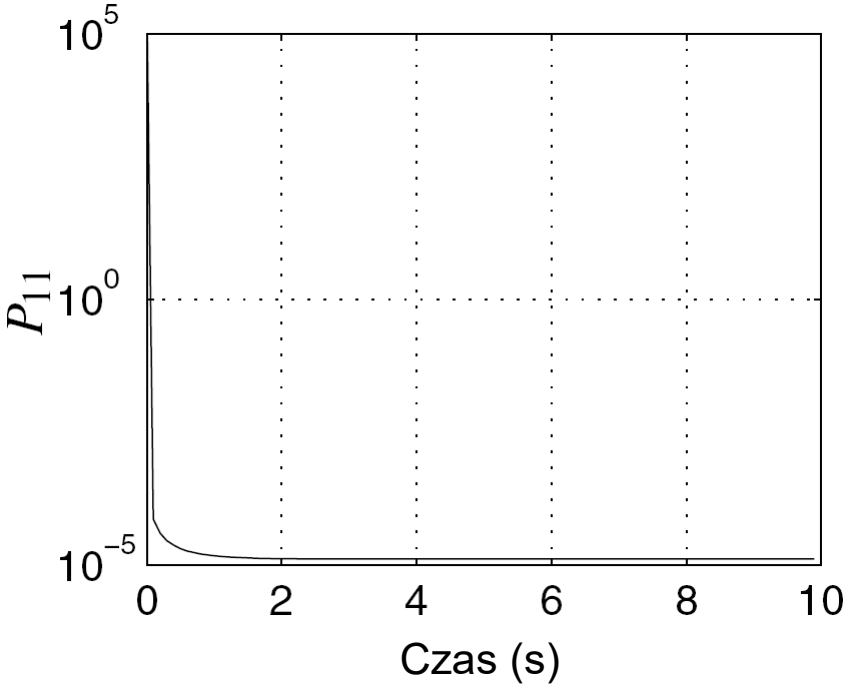
$$\hat{\boldsymbol{x}}_1 = P_1\left[\frac{1}{\alpha}\boldsymbol{\beta} + H_1^T W_1 \tilde{\boldsymbol{y}}_1\right] = \begin{bmatrix} 10.010 \\ 0.014 \end{bmatrix}$$

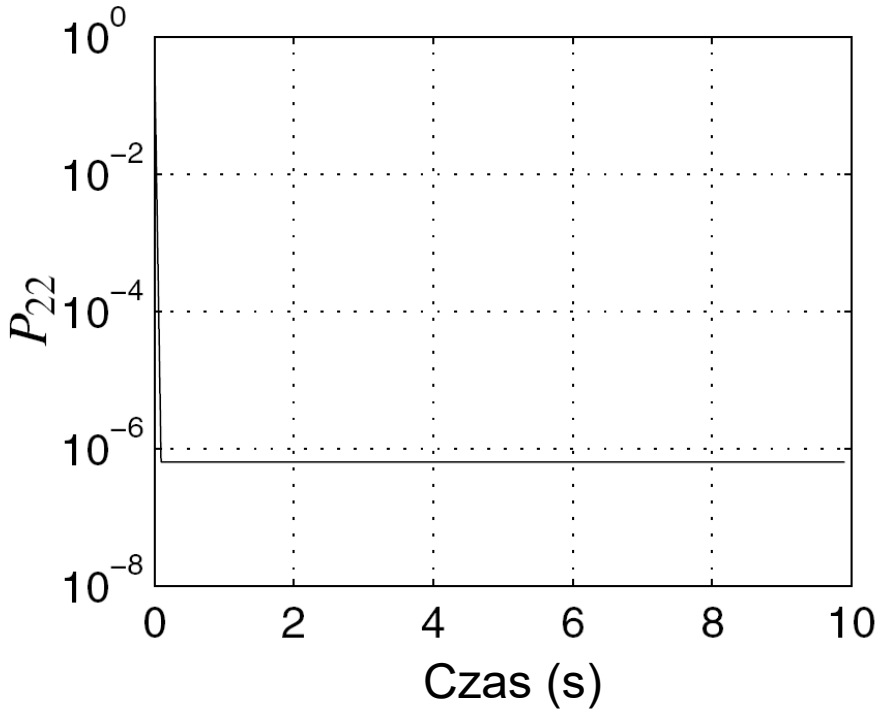
Estymaty:





Elementy diagonalne macierzy P





Dziękuję
– koniec materiału prezentowanego podczas wykładu

POLITECHNIKA GDAŃSKA

HISTORIA MĄDROŚCIĄ
PRZYSZŁOŚĆ WYZWANIEM