

Modelowanie i Identyfikacja

(MiI2025)

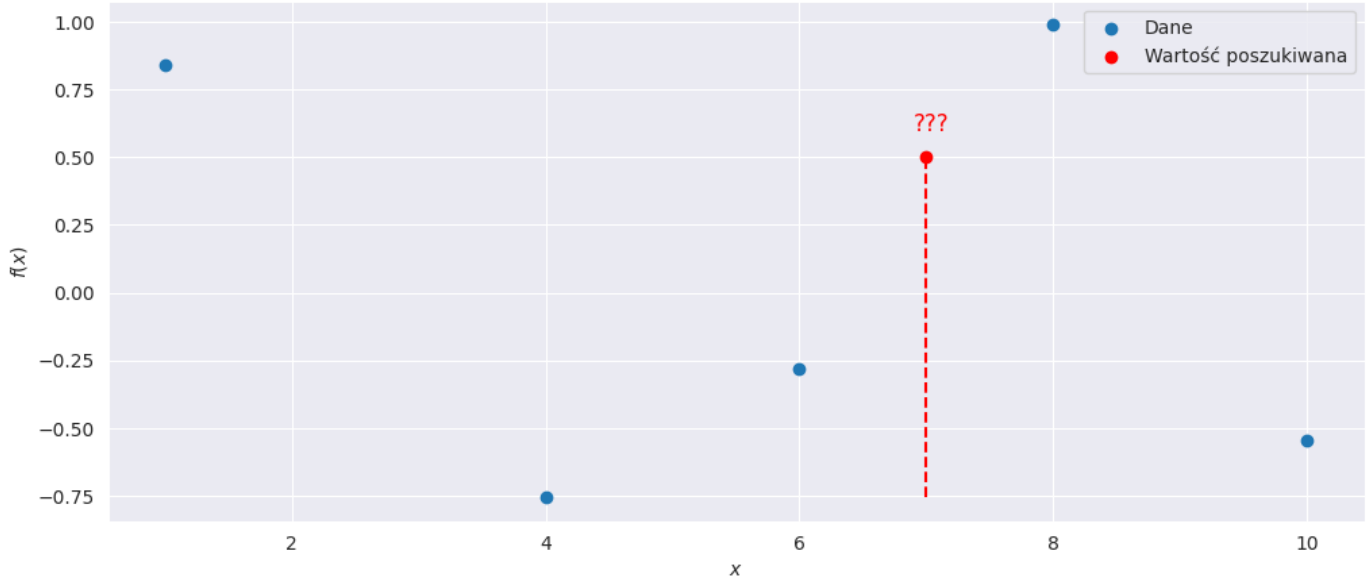
Materiał wykładowy: Modelowanie z wykorzystaniem procesów Gaussowskich

Wydział Elektrotechniki i Automatyki
Katedra Inteligentnych Systemów Sterowania i Wspomagania Decyzji
dr inż. Bartosz Puchalski (bartosz.puchalski@pg.edu.pl)
24.06.2026

Motywacja, background

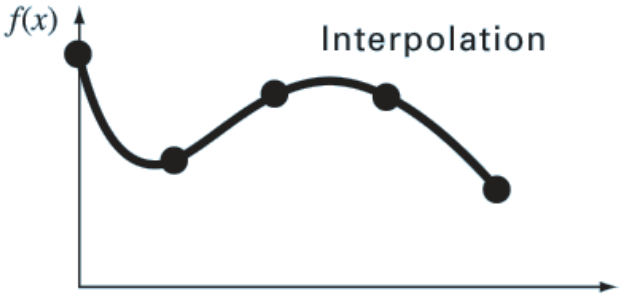
Naszym zadaniem będzie znalezienie sposobu na to, aby na podstawie danych, które posiadamy (np. na podstawie zapisanych próbek) spróbować odtworzyć funkcje (znaleźć model zjawiska), na podstawie której (którego) dane te mogły zostać wygenerowane.

W tym celu możemy wykorzystać znane metody parametryczne takie jak interpolacja czy regresja.



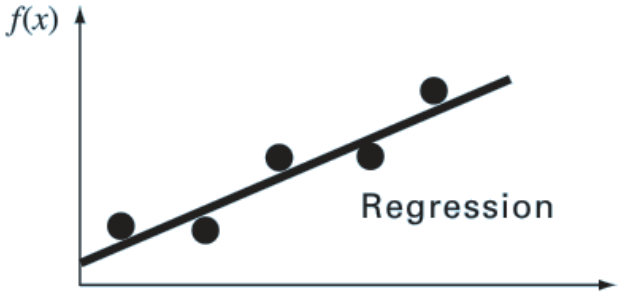
Motywacja, background

Interpolacja służy do oszacowywania wartości wewnątrz zbioru danych, czyli pomiędzy znanymi punktami. Zakłada, że dane są dostępne w określonym zakresie i przewidywane wartości znajdują się w ramach tego zakresu.



[1]

Regresja pozwala na przewidywanie wartości nie tylko wewnątrz, ale także poza zakresem znanych danych. Regresja koncentruje się na modelowaniu relacji pomiędzy zmiennymi, budując równanie lub funkcję, która najlepiej je opisuje. Może być stosowana zarówno do analizy trendów, jak i ekstrapolacji danych poza dostępny zakres.



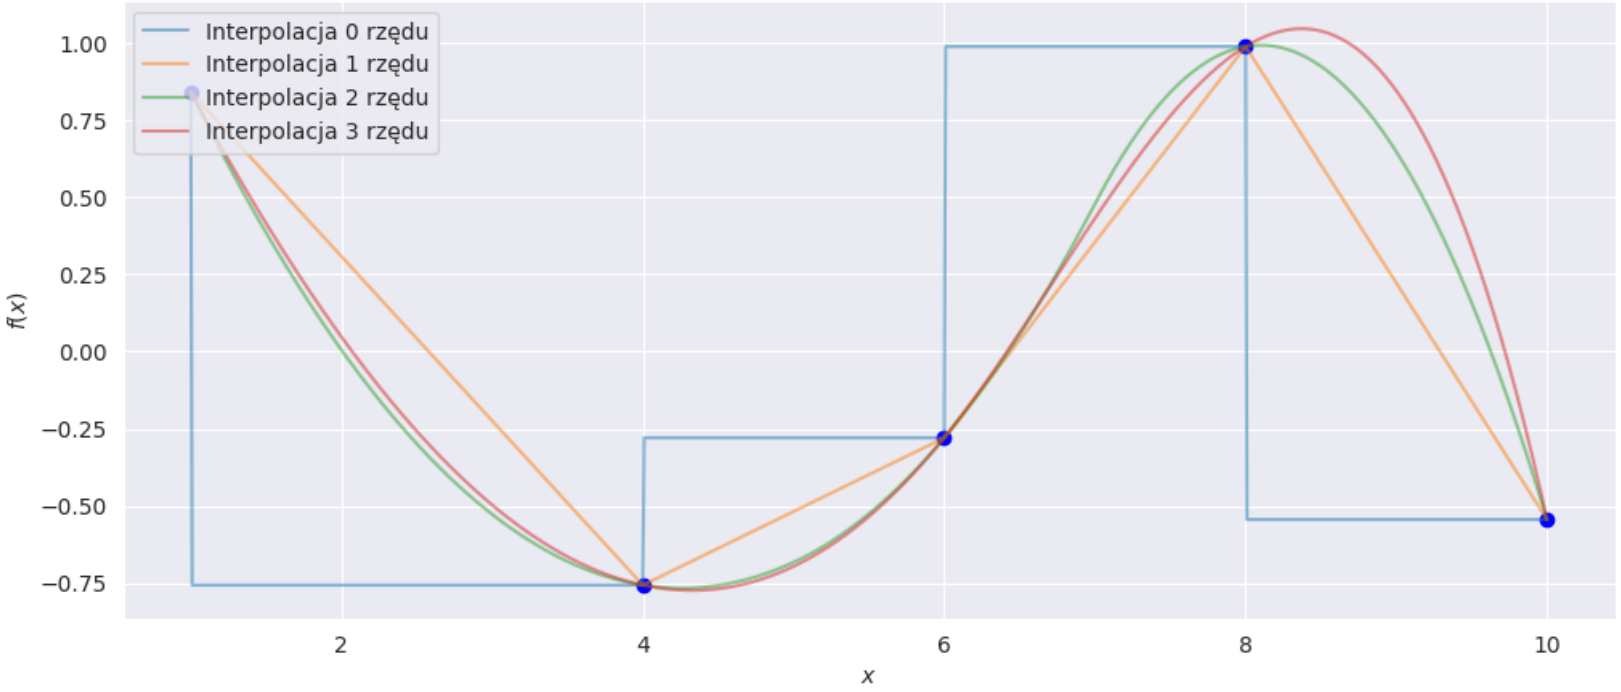
[1]

[1] Chapra, S.C. and Canale, R.P. (2015) Numerical Methods for Engineers. 7th Edition, McGraw-Hill, New York

Motywacja, background

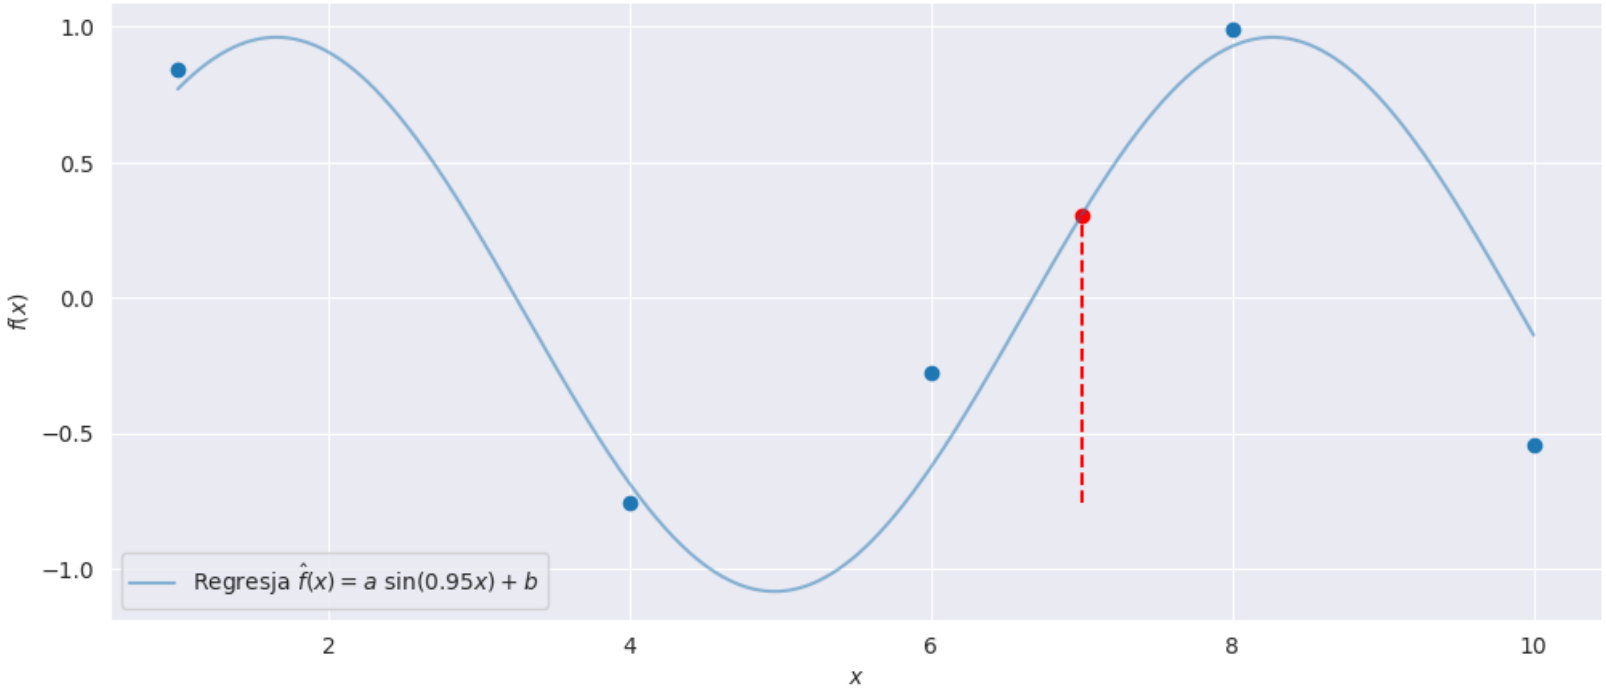
Przykład wykorzystania interpolacji wielomianowej:

- zerowego rzędu,
- pierwszego rzędu,
- drugiego rzędu,
- trzeciego rzędu.



Motywacja, background

Przykład wykorzystania regresji z funkcją: $\hat{f}(x) = a\sin(0.95x) + b$



Problemem jest to, że nie zawsze wiemy jaką funkcję wybrać lub z jakich funkcji bazowych będzie ona się składać ¯_(ツ)_/¯

Rozkład Gaussa

O zmiennej losowej X mówi się, że ma **rozkład normalny** ze średnią μ i wariancją σ^2, jeśli jej funkcja gęstości prawdopodobieństwa jest dana jako:

$$P_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

gdzie: X oznacza zmienną losową, a x jest argumentem należącym do zbioru liczb rzeczywistych $\mathbb{R}$. Rozkład Gaussowski dla X jest zazwyczaj oznaczany jako

$$P(x) \sim \mathcal{N}(\mu, \sigma^2)$$

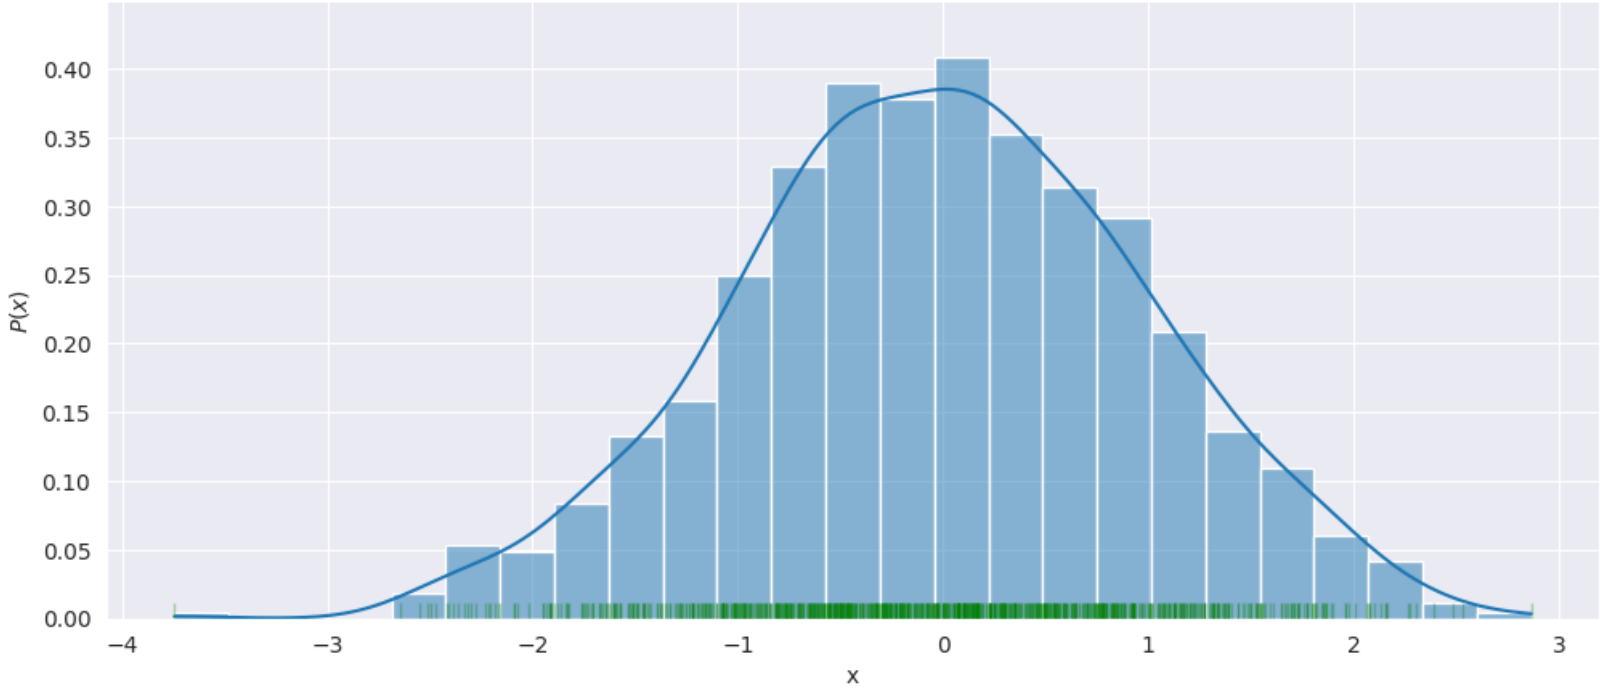
Jeżeli $\mu = 0$ i $\sigma = 1$, to rozkład normalny nazywa się **standardowym rozkładem normalnym** i jest on wyrażony następującą funkcją gęstości prawdopodobieństwa:

$$\phi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

Parametr σ nazywany jest odchyleniem standardowym.

Rozkład Gaussa

Funkcja gęstości prawdopodobieństwa dla przykładowego wektora danych (1000 elementów) wygenerowanego na podstawie jednowymiarowego rozkładu Gaussowskiego została przedstawiona poniżej.



Rozkład Gaussa

Wiemy, że funkcja gęstości prawdopodobieństwa $\mathcal{N}(\mu, \sigma^2)$ dla rozkładu jednowymiarowego (1D) jest określona za pośrednictwem dwóch parametrów μ oraz σ^2.

Mając do dyspozycji zestaw zebranych danych $\mathbf{x}_1$ możemy zamodelować go przyjmując, że dystrybucja jego elementów jest Gaussowska i jednowymiarowa. W takim wypadku obowiązuje

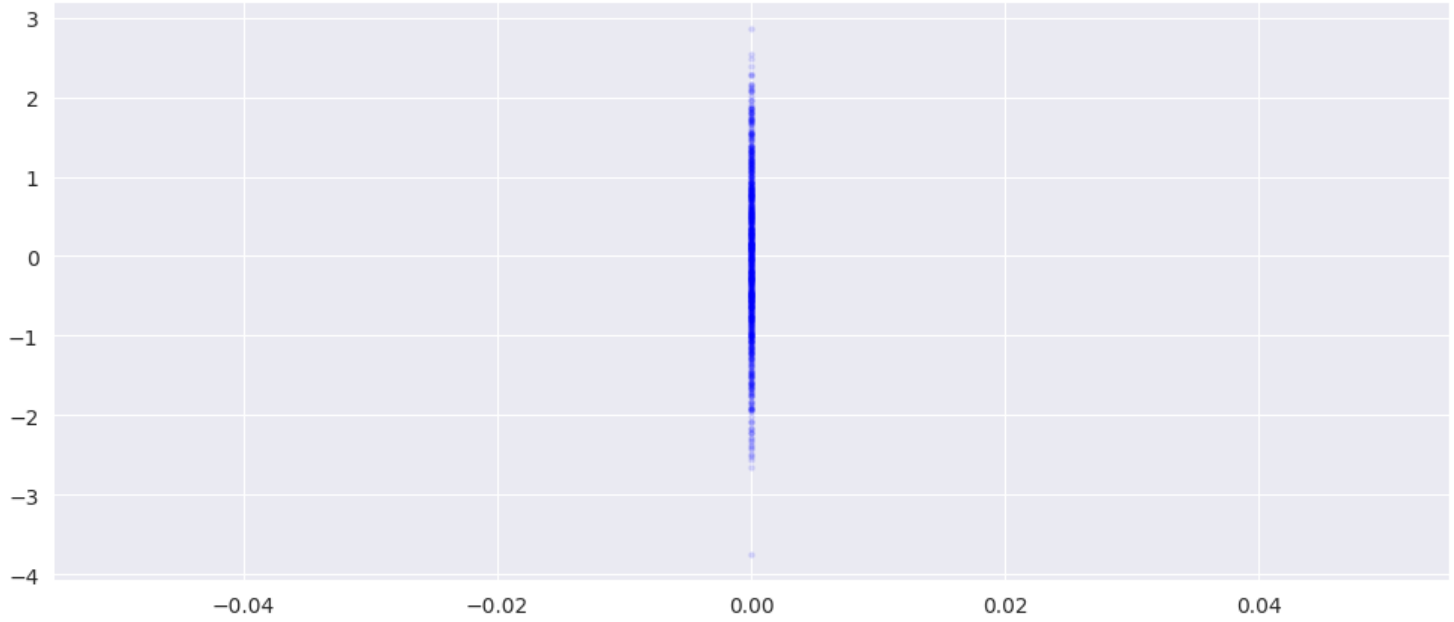
$$\mu = \frac{1}{M}\sum_{i=1}^{M} x_i$$

oraz

$$\sigma^2 = \frac{1}{M}\sum_{i=1}^{M} (x_i - \mu)^2$$

Rozkład Gaussa

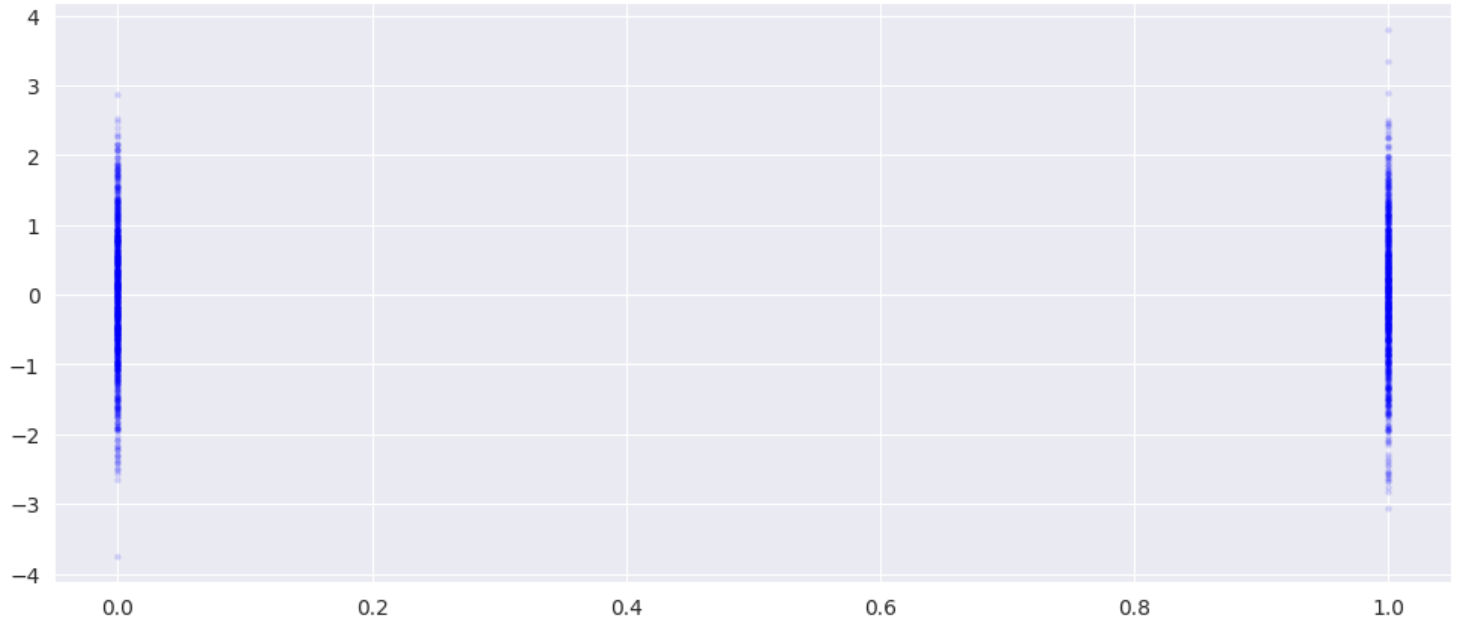
Zobaczmy co się stanie, gdy nasz wektor losowych liczb rzucimy na oś OX innej przestrzeni. Aby tego dokonać narysujemy wektor $\mathbf{x}_1$ w miejscu, w którym w nowej przestrzeni $x = 0$.



Wychodzi na to, że nie zrobiliśmy nic innego jak tylko narysowaliśmy nasz wektor $\mathbf{x}_1$ pionowo w nowym punkcie $x = 0$. Nie ulega wątpliwości, że $\mathbf{x}_1$ cechuje się rozkładem Gaussa.

Rozkład Gaussa

W ten sam sposób możemy wygenerować wektory dla innych punktów naszej nowej przestrzeni. Dla przykładu umieścimy wektor $\mathbf{x}_1$ w punkcie $x = 0$ oraz $\mathbf{x}_2$ w punkcie $x = 1$.

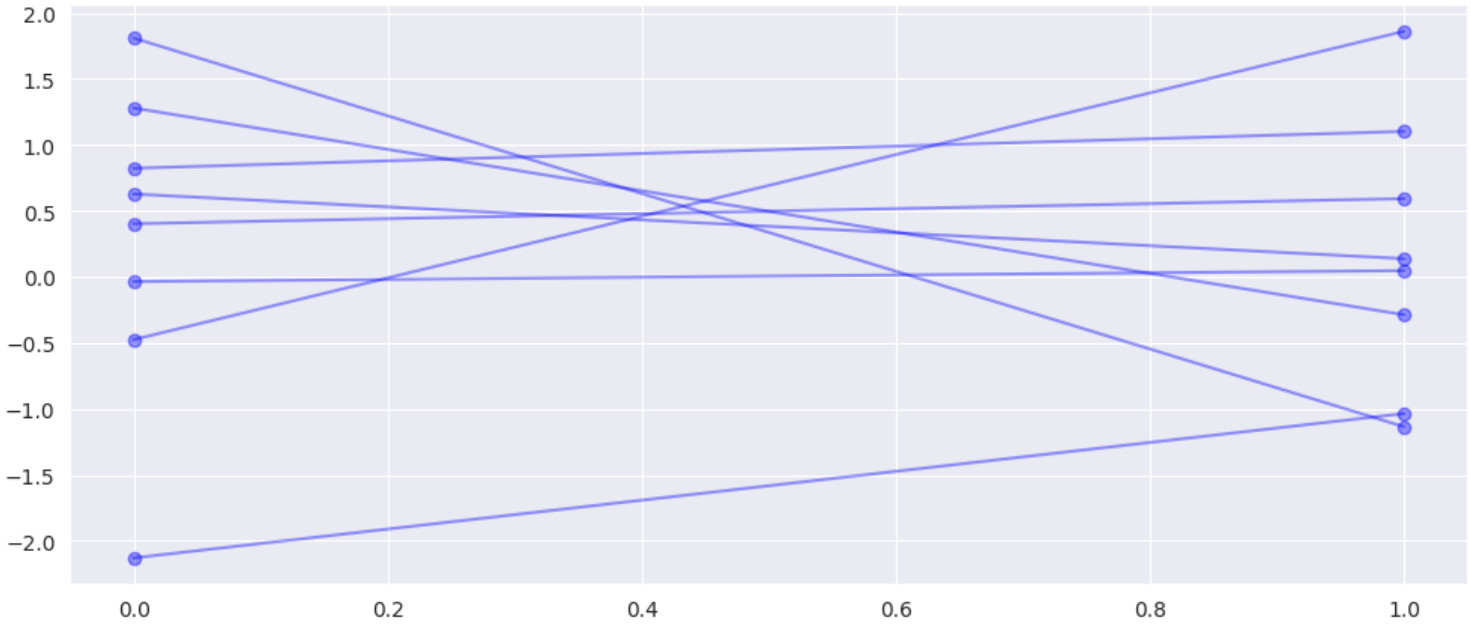


Należy tutaj zauważyć, że w dalszym ciągu $\mathbf{x}_1$ oraz $\mathbf{x}_2$ charakteryzują się rozkładem Gaussowskim.

Rozkład Gaussa

Zobaczmy co się stanie gdy połączymy obydwa wektory. Dla czytelności ograniczymy ilość wygenerowanych punktów w wektorach $\mathbf{x}_1$ oraz $\mathbf{x}_2$.

Łączenie wektorów odbywa się według indeksów, np. element wektora $x_{1,1}$ łączymy z elementem $x_{2,1}$ itd.



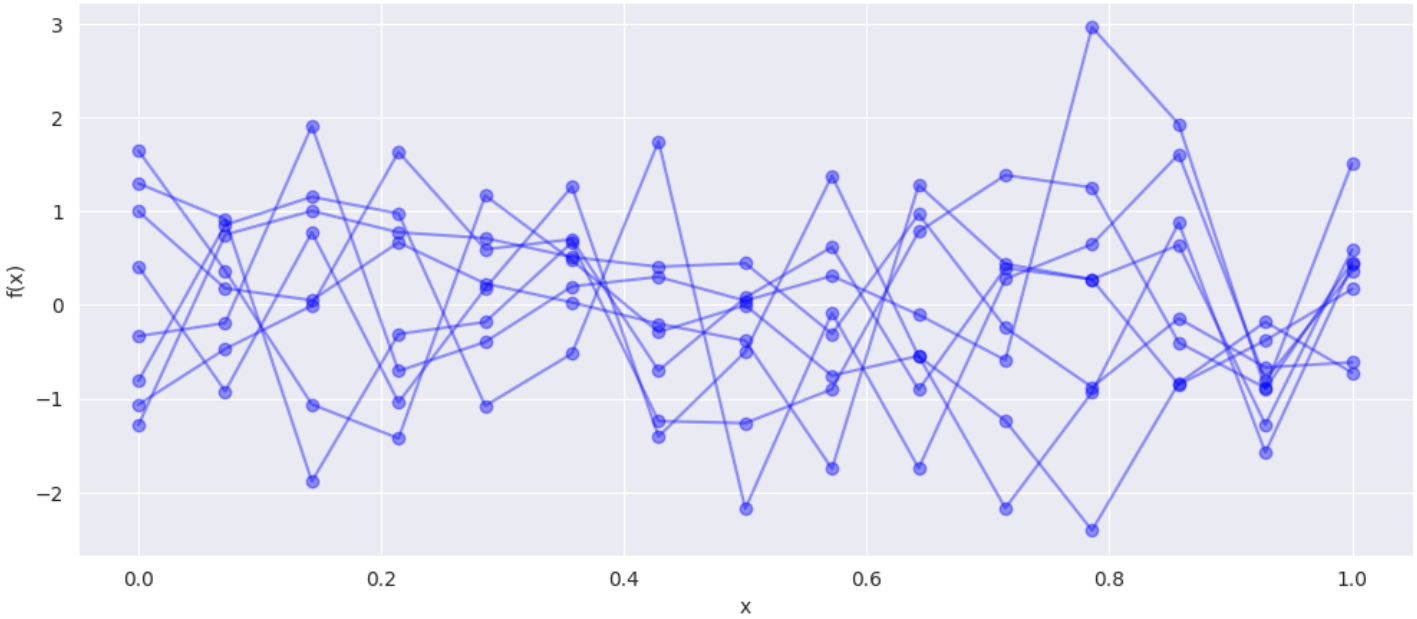
Rozkład Gaussa

Wracając do wątku z początku wykładu dotyczącego regresji. Wygenerowane linie wyglądają jak funkcje dla każdej pary punktów. Z drugiej strony wygląda to również tak jakbyśmy próbkowali region $x \in [0,1]$ funkcjami liniowymi z dwoma punktami na początku oraz końcu.

Aktualnie patrząc na to z perspektywy próbkowania funkcji wykonujemy to w dziedzinie $x \in [0,1]$, czyli w wyznaczonym obszarze zainteresowania, dla którego de facto wykonujemy zadanie regresji.

Będzie to wyglądało w bardziej wyraźny sposób, gdy weźmiemy pod uwagę więcej punktów x, dla których wyrysujemy wektory zgodnie z rozkładem Gaussowskim i połączymy ich elementy.

Rozkład Gaussa



Okazuje się, że znaleźliśmy sposób na losowe generowanie funkcji w określonym obszarze zainteresowania, który w tym wypadku wynosi [0,1].

Niestety wygenerowane funkcje charakteryzują się zbyt wysokim "szumem" aby mogły być one wykorzystane do zadania regresji.

Rozkład Gaussa

Musimy znaleźć sposób aby wygenerowane funkcje pozbawić w jakimś stopniu szumu, czyli wygładzić.

Aby to zrobić przyjmiemy, że punkty znajdujące się na osi OX, tj. punkty wejściowe x, które są blisko siebie powinny charakteryzować się zbliżonymi wartościami funkcji $f(x)$. Sprowadza się to do tego, że wykorzystamy skorelowane ze sobą rozkłady Gaussa.

Wielowymiarowy rozkład Gaussa

Wielowymiarowy rozkład Gaussowski n-wymiarowego losowego wektora $\mathbf{X} = (X_1, \dots, X_n)^T$ można oznaczyć jako

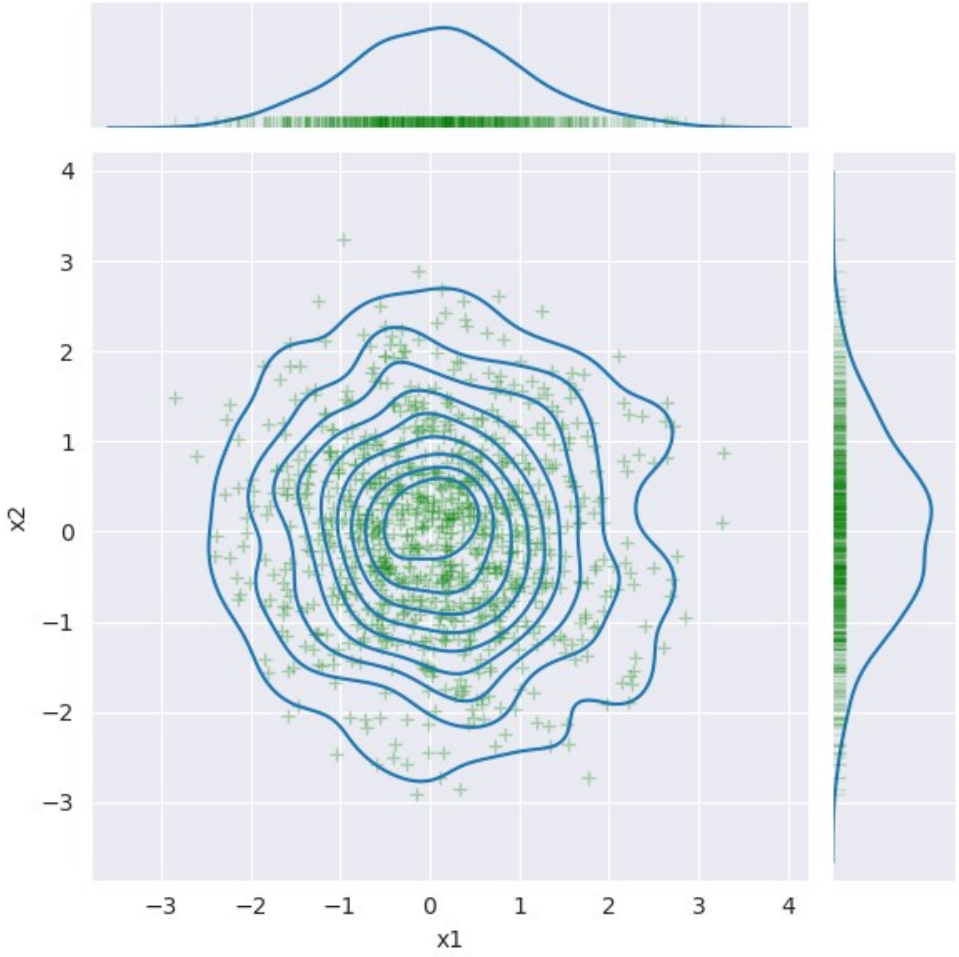
$$\mathbf{X} \sim \mathcal{N}_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

gdzie $\boldsymbol{\mu}$ jest wektorem średnich rozkładu, a $\boldsymbol{\Sigma}$ jest kwadratową macierzą kowariancji. Przykłady 2-wymiarowych rozkładów Gaussowskich przedstawiono poniżej.

Wielowymiarowy rozkład Gaussa

Dwuwymiarowy rozkład Gaussowski o parametrach

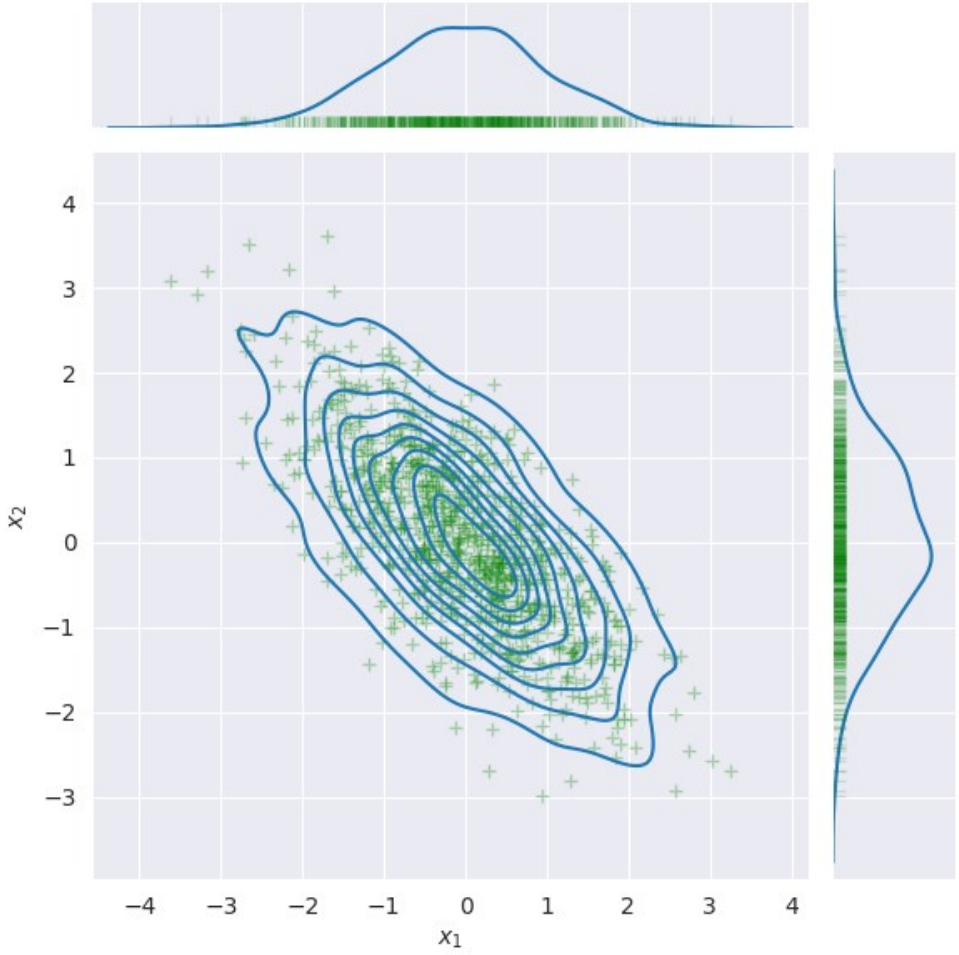
$$\boldsymbol{\mu} = [0 \quad 0] \quad \text{oraz} \quad \boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



Wielowymiarowy rozkład Gaussa

Dwuwymiarowy rozkład Gaussowski o parametrach

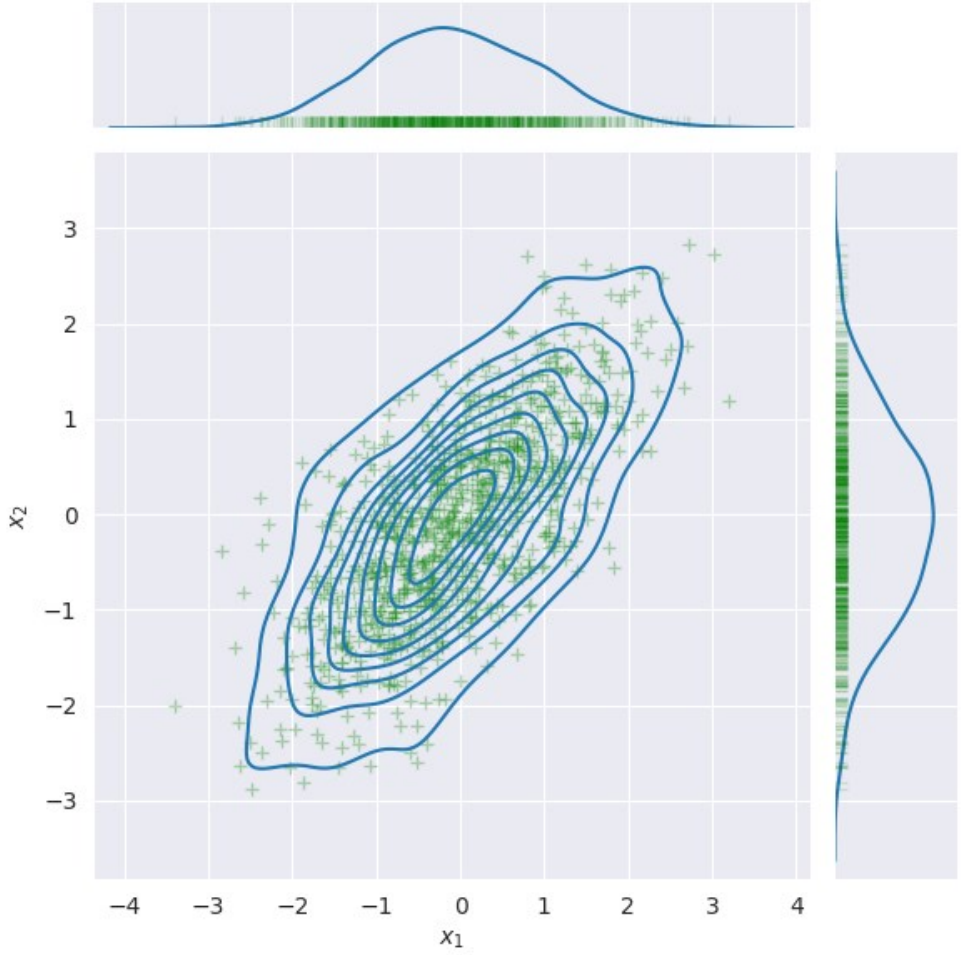
$$\boldsymbol{\mu} = [0 \quad 0] \quad \text{oraz} \quad \boldsymbol{\Sigma} = \begin{bmatrix} 1 & -0.6 \\ -0.6 & 1 \end{bmatrix}$$



Wielowymiarowy rozkład Gaussa

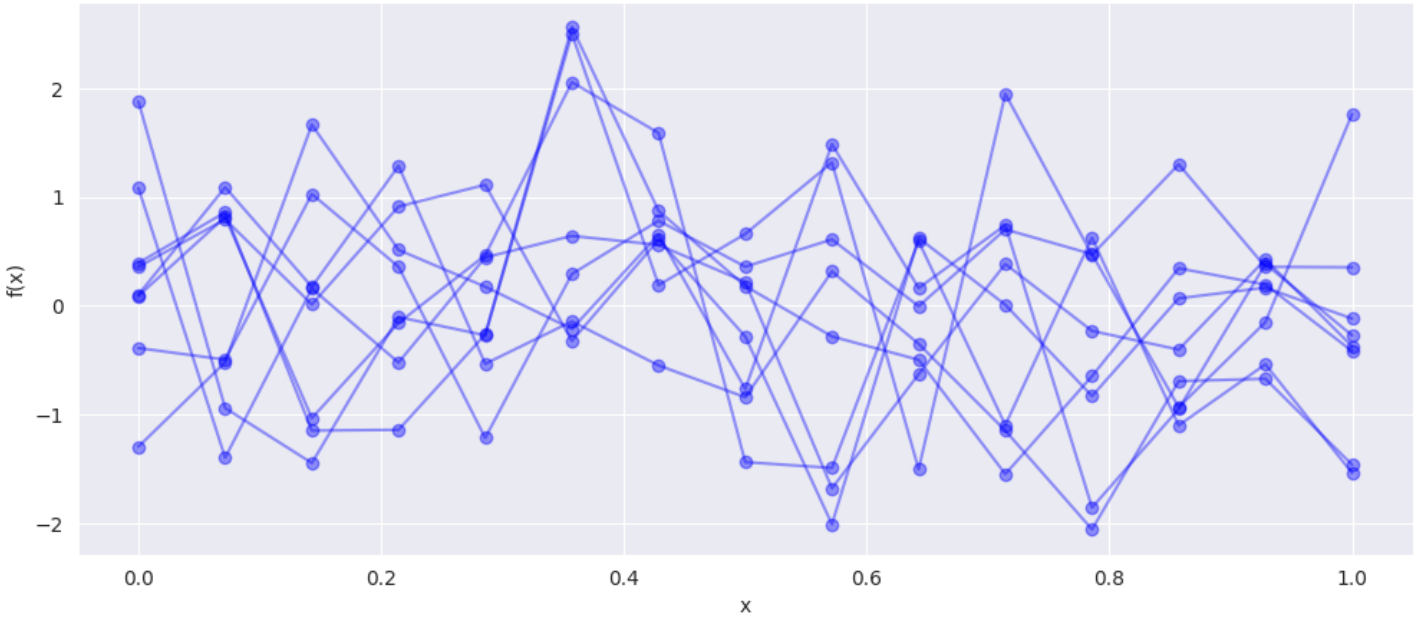
Dwuwymiarowy rozkład Gaussowski o parametrach

$$\boldsymbol{\mu} = [0 \quad 0] \quad \text{oraz} \quad \boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$$



Macierze kowariancji

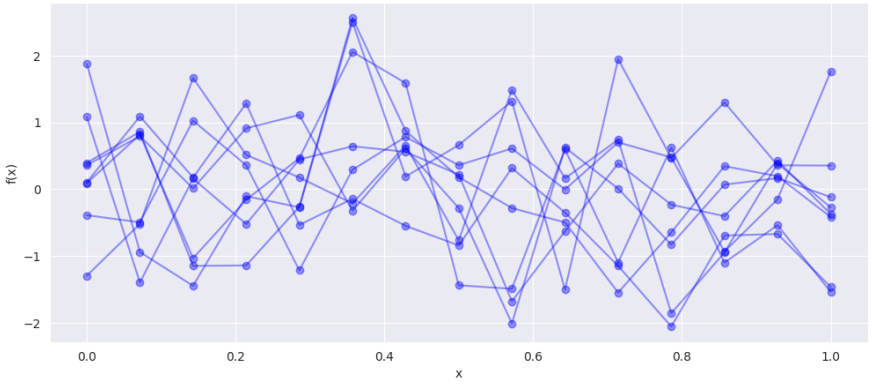
Na samym początku odtwórzmy rysunek, na którym przedstawione były losowo wygenerowane funkcje o rozkładzie Gaussowskim, lecz tym razem do tego celu wykorzystamy wielowymiarowy rozkład Gaussa



`dimensions = 15` → OX → ile wymiarów ma rozkład Gaussa
`number_of_samples = 8` → OY → losujemy z wielowymiarowego rozkładu Gaussa 8 wektorów, które mają po 15 elementów

Macierze kowariancji

W powyższym przykładzie wykorzystaliśmy następującą macierz kowariancji. Jak widać próbkowane funkcje nie są w żadnym stopniu wygładzone.




```
[[1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1. 0.]
 [0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0. 1.]]
```

Macierze kowariancji

Następnie spróbujemy zastanowić się w jaki sposób utworzyć macierz kowariancji tak aby mieć wpływ na jej poziom skorelowania.

Macierz kowariancji opisuje niepewność danych i to, jak niepewność jednego punktu jest związana z niepewnością innego punktu. Jeśli mamy punkty danych, które są całkowicie niezależne, macierz kowariancji posiada tylko elementy na przekątnej (elementy poza przekątną są zerowe).

Jeśli dwa punkty danych tuż obok siebie są powiązane, wtedy wartość elementu macierzy kowariancji odpowiadająca tej parze punktów nie będzie miała wartości zero.

Okazuje się, że do generowania macierzy kowariancji możemy wykorzystać funkcje kernelowe.

Macierze kowariancji

Jedną z najczęściej stosowanych funkcji kernelowych w procesach Gaussowskich jest funkcja Radial Basis Function (RBF) wyrażona jako:

$$K_{RBF}(\mathbf{x}, \mathbf{x}') = \sigma^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|}{2l^2}\right)$$

gdzie: l jest określane jako parametr długości, a σ^2 jest parametrem skalującym. Dla uproszczenia przyjmiemy, że $\sigma^2 = 1$.

Macierze kowariancji

Jak to jest liczone na piechotę…

```
def kernel(x1, x2, length_scale, scale_factor=1):
    # Covariance matrix
    return (scale_factor**2) * np.exp(-1 / (2 * length_scale**2) * np.abs(x1[:, np.newaxis] - x2[:, np.newaxis].T) ** 2)
```

```
a = np.array([[1, 2, 3]])
kernel(a.ravel(), a.ravel(), 1)
```

```
array([[1.        , 0.60653066, 0.13533528],
       [0.60653066, 1.        , 0.60653066],
       [0.13533528, 0.60653066, 1.        ]])
```

```
[
    [np.exp(-(((1 - 1) ** 2) / 2)), np.exp(-(((1 - 2) ** 2) / 2)), np.exp(-(((1 - 3) ** 2) / 2))],
    [np.exp(-(((2 - 1) ** 2) / 2)), np.exp(-(((2 - 2) ** 2) / 2)), np.exp(-(((2 - 3) ** 2) / 2))],
    [np.exp(-(((3 - 1) ** 2) / 2)), np.exp(-(((3 - 2) ** 2) / 2)), np.exp(-(((3 - 3) ** 2) / 2))],
]
```

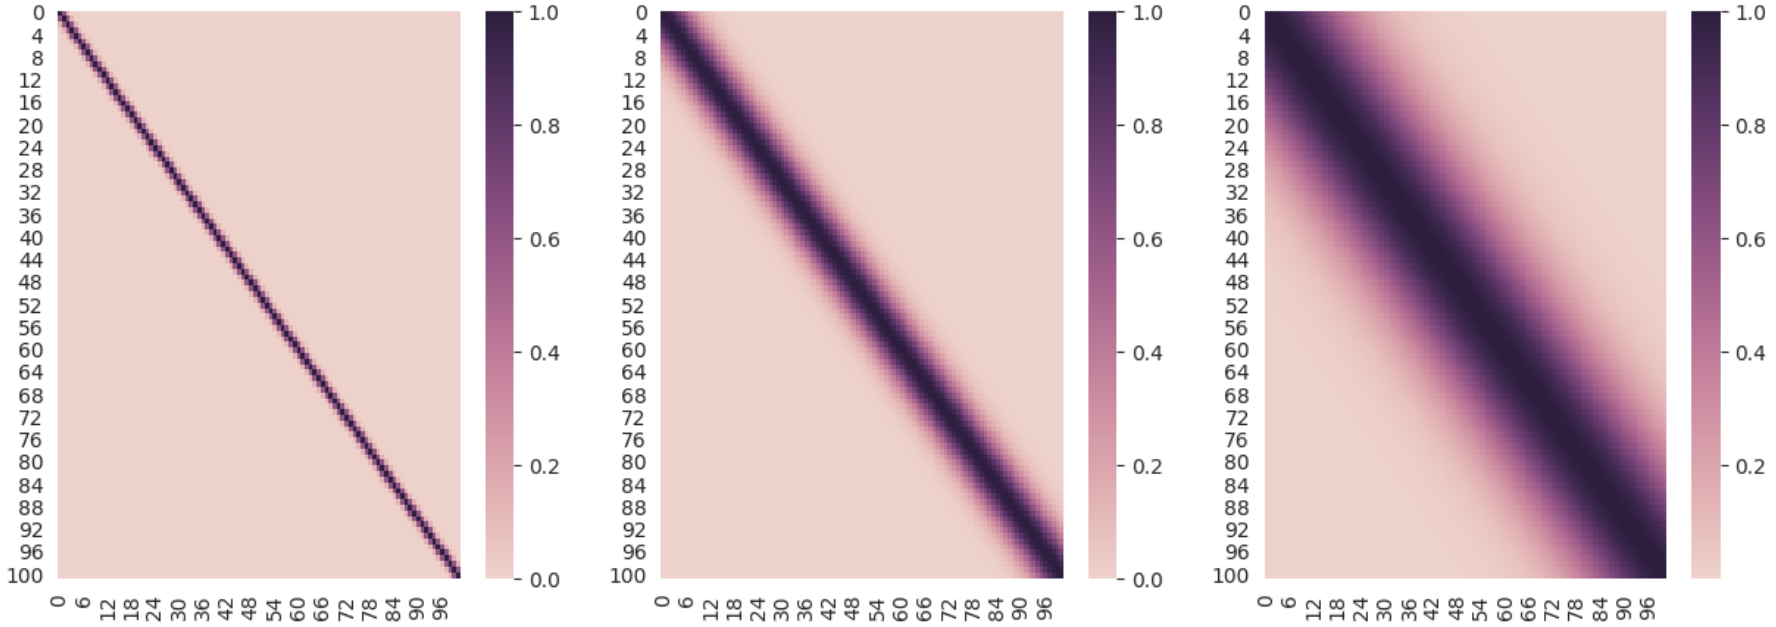
```
[[1.0, 0.6065306597126334, 0.1353352832366127],
 [0.6065306597126334, 1.0, 0.6065306597126334],
 [0.1353352832366127, 0.6065306597126334, 1.0]]
```

```
np.exp(-((a - a.T) ** 2) / 2)
```

```
array([[1.        , 0.60653066, 0.13533528],
       [0.60653066, 1.        , 0.60653066],
       [0.13533528, 0.60653066, 1.        ]])
```

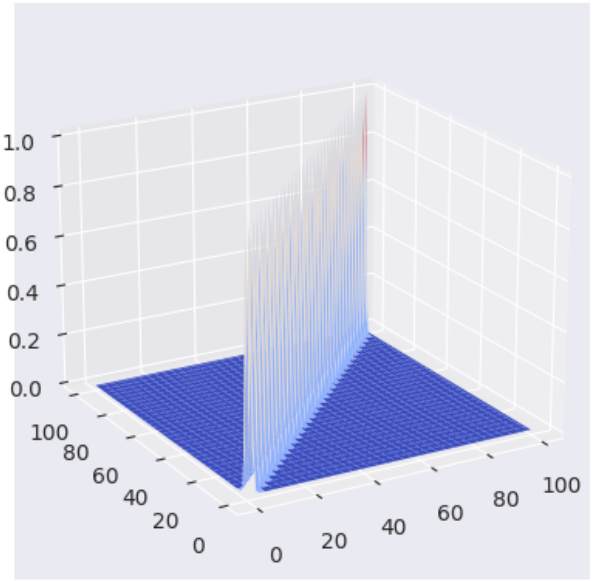
Macierze kowariancji

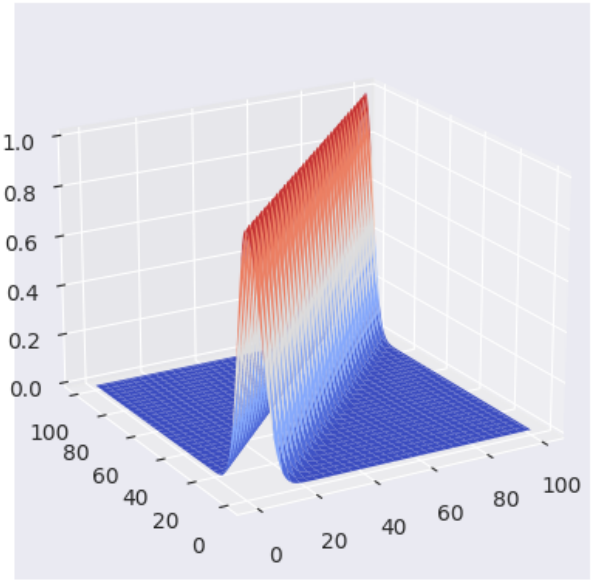
Przykłady macierzy kowariancji wygenerowane na podstawie RBF

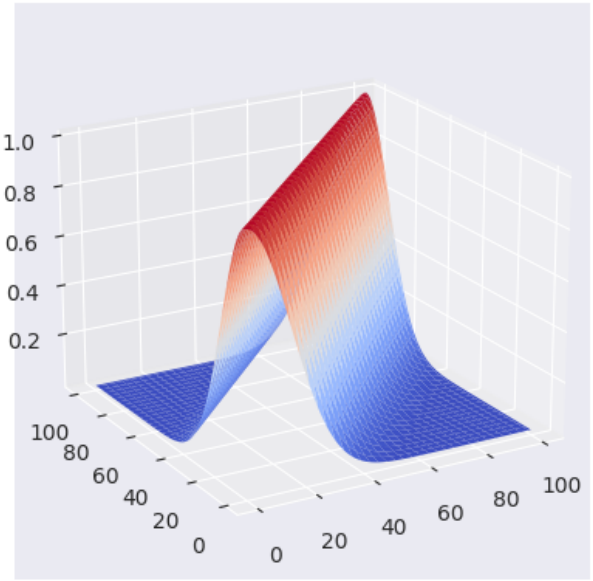


Macierze kowariancji

Przykłady macierzy kowariancji wygenerowane na podstawie RBF



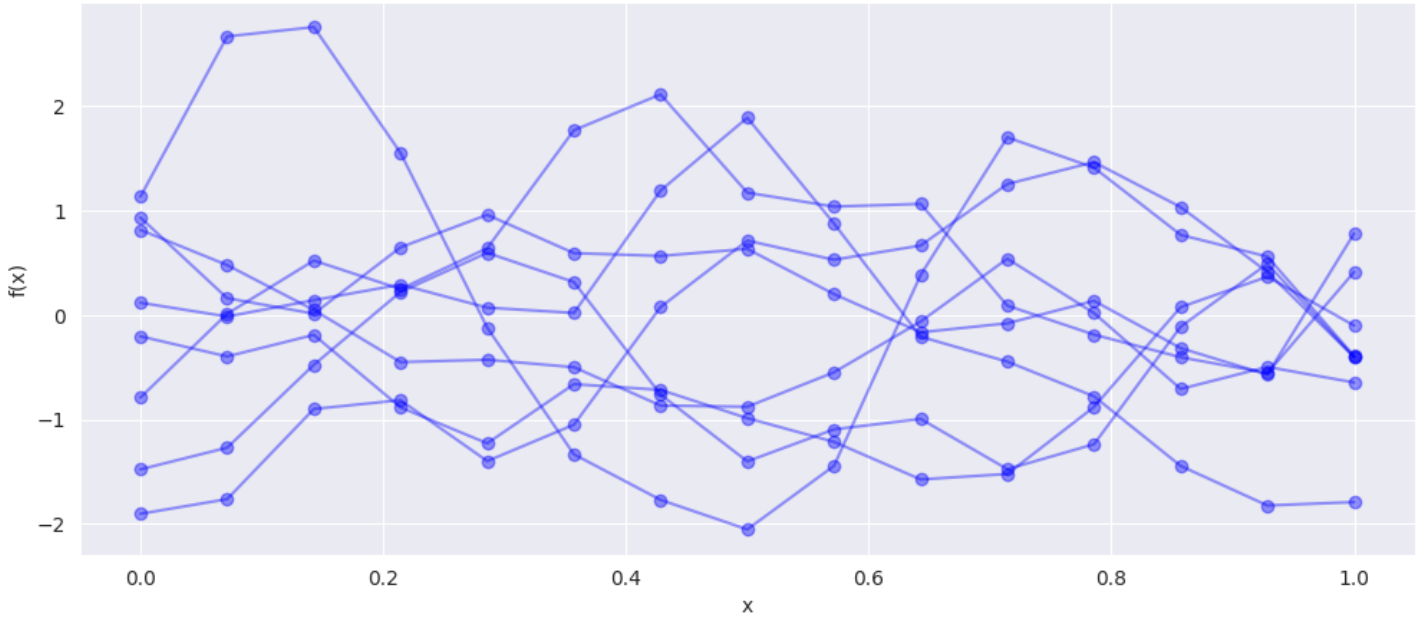




Wygładzenie

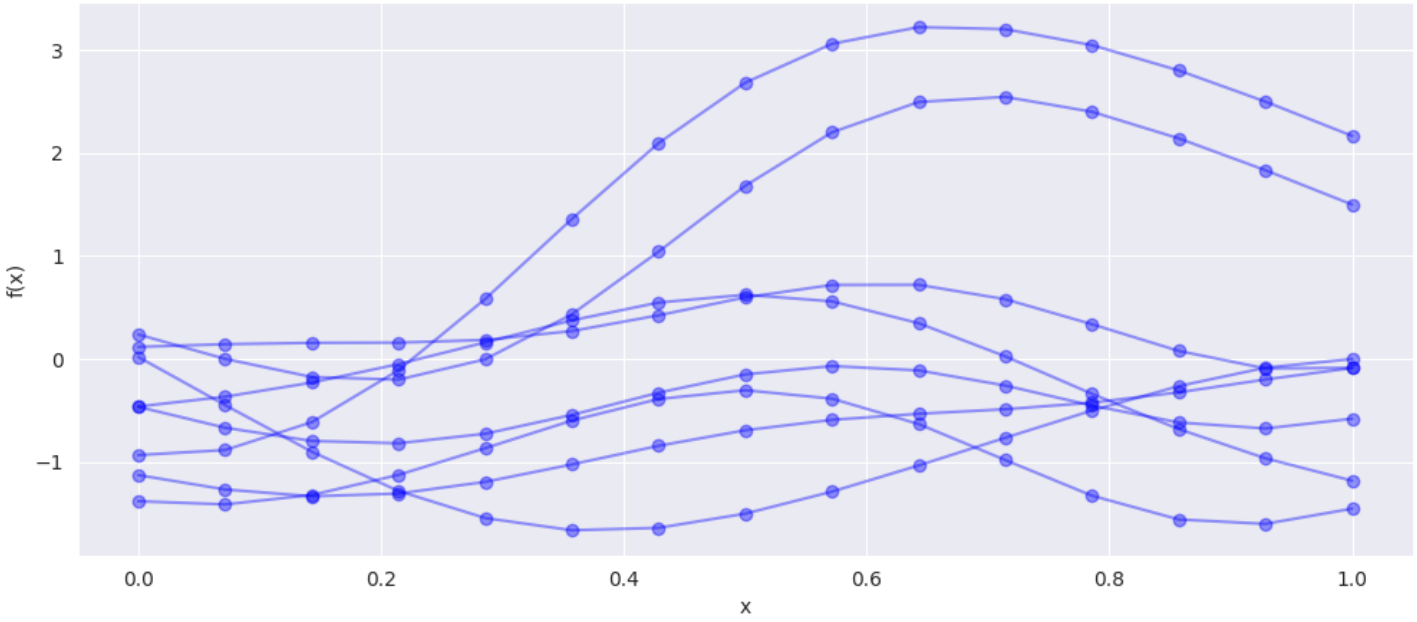
Następnym krokiem będzie wygenerowanie nowych próbek z wielowymiarowych rozkładów Gaussowskich z wykorzystaniem poznanej funkcji kernelowej RBF. Wykonamy to z uwzględnieniem zmiany parametru l w funkcji kernelowej.

Funkcje wylosowane z uwzględnieniem macierzy kowariancji generowanej na podstawie funkcji kernelowej RBF z parametrem $l = 0.1$



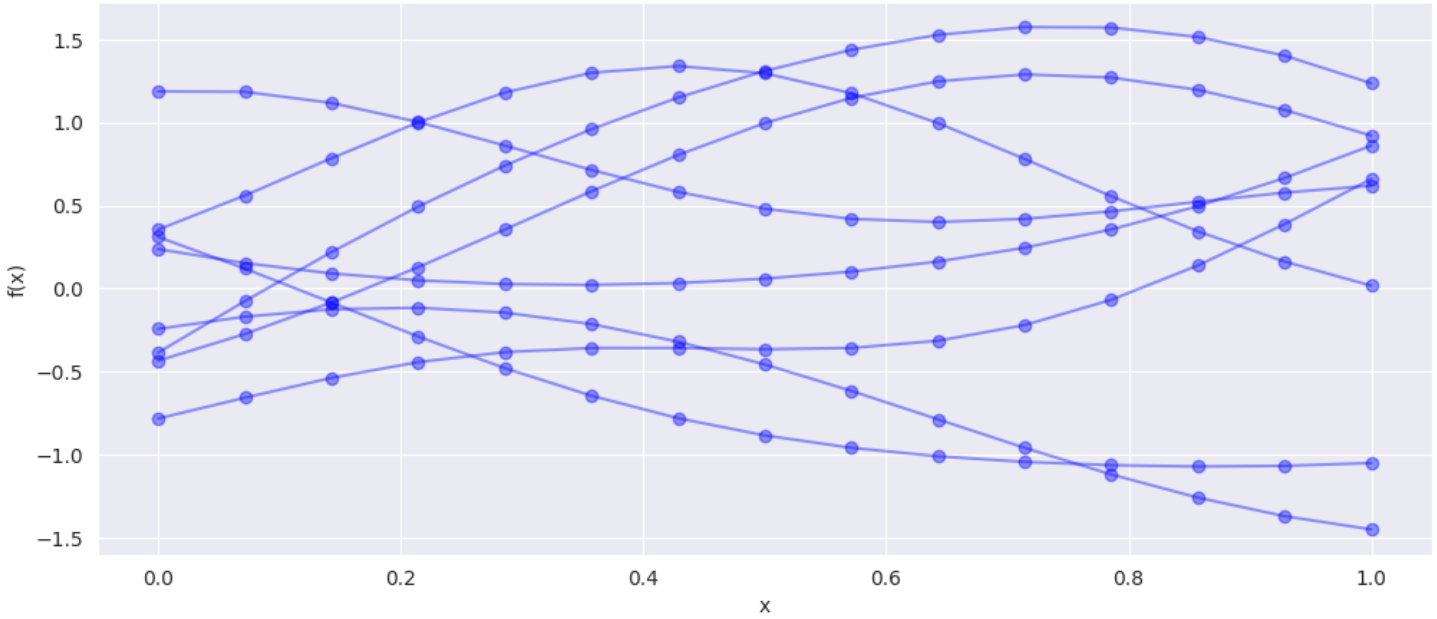
Wygładzenie

Funkcje wylosowane z uwzględnieniem macierzy kowariancji generowanej na podstawie funkcji kernelowej RBF z parametrem $l = 0.3$



Wygładzenie

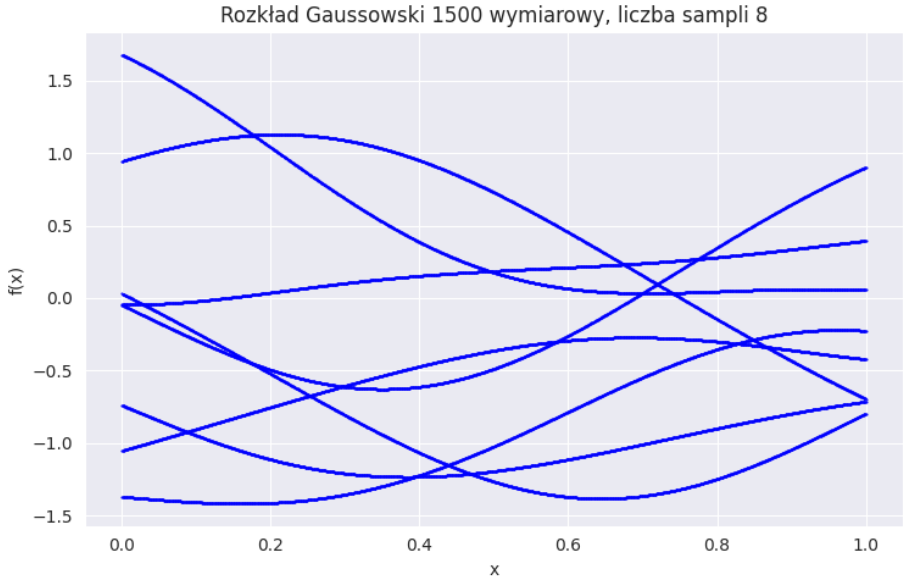
Funkcje wylosowane z uwzględnieniem macierzy kowariancji generowanej na podstawie funkcji kernelowej RBF z parametrem $l = 0.5$

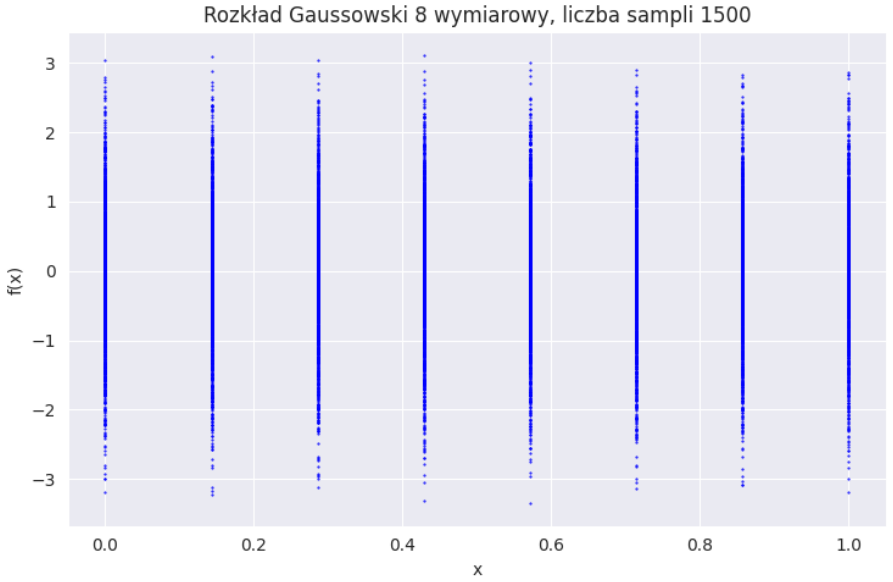


Wygładzenie

Łączenie linii poleceniem `plot` trochę zniekształca obraz "losowanych" funkcji.

Na tym etapie powinniśmy rozróżniać co oznacza, że rozkład Gaussowski jest n-wymiarowy oraz co oznacza, że „losujemy m funkcji z tego rozkładu.





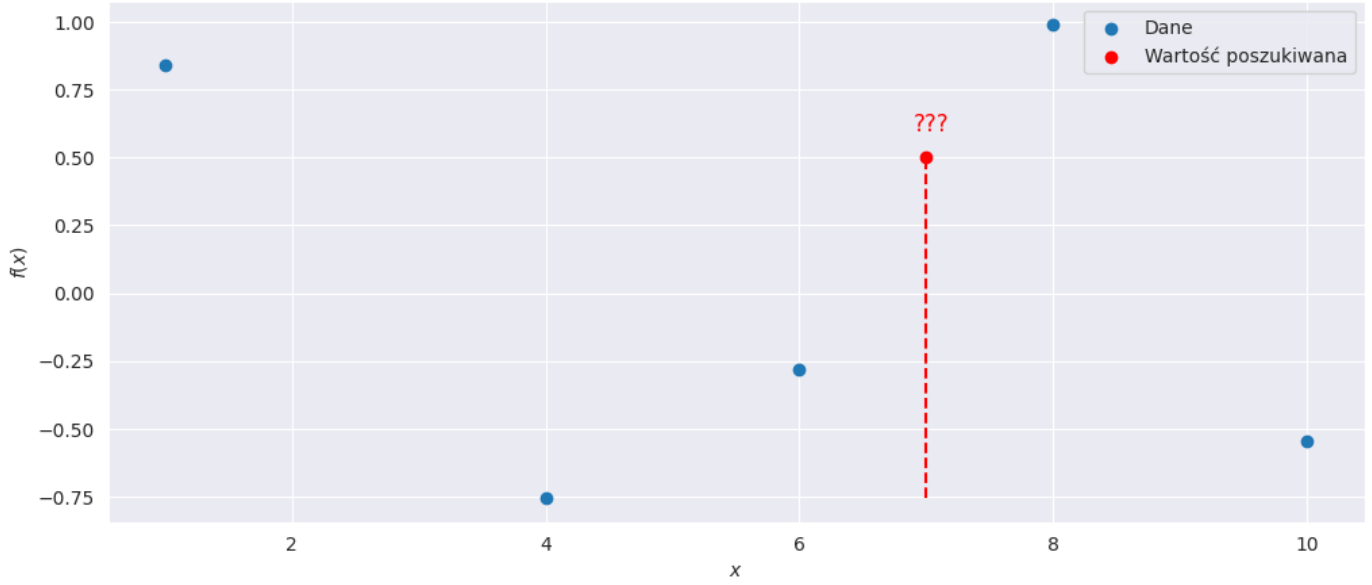
Tu już nie korzystamy z polecenia `plot`, czyli nie łączymy „sztucznie” elementów na wykresie prostymi liniami.

Dane

Wracamy do przykładu z początku wykładu. Niech wektor $\mathbf{x}_1$ oznacza zmierzone wejścia, a wektor $\mathbf{y}_1$ zmierzone wyjścia.

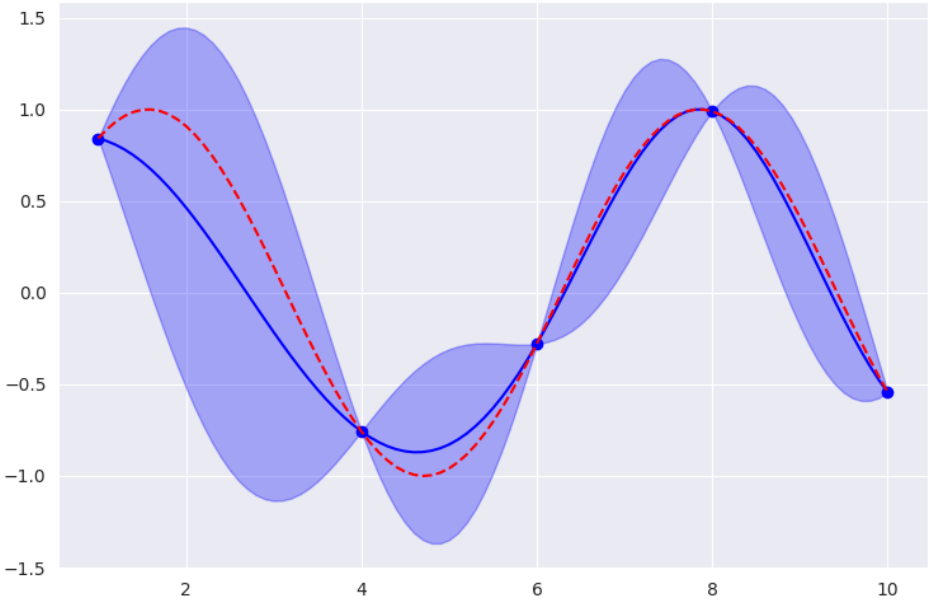
Definiujemy dziedzinę naszego problemu. Niech będzie to przedział $[1, 10]$, z którego wybierzemy 91 równo rozłożonych punktów (rozkład Gaussowski 91-wymiarowy).

Następnie zdefiniujemy hiperparametr dla funkcji kernelowej RBF ($l = 1.5$), za pomocą której będziemy realizowali dalsze obliczenia prowadzące do regresji z wykorzystaniem modelu GP.

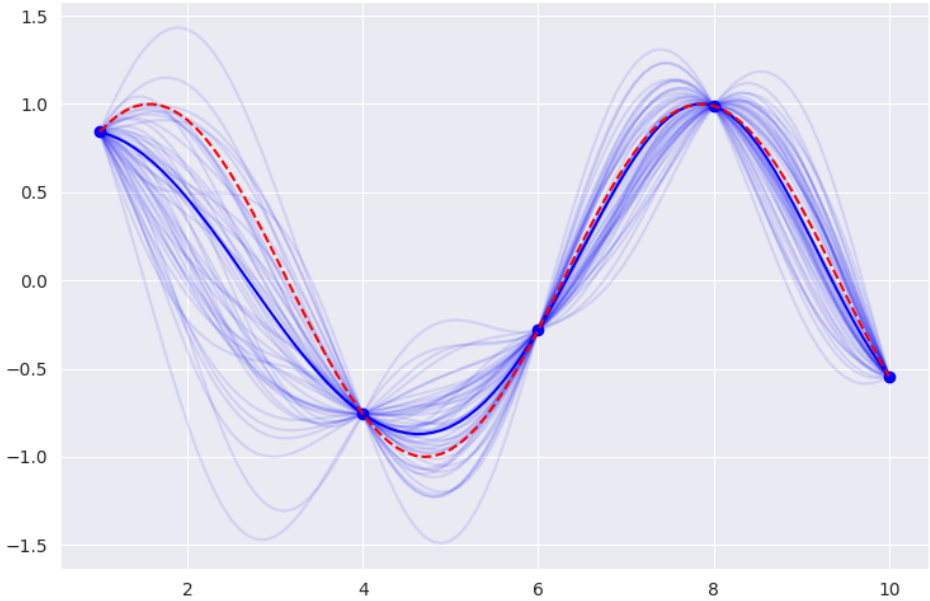


Dane

Po wykonaniu pewnych obliczeń, uwzględniających zmierzone dane otrzymamy następujący wynik:



Regresja z wykorzystaniem Procesu Gaussowskiego. Kolorem niebieskim zaznaczono „prawdziwą” funkcję, natomiast kolorem czerwonym, średnią z „wielu” sampli funkcji. Niebieskie obszary to 95% przedziały ufności



Regresja z wykorzystaniem Procesu Gaussowskiego. Niebieskie krzywe przestawiają losowych kandydatów „sample” funkcji, które wpasowały się w zestaw danych. Kolorem czerwonym zaznaczono średnią z tych „sampli” – wynik regresji.

Przedziały ufności

Przedział ufności na poziomie 95% jest definiowany jako zakres wartości, który z prawdopodobieństwem 95% będzie zawierał prawdziwą, nieznaną wartość parametru.

Zakres ten jest określony na podstawie pewnej dolnej i górnej granicy. Granice te wyznaczane są z próby danych.

Przedział ufności na poziomie 95% ma następującą właściwość: jeśli wielokrotnie pobieramy próbki z danych i dla każdej konstruujemy przedział ufności, to 95% tych przedziałów będzie zawierać rzeczywistą, nieznaną wartość parametru.

Dla regresji liniowej $Y = \beta_0 + \beta_1 X + \epsilon$, 95% przedział ufności dla parametru β_1 możemy w przybliżeniu oszacować na podstawie błędu standardowego SE jako

$$\hat{\beta}_1 \pm 2 \cdot \mathrm{SE}(\hat{\beta}_1)$$

To oznacza, że mamy w przybliżeniu 95% prawdopodobieństwo, że przedział

$$\left[\hat{\beta}_1 - 2 \cdot \mathrm{SE}(\hat{\beta}_1),\ \hat{\beta}_1 + 2 \cdot \mathrm{SE}(\hat{\beta}_1)\right]$$

będzie zawierał „prawdziwą” wartość β_1. Analogicznie przedział ufności dla parametru $\hat{\beta}_0$ w przybliżeniu wynosi $\hat{\beta}_0 \pm 2 \cdot \mathrm{SE}(\hat{\beta}_0)$

Przedziały ufności

Tak naprawdę 2, w poprzednich zależnościach wyznaczane jest na podstawie tablic statystycznych rozkładu Gaussa lub rozkładu t-studenta.

W przypadku regresji liniowej, stopnie swobody są obliczane jako liczba obserwacji minus liczba estymowanych parametrów.

Przykładowe tabele statystyczne:

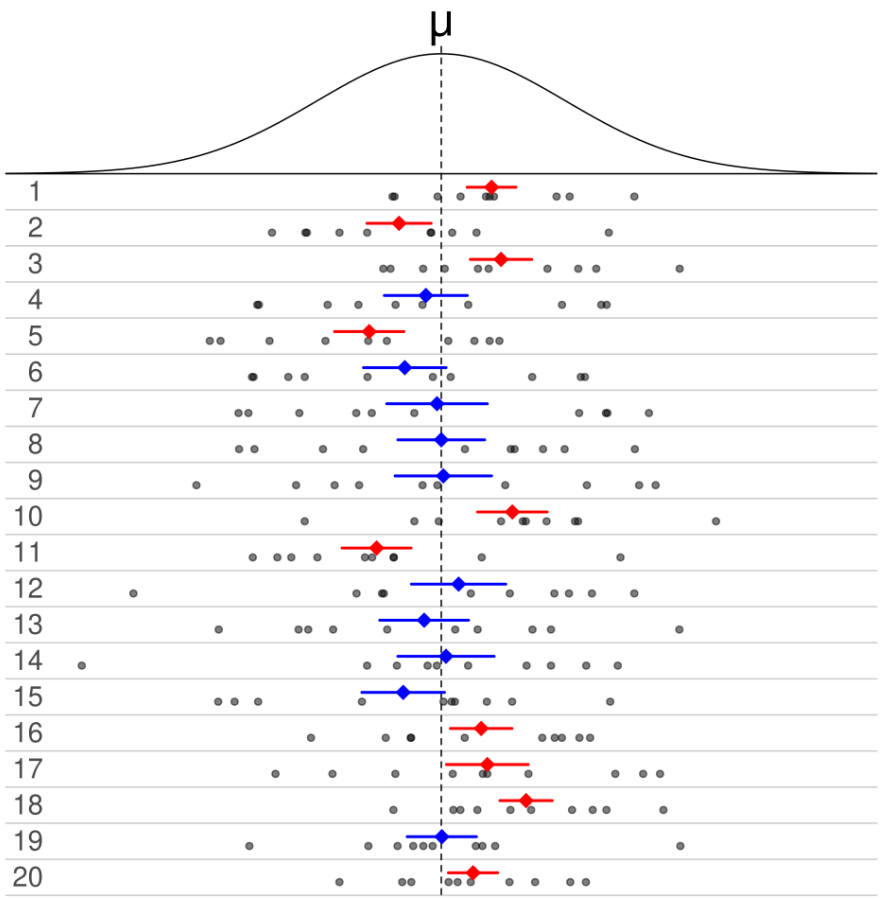
https://www.medcalc.org/manual/t-distribution-table.php

https://www.sjsu.edu/faculty/gerstman/StatPrimer/t-table.pdf

Przedziały ufności

Interpretacja raz jeszcze, przykład 50% przedziału ufności.

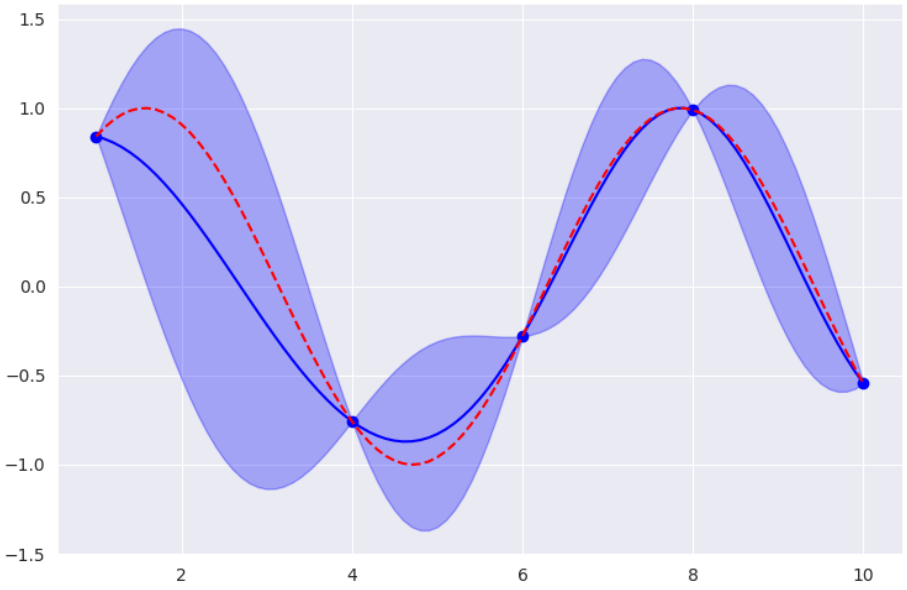
Każdy wiersz punktów stanowi próbkę danych z tego samego rozkładu normalnego. Kolorowe linie to 50% przedziały ufności dla średniej populacji - μ. W centrum każdego przedziału znajduje się średnia z próby - $\bar{\mu}$, oznaczona diamentem. Niebieskie przedziały zawierają μ, a czerwone nie. W tym przypadku 50% wszystkich przedziałów (niebieskich) obejmuje średnią populacji.

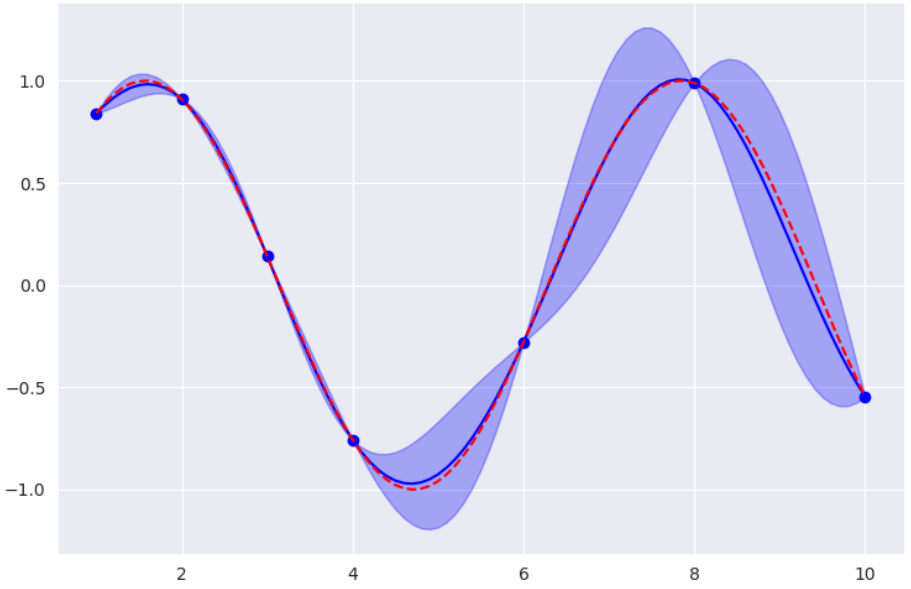


By FRuDIxAFLG - Own work, CC BY-SA 4.0,
https://commons.wikimedia.org/w/index.php?curid=114452600

Dane

Co się stanie, jeżeli dane zostaną uzupełnione o nowe próbki…



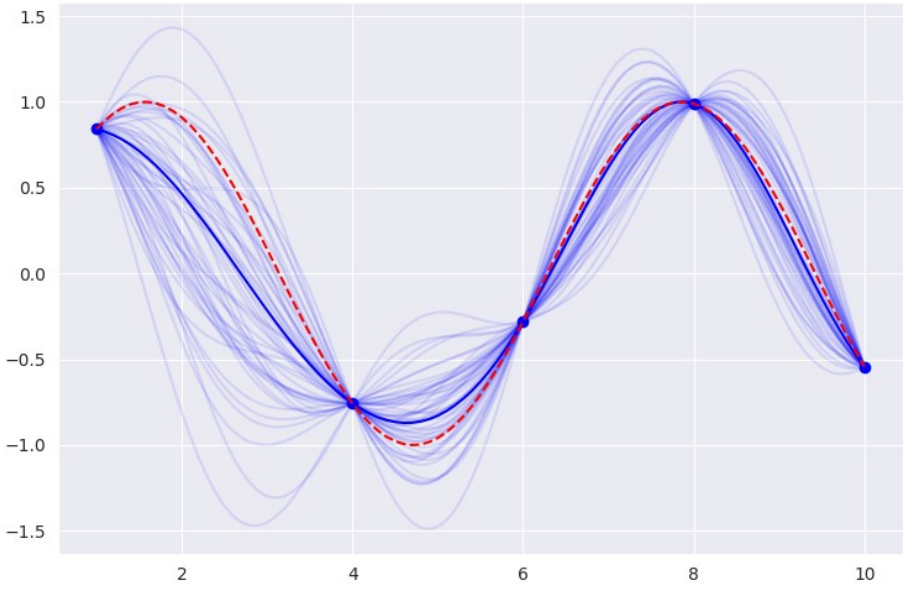


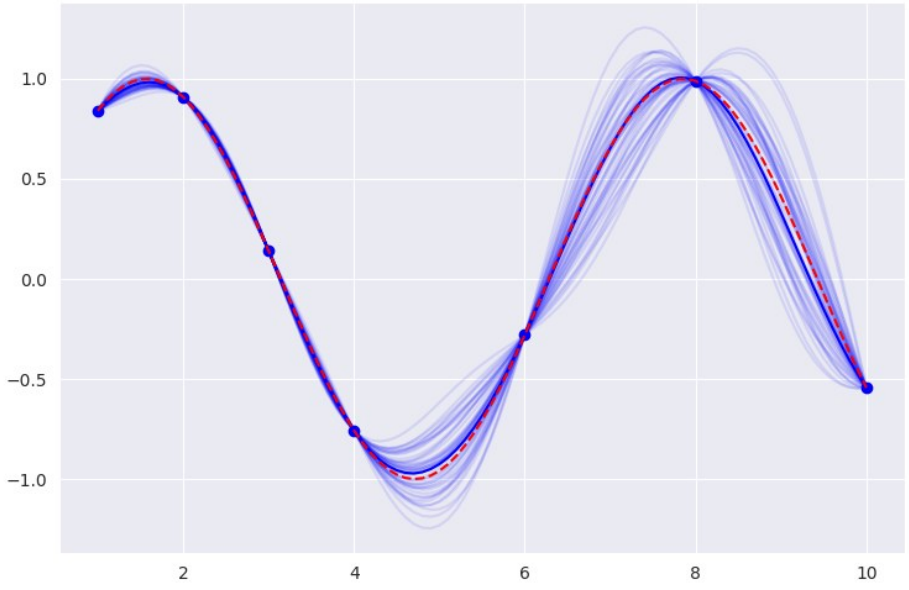


Uzyskaliśmy nowe próbki danych

Dane

Co się stanie, jeżeli dane zostaną uzupełnione o nowe próbki…



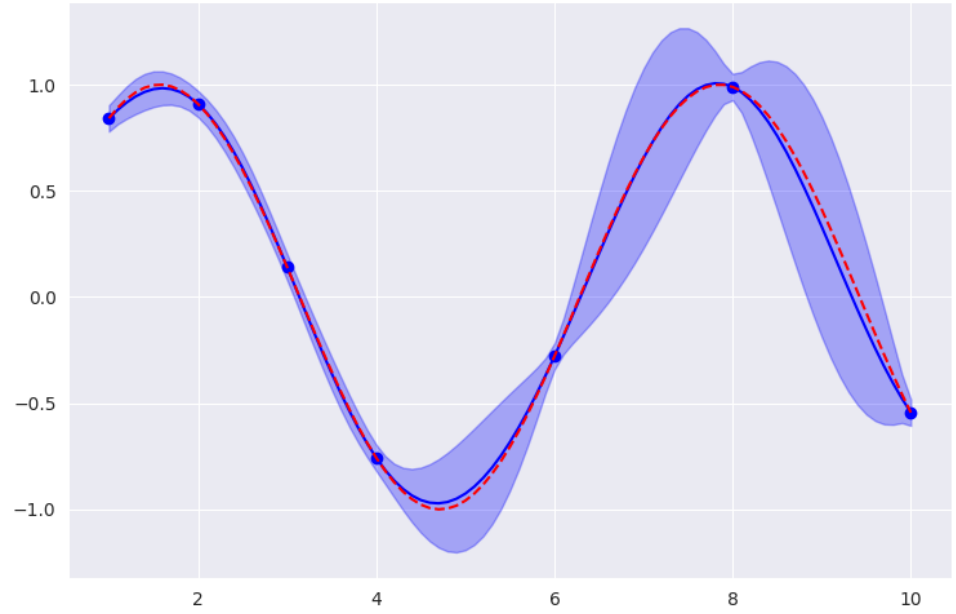


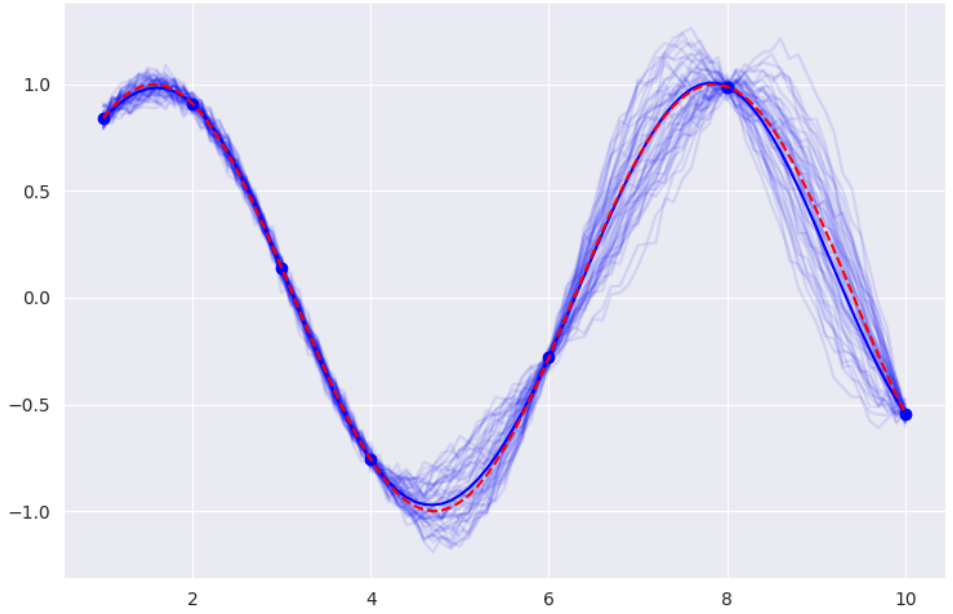


Uzyskaliśmy nowe próbki danych

Dane

Szum w danych





Jak to jest liczone

1. Wektor danych
$$\mathbf{X} = [x_1, x_2, \dots, x_N]^T$$

2. Wektor wartości funkcji
$$f(\mathbf{X}) = [f_1(x_1), f_2(x_2), \dots, f(x_N)]^T$$

3. Wektor „dziedziny” $\mathbf{x}_\star$ wygenerowany dla pewnego przedziału $[\mathbf{x}_{\star L}, \mathbf{x}_{\star U}]$. Dla elementów wektora $\mathbf{x}_\star$ będziemy prognozowali wartości $f(\mathbf{x}_\star)$

4. Definicja funkcji jądra (kernel) $K(\cdot,\cdot)$

5. Wyznaczenie macierzy $K(\mathbf{x}_\star, \mathbf{x}_\star)$ za pomocą funkcji kernelowej (punkt 4) dla wektora zdefiniowanej wcześniej dziedziny (macierz kwadratowa)
$$K(\mathbf{x}_\star, \mathbf{x}_\star) = \kappa(x_\star, x_\star)$$
6. Wyznaczenie macierzy $K(\mathbf{X}, \mathbf{x}_\star)$
$$K(\mathbf{X}, \mathbf{x}_\star) = \begin{bmatrix} \kappa(x_1, x_\star) \\ \vdots \\ \kappa(x_N, x_\star) \end{bmatrix} = K(\mathbf{x}_\star, \mathbf{X})^{\boldsymbol{T}}$$

Jak to jest liczone

7. Wyznaczamy macierz $K(\mathbf{X}, \mathbf{X})$

$$K(\mathbf{X}, \mathbf{X}) = \begin{bmatrix} \kappa(x_1, x_1) & \cdots & \kappa(x_1, x_N) \\ \vdots & \ddots & \vdots \\ \kappa(x_N, x_1) & \cdots & \kappa(x_N, x_N) \end{bmatrix}$$

8. Łączymy wszystko otrzymując

$$\begin{bmatrix} f(\mathbf{X}) \\ f(\mathbf{x}_\star) \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \mathbf{0} \\ \mathbf{0} \end{bmatrix}, \begin{bmatrix} K(\mathbf{X}, \mathbf{X}) & K(\mathbf{x}_\star, \mathbf{X}) \\ K(\mathbf{X}, \mathbf{x}_\star) & K(\mathbf{x}_\star, \mathbf{x}_\star) \end{bmatrix} \right)$$

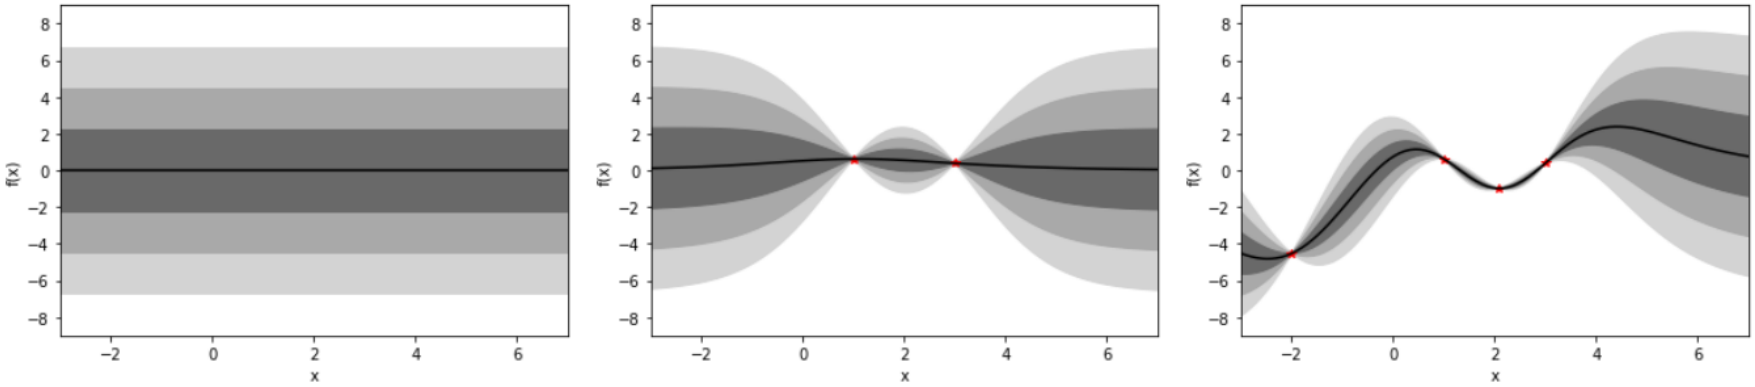
przy czym

$$f(\mathbf{x}_\star)|f(\mathbf{X}) \sim \mathcal{N}\left(K(\mathbf{x}_\star, \mathbf{X}) K(\mathbf{X}, \mathbf{X})^{-1} f(\mathbf{X}), K(\mathbf{x}_\star, \mathbf{x}_\star) - K(\mathbf{x}_\star, \mathbf{X}) K(\mathbf{X}, \mathbf{X})^{-1} K(\mathbf{X}, \mathbf{x}_\star) \right)$$

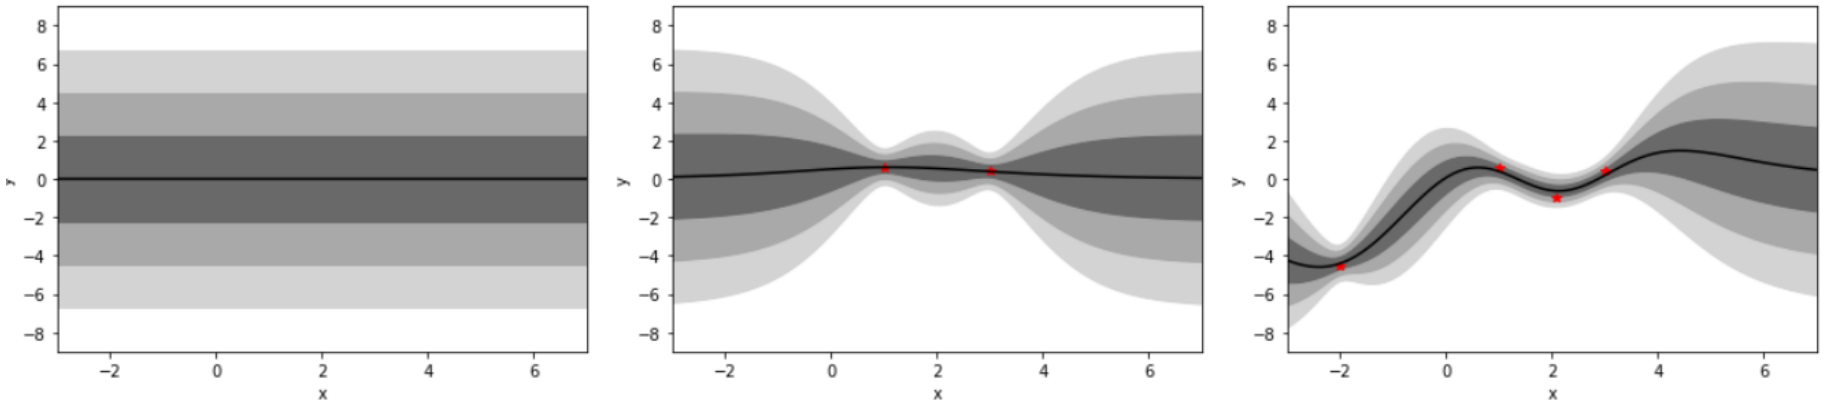


Pionowy znak | oznacza „Zdarzenie $f(\mathbf{x}_\star)$ pod warunkiem, że zaszło zdarzenie $f(\mathbf{X})$”

$$f(x_\star) \mid f(\mathbf{X}) \sim \mathcal{N}\left(\mathbf{K}(x_\star, \mathbf{X})K(\mathbf{X}, \mathbf{X})^{-1} f(\mathbf{X}), K(x_\star, x_\star) - K(\mathbf{X}, x_\star)K(\mathbf{X}, \mathbf{X})^{-1} K(\mathbf{X}, x_\star)\right)$$



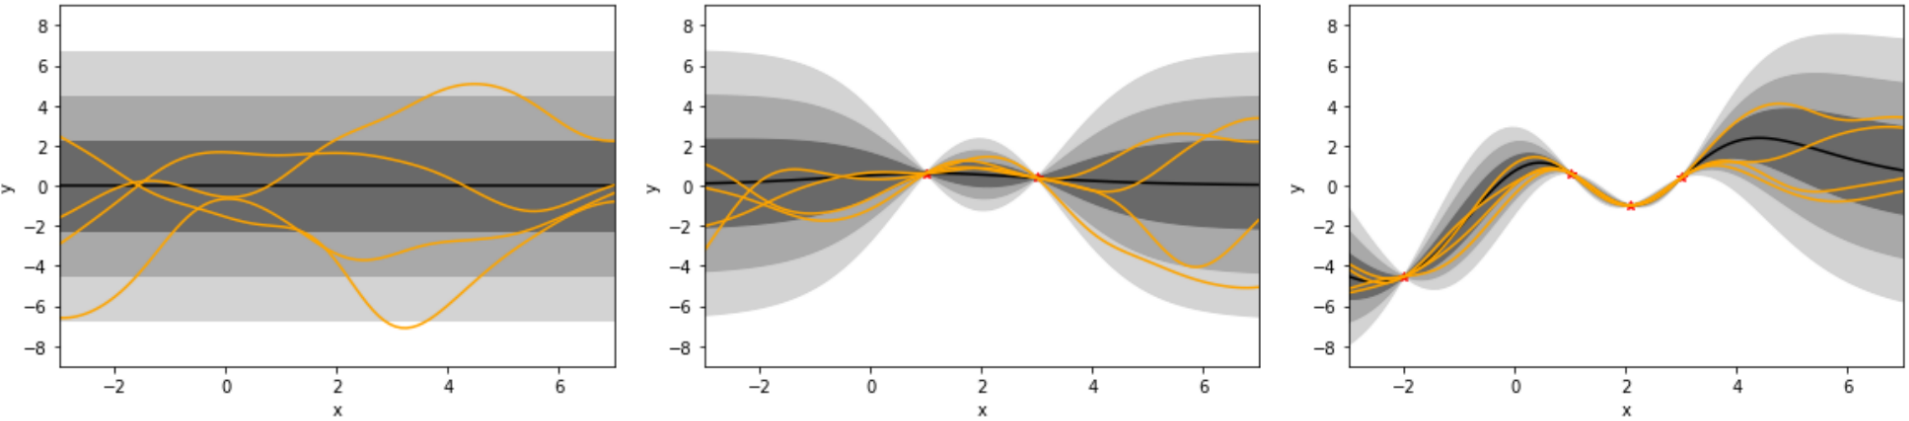
$$f(x_\star) \,|\, \mathbf{y} \sim \mathcal{N}\left(\mathbf{K}(x_\star, \mathbf{X})(K(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1}\mathbf{y}, K(x_\star, x_\star) - K(x_\star, \mathbf{X})(K(\mathbf{X}, \mathbf{X}) + \sigma_n^2 \mathbf{I})^{-1} K(\mathbf{X}, x_\star)\right)$$



Jak to jest liczone

$$f(x_\star)\,|\,\mathbf{y} \sim \mathcal{N}\left(\mathbf{K}(x_\star,\mathbf{X})(K(\mathbf{X},\mathbf{X})+\sigma_n^2\mathbf{I})^{-1}\mathbf{y}, K(x_\star,x_\star) - K(x_\star,\mathbf{X})(K(\mathbf{X},\mathbf{X})+\sigma_n^2\mathbf{I})^{-1}K(\mathbf{X},x_\star)\right)$$

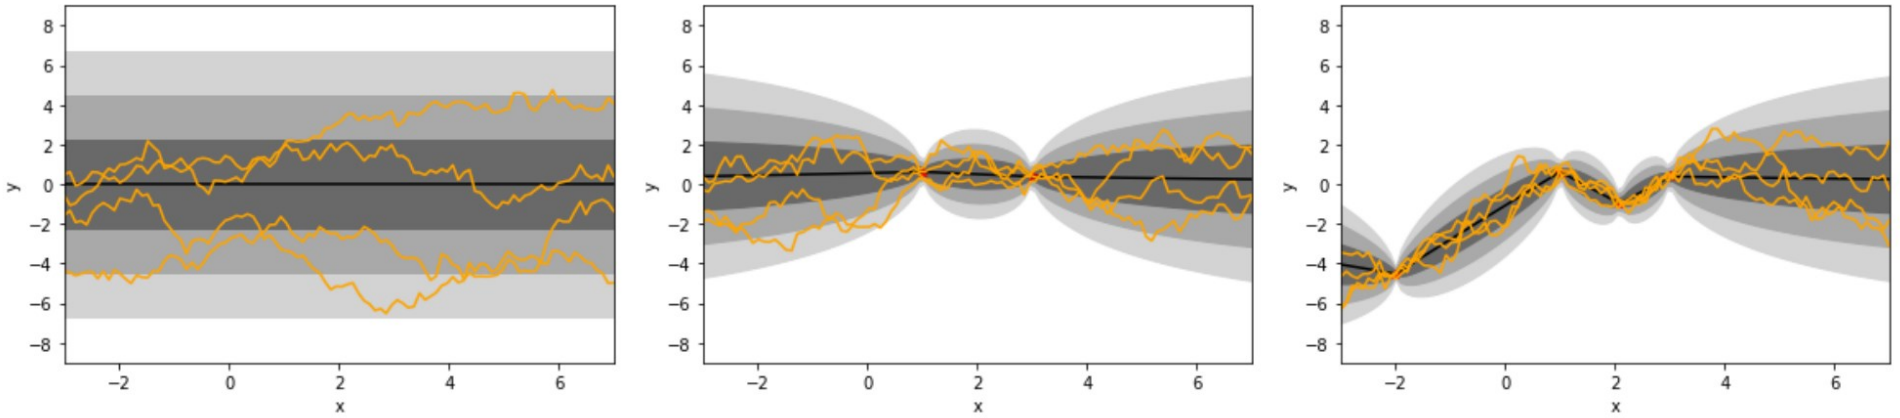
$$\kappa(x,x') = \sigma^2\left(1+\frac{|x-x'|^2}{2\alpha\ell}\right)^{-\alpha}, \quad \sigma^2 = 5, \alpha = 2, \ell = 3$$



Jak to jest liczone

$$f(x_\star)\,|\,\mathbf{y} \sim \mathcal{N}\left(\mathbf{K}(x_\star,\mathbf{X})(K(\mathbf{X},\mathbf{X})+\sigma_n^2\mathbf{I})^{-1}\mathbf{y}, K(x_\star,x_\star) - K(x_\star,\mathbf{X})(K(\mathbf{X},\mathbf{X})+\sigma_n^2\mathbf{I})^{-1}K(\mathbf{X},x_\star)\right)$$

$$\kappa(x,x') = \sigma^2 \exp\left(1 + \frac{|x-x'|}{\ell^2}\right), \quad \sigma^2 = 5, \ell = 3$$



Dziękuję
– koniec materiału prezentowanego podczas wykładu

POLITECHNIKA GDAŃSKA

HISTORIA MĄDROŚCIĄ
PRZYSZŁOŚĆ WYZWANIEM