POLITECHNIKA GDAŃSKA

Modelowanie i podstawy identyfikacji

Materiał wykładowy: 8-9 – Metoda najmniejszych kwadratów – identyfikacja wsadowa (jednorazowa); wybrane algorytmy

Wydział Elektrotechniki i Automatyki
Katedra Inteligentnych Systemów Sterowania i Wspomagania Decyzji
dr hab. inż. Kazimierz Duzinkiewicz
dr inż. Bartosz Puchalski

Zadanie estymacji parametrów modelu

Typowa forma zadania estymacji parametrów

- Dany jest system dynamiczny, dla którego proponowany jest model matematyczny oparty na doświadczeniu proponującego i który:
  - zgodny jest ze wszystkimi znanymi prawami rządzącymi zachowaniem się systemu,
  - pozwala wykorzystać dostępne w systemie pomiary dla porównania zachowania się modelu i systemu
  - jego struktura spełnia wymagania pozwalające uzyskać pożądaną dokładność

  ale zawiera szereg niezbyt dobrze znanych parametrów
- Należy określić „najlepsze” estymaty wszystkich nieznanych dobrze parametrów tak, aby model matematyczny zapewniał „optymalną estymatę” zachowania systemu

Zadanie estymacji parametrów modelu

Każda metoda rozwiązująca zadanie o podanej strukturze – realizacja **procesu estymacji**

Zadania estymacji: bardzo łatwe $\rightarrow$ ..... nierozwiązywalne

Podstawa wielu procesów estymacji – metoda najmniejszych kwadratów

Wartości zmiennych/wielkości systemu

W procesie estymacji z każdą włączoną w ten proces zmienną/wielkością związane są **trzy wartości**:

x - wartość prawdziwa (rzeczywista) zmiennej

$\tilde{x}$ - wartość mierzona zmiennej

$\hat{x}$ - wartość estymowana zmiennej

Co można powiedzieć o tych wartościach?

x - wartość praktycznie nieznana

$\tilde{x}$ - wartość uzyskiwana z czujnika lub z innego pomiaru, nigdy nierówna wartości prawdziwej, obarczona błędem pomiaru

$\hat{x}$ - wartość zmiennej uzyskiwana jako wynik procesu estymacji

W zadaniu estymacji zmienne x – parametry modelu

Błędy związane ze zmiennymi/wielkościami systemu

Dwa błędy:

1. Błąd pomiaru (measurement error)

błąd pomiaru

$$\tilde{x} = x + \tilde{e} \qquad \tilde{e} = \tilde{x} - x$$

wartość mierzona — wartość prawdziwa

2. Błąd resztkowy (residual error)

błąd resztkowy – (residuum)

$$\tilde{x} = \hat{x} + \hat{e} \qquad \hat{e} = \tilde{x} - \hat{x}$$

wartość mierzona — wartość estymowana

Co można powiedzieć o tych błędach:

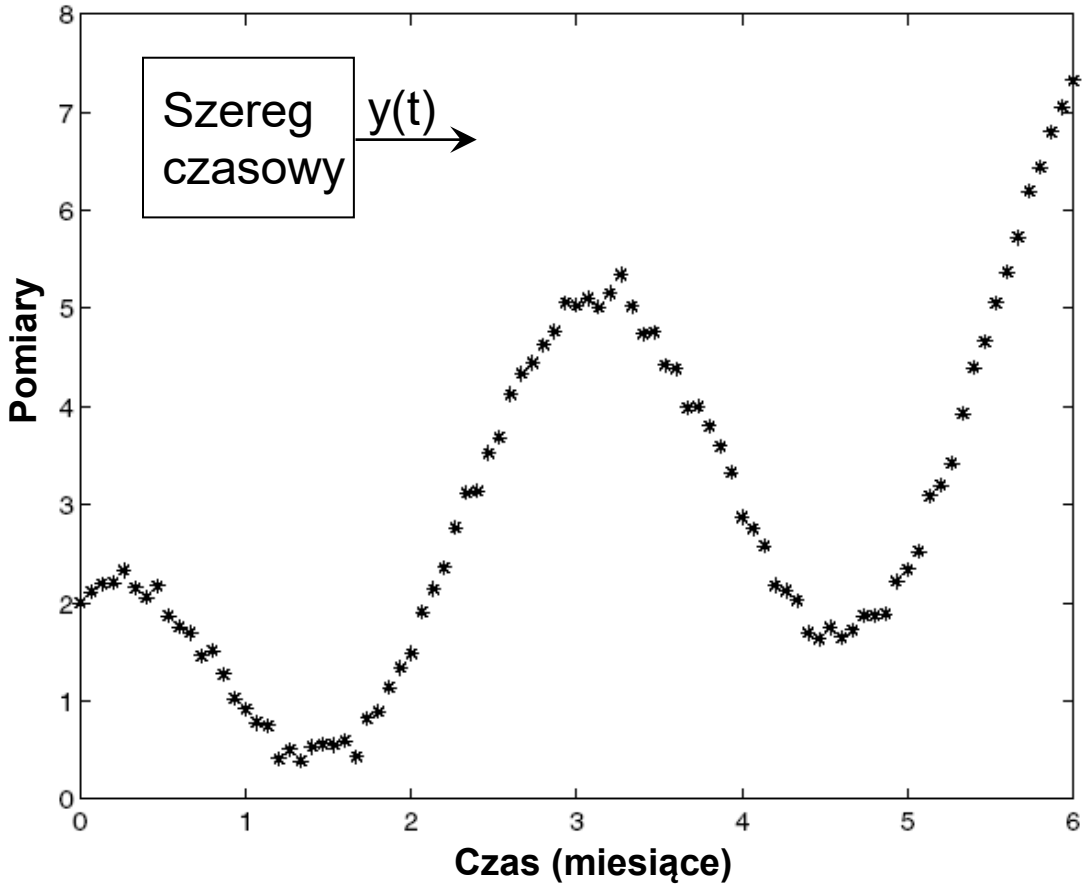
$\tilde{e}$ - wartość praktycznie nigdy nieznana; mechanizm generujący ten błąd zwykle jest aproksymowany przez pewien znany proces (np. szum gaussowski o zerowej wartości średniej i znanej wariancji σ^2;

$\hat{e}$ - wartość znana w momencie wyznaczenia wartości estymowanej

Przykład 1 (aproksymacja szeregu czasowego):

Rysunek – wyniki pomiaru pewnego procesu w czasie

System bez zewnętrznego wejścia – szereg czasowy



Możliwa interpretacja – historia notowań na giełdzie pewnej firmy w okresie 6 miesięcy

Zadanie – zbudować model y(t) do predykcji perspektyw firmy

Dane:

Pomiary $y(t)$ (np. notowań zamknięcia giełdy), oznaczone $\tilde{y}(t)$

dane dla przedziału 6 miesięcy

Wymagania:

Wartość bezwzględna błędów resztkowych (residuów) |μ| nie większa niż 0.0075:

Odchylenie standardowe błędów resztkowych (residuów) σ nie większa od 0.125

Średnia z próby:

$$\mu = \frac{1}{m}\sum_{i=1}^{m}\left[\tilde{y}(t_i) - \hat{y}(t_i)\right]$$

m – liczba próbek, liczba pomiarów

Wariancja z próby:

$$\sigma^2 = \frac{1}{m-1}\sum_{i=1}^{m}\left\{\left[\tilde{y}(t_i) - \hat{y}(t_i)\right] - \mu\right\}^2$$

Proponowane modele:

$$Model\ 1: \quad y_1(t) = c_1 t + c_2\, sin(t) + c_3\, cos(2t)$$

$$Model\ 2: \quad y_2(t) = d_1(t+2) + d_2 t^2 + d_3 t^3$$

t - czas [miesiące – m]

c_1, c_2, c_3 - stałe współczynniki – parametry Modelu 1

d_1, d_2, d_3 - stałe współczynniki – parametry Modelu 2

Ocena:

Jak dobrze każdy z proponowanych modeli z „optymalnymi” wartościami współczynników c_i oraz d_i dokonuje predykcji pomiarów?

W statystyce: proces „wpasowywania” krzywej takiej jak np. Model 1 lub Model 2 w posiadane pomiary - **regresja**

Załóżmy, że znamy **metodę najmniejszych kwadratów** i zastosowaliśmy algorytm tej metody do wyznaczenia „optymalnych" wartości współczynników c_i Modelu 1 oraz d_i Modelu 2

„Optymalne" wartości współczynników c_i Modelu 1

$$\left(\hat{c}_1, \hat{c}_2, \hat{c}_3\right)^T = \left(0.9967, 0.9556, 2.0030\right)^T$$

„Optymalne" wartości współczynników d_i Modelu 2

$$\left(\hat{d}_1, \hat{d}_2, \hat{d}_3\right)^T = \left(0.6721, -0.1303, 2.0210\right)^T$$

Modele z „optymalnymi" wartościami współczynników

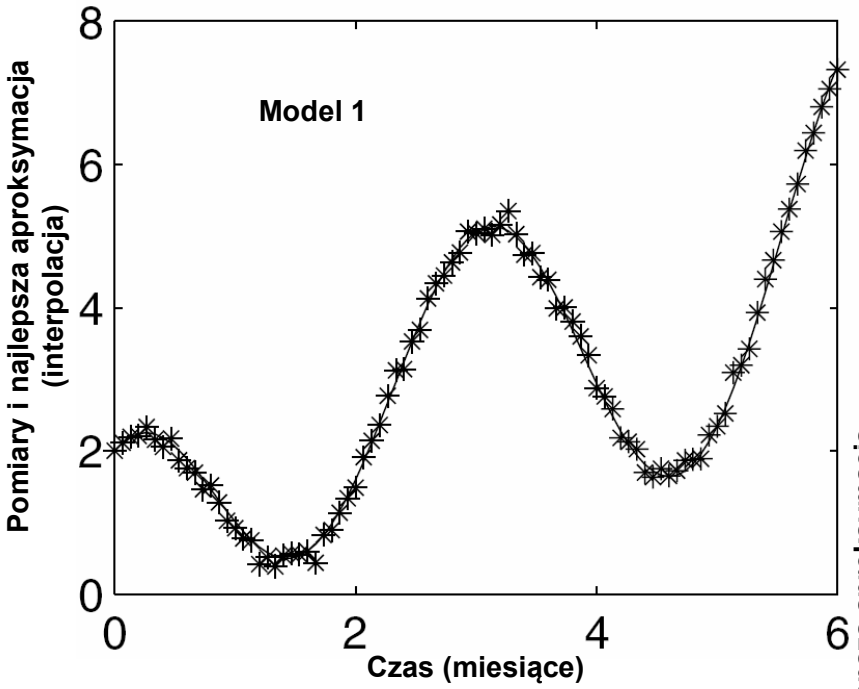
$$Model\ 1: \quad \hat{y}_1(t) = 0.9967t + 0.9556\ sin(t) + 2.0030\ cos(2t)$$

$$Model\ 2: \quad \hat{y}_2(t) = 0.6721(t+2) - 0.1303t^2 + 2.0210t^3$$

Porównanie modeli:

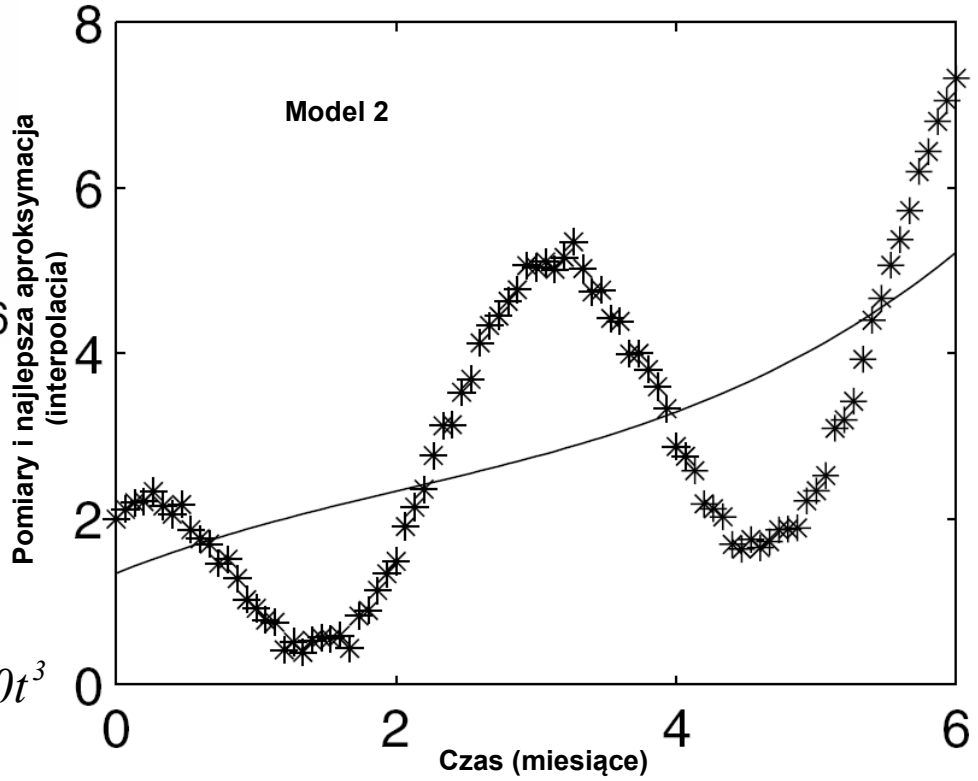
Model 1 :

$$\hat{y}_1(t) = 0.9967t + 0.9556\,sin(t) + 2.0030\,cos(2t)$$

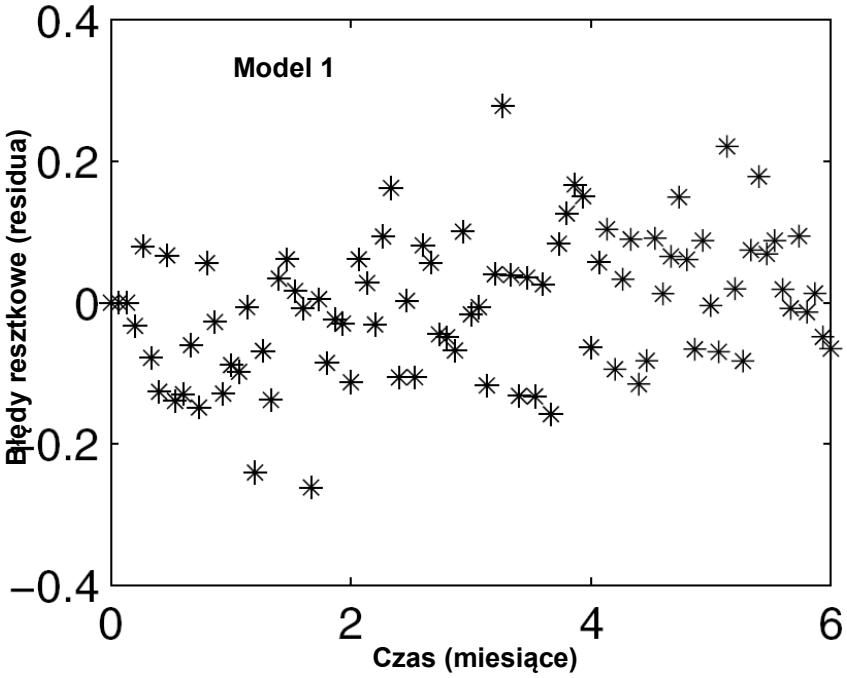


Model 2 :

$$\hat{y}_2(t) = 0.6721(t+2) - 0.1303t^2 + 2.0210t^3$$

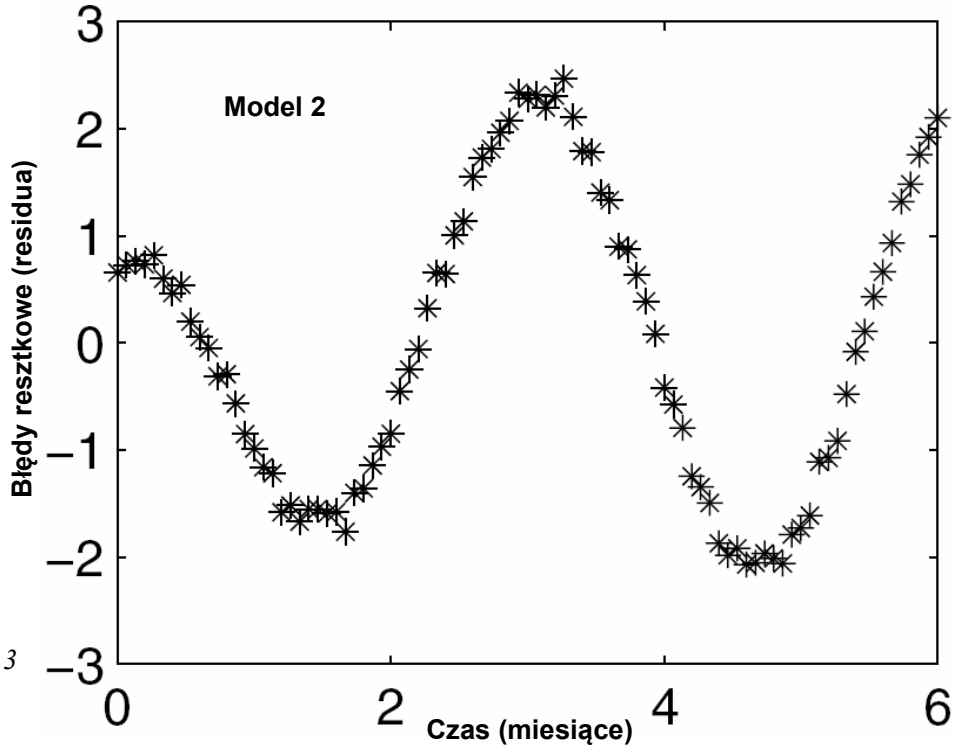


Porównanie modeli:



Model 1 :

$$\hat{y}_1(t) = 0.9967t + 0.9556\,sin(t) + 2.0030\,cos(2t)$$



Model 2 :

$$\hat{y}_2(t) = 0.6721(t+2) - 0.1303t^2 + 2.0210t^3$$

Porównanie modeli:

Średnia z próby błędów resztkowych (residuów):

$$Model\ 1: \mu_1 = 1 \cdot 10^{-5}$$

$$Model\ 2: \mu_2 = 1 \cdot 10^{-5}$$

Odchylenie standardowe z próby błędów resztkowych (residuów):

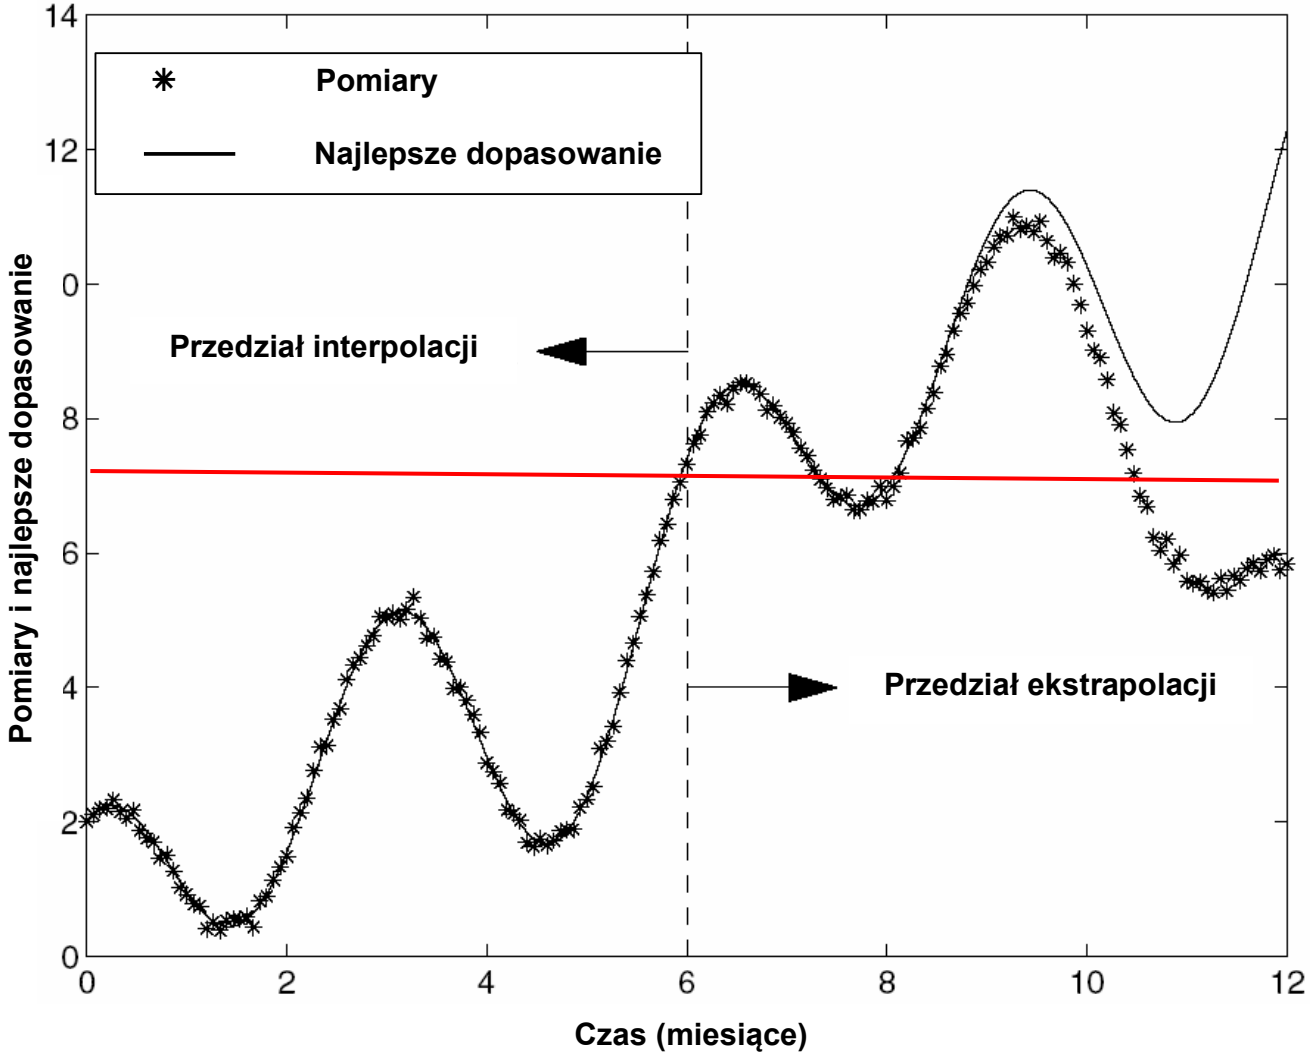
$$Model\ 1: \sigma_1 = 0.0921$$

$$Model\ 2: \sigma_2 = 1.3685$$

Konkluzja:

Nie mając podstaw przypuszczać istnienia systematycznych błędów w pomiarach stwierdzamy, że Model 1 może być używany do dokładnej oceny zachowania y(t)

Jaka będzie jakość predykcji y(t) poza przedziałem 0-6m?:



„Kuchnia” naszego zadania:

Pomiary generowane zgodnie z równaniem

$$\tilde{y}_1(t) = 1 \cdot t + 1 \cdot sin(t) + 2 \cdot cos(2t) - 4 \cdot 10^{-5} \cdot e^t + \tilde{e}_1$$

Symulacja błędu pomiaru: generator szumu gaussowskiego o zerowej wartości średniej i odchyleniu standardowym σ = 0.1

Propozycja strukturalnie poprawnego modelu:

$$Model\ 3: \quad y_3(t) = x_1 t + x_2\, sin(t) + x_3\, cos(2t) + x_4 e^t$$

„Optymalne” wartości współczynników x_i Modelu 3

$$\left(\hat{x}_1, \hat{x}_2, \hat{x}_3, \hat{x}_4\right)^T = \left(0.9958, 0.9979, 2.0117, -4.232 \cdot 10^{-5}\right)^T$$

Model strukturalnie poprawny – różnice wartości prawdziwych i wartości estymowanych parametrów

Prawdziwe wartości współczynników x_i Modelu 3

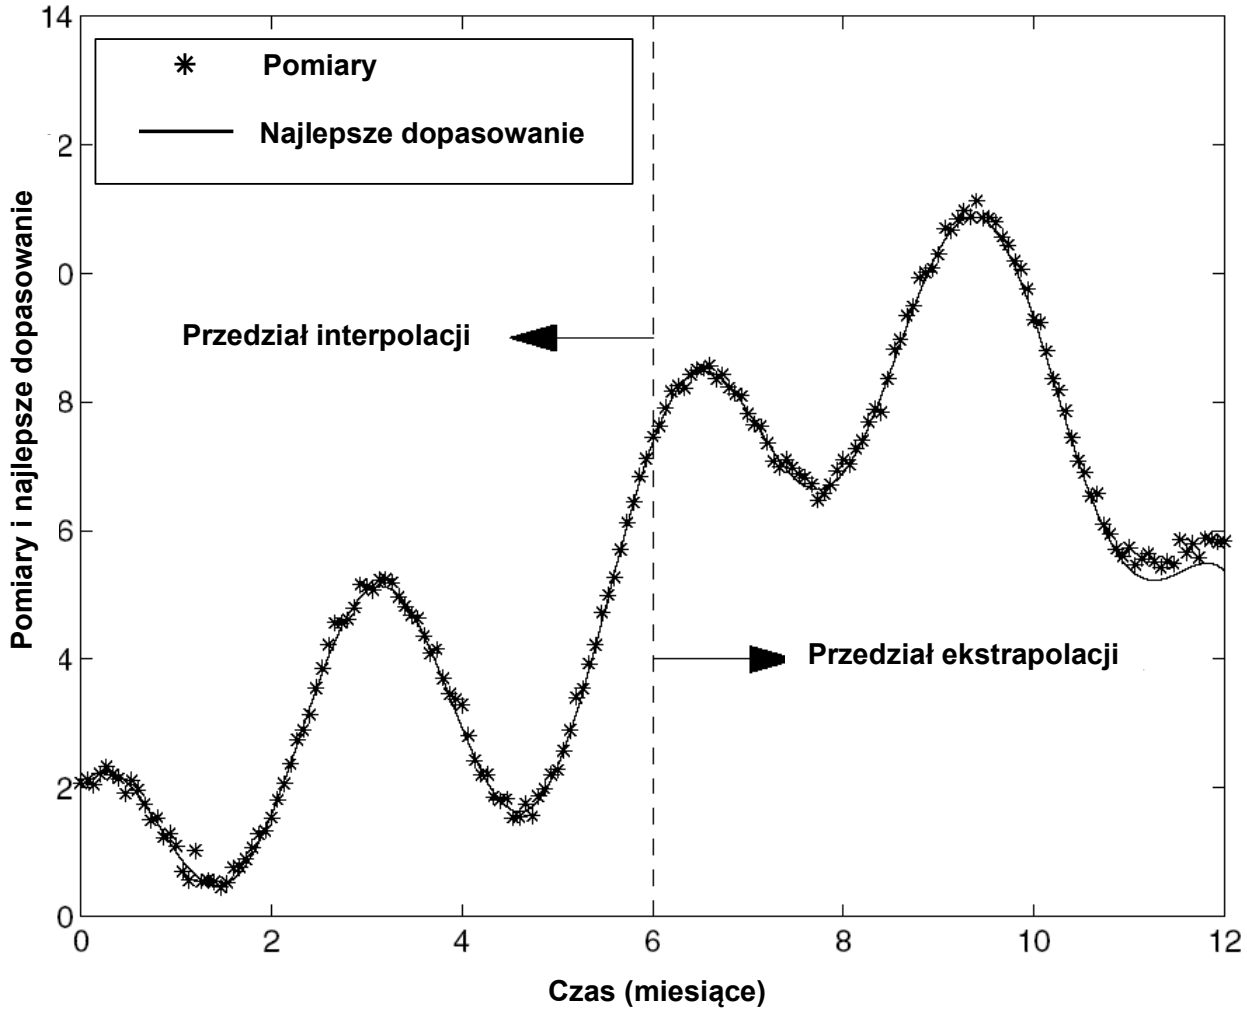
$$\left(x_1, x_2, x_3, x_4\right)^T = \left(1.0, 1.0, 2.0, -4.0 \cdot 10^{-5}\right)^T$$

Estymowane „optymalnie” wartości współczynników x_i Modelu 3 (dane z okresu 0-6m)

$$\left(\hat{x}_1, \hat{x}_2, \hat{x}_3, \hat{x}_4\right)^T = \left(0.9958, 0.9979, 2.0117, -4.232 \cdot 10^{-5}\right)^T$$

Jedyna przyczyna – błędy pomiarów

Jaka będzie jakość predykcji y(t) z wykorzystaniem strukturalnie poprawnego modelu z wartościami parametrów estymowanymi w oparciu o dane z okresu 0-6m?



Wnioski z Przykładu 1

- ogromne znaczenie w praktyce estymacji poprawnego strukturalnie modelu matematycznego systemu
- zaproponowanie strukturalnie poprawnego modelu jest zadaniem trudnym dla nie – specjalisty z dziedziny aplikacji
- pominięte elementy modelu oraz błędy estymacji parametrów modelu mogą prowadzić do błędnych wyników uzyskiwanych z modelu, szczególnie poza obszarami objętymi pomiarami

Teoria estymacji może być rozwijana bez zwracania uwagi na konkretne systemy dynamiczne, ale udane zastosowania teorii estymacji prawie zawsze oparte są na łącznym zrozumieniu teorii estymacji i zasad rządzących zachowaniem się rozważanego systemu

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

Dane:

Pomiary $\{\tilde{y}_1, t_1; \tilde{y}_2, t_2; \ldots; \tilde{y}_j, t_j; \ldots; \tilde{y}_m, t_m\}$ (1)

Proponowany model:

Liniowy względem parametrów

$$y(t) = \sum_{i=1}^{n} x_i h_i(t) \quad (2)$$

$\{h_1(t), h_2(t), \ldots, h_i(t), \ldots, h_n(t)\}$ - określony zbiór niezależnych **funkcji bazowych** (3)

Parametry nieznane

$$x_i; \quad i = \overline{1,n}$$

Założenie:

$$m \geq n$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

Poszukiwanie:

Estymaty $\hat{x}_i; \quad i = \overline{1,n}$ nieznanych parametrów $x_i; \quad i = \overline{1,n}$

Kryterium jakości doboru wartości estymowanych parametrów – jak dobrze proponowany model dokonuje predykcji pomiarów

Argument kryterium – błędy resztkowe (residua)

$$\hat{e}_j = \tilde{y}_j - \hat{y}_j, \quad j = \overline{1,m}$$

Liczba błędów resztkowych – liczba pomiarów

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

Pamiętać należy o powodach błędu pomiędzy wartością prawdziwą a wartością estymowaną:

- błąd pomiaru
- niepoprawny wybór wartości parametrów x_i, i=1, ..., n
- niepoprawna struktura modelu – błąd modelowania

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

Zależności:

$$\tilde{y}_j \equiv \tilde{y}(t_j) = \sum_{i=1}^{n} x_i h_i(t_j) + \tilde{e}_j, \quad j = \overline{1,m}$$

← - model pomiaru (4)

$$\hat{y}_j \equiv \hat{y}(t_j) = \sum_{i=1}^{n} \hat{x}_i h_i(t_j), \quad j = \overline{1,m} \qquad (5)$$

gdzie

$\tilde{e}_j, \quad j = \overline{1,m}$ - błędy pomiaru: zakładamy na razie, że ich mechanizm nie jest znany i może mieć charakter przypadkowy lub deterministyczny

Przyjmujemy

$$\tilde{y}_j = \hat{y}_j + \hat{e}_j = \sum_{i=1}^{n} \hat{x}_i h_i(t_j) + \hat{e}_j, \quad j = \overline{1,m} \qquad (6)$$

gdzie

$\hat{e}_j = \tilde{y}_j - \hat{y}_j, \quad j = \overline{1,m}$ - błędy resztkowe

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

Zależności modeli pomiaru/obserwacji w zwartej postaci

$$\tilde{\boldsymbol{y}} = H\boldsymbol{x} + \tilde{\boldsymbol{e}} \tag{4a}$$

$\boldsymbol{x} = \left(x_1, x_2, \ldots, x_i, \ldots, x_n\right)^T$ - wektor prawdziwych wartości parametrów

$\tilde{\boldsymbol{y}} = \left(\tilde{y}_1, \tilde{y}_2, \ldots, \tilde{y}_j, \ldots, \tilde{y}_m\right)^T$ - wektor wartości mierzonych y

$\tilde{\boldsymbol{e}} = \left(\tilde{e}_1, \tilde{e}_2, \ldots, \tilde{e}_j, \ldots, \tilde{e}_m\right)^T$ - wektor błędów pomiarów

$$\tilde{\boldsymbol{y}} = H\hat{\boldsymbol{x}} + \hat{\boldsymbol{e}} \tag{6a}$$

$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$ - wektor estymowanych wartości parametrów

$\tilde{\boldsymbol{y}} = \left(\tilde{y}_1, \tilde{y}_2, \ldots, \tilde{y}_j, \ldots, \tilde{y}_m\right)^T$ - wektor wartości mierzonych y

$\hat{\boldsymbol{e}} = \left(\hat{e}_1, \hat{e}_2, \ldots, \hat{e}_j, \ldots, \hat{e}_m\right)^T$ - wektor błędów resztkowych (residuów)

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa (linear batch estimation)

$$H = \begin{pmatrix} h_1(t_1) & h_2(t_1) \ldots h_i(t_1) \ldots h_n(t_1) \\ h_1(t_2) & h_2(t_2) \ldots h_i(t_2) \ldots h_n(t_2) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_j) & h_2(t_j) \ldots h_i(t_j) \ldots h_n(t_j) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_m) & h_2(t_m) \ldots h_i(t_m) \ldots h_n(t_m) \end{pmatrix}^T$$

Macierz obserwacji

Równania (4a) oraz (6a) – **równania obserwacji**

Przykład 2: rozpuszczalność azotanu sodu w zależności od temperatury

Pomiar j	Temperatura u_j	Rozpuszczalność y_j
1	0	66,7
2	4	71,0
3	10	76,3
4	15	80,6
5	21	85,7
6	29	92,9
7	36	99,4
8	51	113,6
9	68	125,1

Funkcje bazowe:

$$\{h_0(u)=1,\ h_1(u)=u\}$$

Wektor wartości mierzonych y:

$$\tilde{\boldsymbol{y}}=\begin{pmatrix}66.7\\71.0\\76.3\\80.6\\85.7\\92.9\\99.4\\113.6\\125.1\end{pmatrix}$$

Wektor wartości estymowanych y:

$$\hat{\boldsymbol{y}}=\begin{pmatrix}?\\?\\?\\?\\?\\?\\?\\?\\?\end{pmatrix}$$

Proponowany model

$$Model:\quad y(u)=b_0+b_1u$$

Wektor wartości prawdziwych parametrów:

$$\boldsymbol{b}=\begin{pmatrix}b_0\\b_1\end{pmatrix}$$

Wektor wartości estymowanych parametrów:

$$\hat{\boldsymbol{b}}=\begin{pmatrix}\hat{b}_0\\\hat{b}_1\end{pmatrix}$$

$$H = \begin{pmatrix} 1 & 0 \\ 1 & 4 \\ 1 & 10 \\ 1 & 15 \\ 1 & 21 \\ 1 & 29 \\ 1 & 36 \\ 1 & 51 \\ 1 & 68 \end{pmatrix}$$

Równania obserwacji:

$$\tilde{\boldsymbol{y}} = H\boldsymbol{b} + \tilde{\boldsymbol{e}}$$

$$\begin{pmatrix} 66.7 \\ 71.0 \\ 76.3 \\ 80.6 \\ 85.7 \\ 92.9 \\ 99.4 \\ 113.6 \\ 125.1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 4 \\ 1 & 10 \\ 1 & 15 \\ 1 & 21 \\ 1 & 29 \\ 1 & 36 \\ 1 & 51 \\ 1 & 68 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \end{pmatrix} + \begin{pmatrix} \tilde{e}_1 \\ \tilde{e}_2 \\ \tilde{e}_3 \\ \tilde{e}_4 \\ \tilde{e}_5 \\ \tilde{e}_6 \\ \tilde{e}_7 \\ \tilde{e}_8 \\ \tilde{e}_9 \end{pmatrix}$$

Wektor błędów pomiaru:

$$\begin{pmatrix} \tilde{e}_1 \\ \tilde{e}_2 \\ \tilde{e}_3 \\ \tilde{e}_4 \\ \tilde{e}_5 \\ \tilde{e}_6 \\ \tilde{e}_7 \\ \tilde{e}_8 \\ \tilde{e}_9 \end{pmatrix}$$

Wektor błędów resztkowych:

$$\begin{pmatrix} \hat{e}_1 \\ \hat{e}_2 \\ \hat{e}_3 \\ \hat{e}_4 \\ \hat{e}_5 \\ \hat{e}_6 \\ \hat{e}_7 \\ \hat{e}_8 \\ \hat{e}_9 \end{pmatrix}$$

$$\tilde{\boldsymbol{y}} = H\hat{\boldsymbol{b}} + \hat{\boldsymbol{e}}$$

$$\begin{pmatrix} 66.7 \\ 71.0 \\ 76.3 \\ 80.6 \\ 85.7 \\ 92.9 \\ 99.4 \\ 113.6 \\ 125.1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 4 \\ 1 & 10 \\ 1 & 15 \\ 1 & 21 \\ 1 & 29 \\ 1 & 36 \\ 1 & 51 \\ 1 & 68 \end{pmatrix} \begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \end{pmatrix} + \begin{pmatrix} \hat{e}_1 \\ \hat{e}_2 \\ \hat{e}_3 \\ \hat{e}_4 \\ \hat{e}_5 \\ \hat{e}_6 \\ \hat{e}_7 \\ \hat{e}_8 \\ \hat{e}_9 \end{pmatrix}$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa nieważona

Metoda najmniejszych kwadratów Gauss'a proponuje jako optymalny wybór dla wartości nieznanych parametrów, wartość

$$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$$

który minimalizuje sumę kwadratów błędów resztkowych (residuów)

$$J = \frac{1}{2}\hat{\boldsymbol{e}}^T\hat{\boldsymbol{e}}$$

z (6a) $\quad \tilde{\boldsymbol{y}} = H\hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}$

$$\hat{\boldsymbol{e}} = \tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}$$

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Przykład 2: c.d.

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{b}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{b}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{b}} + \hat{\boldsymbol{b}}^T H^T H\hat{\boldsymbol{b}}\right)$$

$$\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} = \begin{pmatrix} 66.7 & 71.0 & 76.3 & 80.6 & 85.7 & 92.9 & 99.4 & 113.6 & 125.1 \end{pmatrix} \begin{pmatrix} 66.7 \\ 71.0 \\ 76.3 \\ 80.6 \\ 85.7 \\ 92.9 \\ 99.4 \\ 113.6 \\ 125.1 \end{pmatrix} = 76218.17$$

$$2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{b}} = 2\begin{pmatrix}66.7 & 71.0 & 76.3 & 80.6 & 85.7 & 92.9 & 99.4 & 113.6 & 125.1\end{pmatrix}\begin{pmatrix}1 & 0\\ 1 & 4\\ 1 & 10\\ 1 & 15\\ 1 & 21\\ 1 & 29\\ 1 & 36\\ 1 & 51\\ 1 & 68\end{pmatrix}\begin{pmatrix}\hat{b}_0\\ \hat{b}_1\end{pmatrix}$$

$$= 2\begin{pmatrix}811.3 & 24628.6\end{pmatrix}\begin{pmatrix}\hat{b}_0\\ \hat{b}_1\end{pmatrix} = 2\left(811.3\hat{b}_0 + 24628.6\hat{b}_1\right) = 1622.6\hat{b}_0 + 49257.2\hat{b}_1$$

$$\hat{\boldsymbol{b}}^T H^T H \hat{\boldsymbol{b}} = \begin{pmatrix} \hat{b}_0 & \hat{b}_1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 4 & 10 & 15 & 21 & 29 & 36 & 51 & 68 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 4 \\ 1 & 10 \\ 1 & 15 \\ 1 & 21 \\ 1 & 29 \\ 1 & 36 \\ 1 & 51 \\ 1 & 68 \end{pmatrix} \begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \end{pmatrix}$$

$$= \begin{pmatrix} \hat{b}_0 & \hat{b}_1 \end{pmatrix} \begin{pmatrix} 9 & 234 \\ 234 & 10144 \end{pmatrix} \begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \end{pmatrix} = \begin{pmatrix} 9\hat{b}_0 + 234\hat{b}_1 & 234\hat{b}_0 + 10144\hat{b}_1 \end{pmatrix} \begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \end{pmatrix}$$

$$= 9\hat{b}_0^2 + 234\hat{b}_0\hat{b}_1 + 234\hat{b}_0\hat{b}_1 + 10144\hat{b}_1^2$$

$$J(\boldsymbol{b}) = 76218.17 - 1622.6\hat{b}_0 - 49257.2\hat{b}_1 + 9\hat{b}_0^2 + 234\hat{b}_0\hat{b}_1 + 234\hat{b}_0\hat{b}_1 + 10144\hat{b}_1^2$$

Metoda najmniejszych kwadratów – kryterium jakości estymacji

Co możemy powiedzieć o : $J(\hat{x})$

$$J = \frac{1}{2}(\tilde{y} - H\hat{x})^T(\tilde{y} - H\hat{x}) = \frac{1}{2}(\tilde{y}^T\tilde{y} - 2\tilde{y}^T H\hat{x} + \hat{x}^T H^T H\hat{x})$$

1. Możemy napisać - $J(\hat{x})$

$$J : R^n \rightarrow R$$ - J jest funkcjonałem

Metoda najmniejszych kwadratów → zadanie minimalizacji funkcjonału bez ograniczeń; zadanie minimalizacji bez ograniczeń

Dla danego w oparciu o równania obserwacji funkcjonału J(x) poszukujemy wartości x^* dającej minimalną wartość tego funkcjonału

Metoda najmniejszych kwadratów – kryterium jakości estymacji

2. Metoda najmniejszych kwadratów → Funkcja celu ma postać formy kwadratowej

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Forma kwadratowa

$$F(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}^T\boldsymbol{x} + c$$

gdzie: A - macierz symetryczna

$$\boldsymbol{A} = H^T H \qquad \boldsymbol{d}^T = -\tilde{\boldsymbol{y}}^T H \qquad c = \frac{1}{2}\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}}$$

Przypomnienie z rachunku różniczkowego ?

Warunki konieczne i wystarczające, jakie musi spełnić punkt x, aby można było go uznać za dający minimalną wartość funkcjonału wyprowadzane są w oparciu o jego rozwinięcie Taylor'a w otoczeniu punktu x

Przypomnienie z rachunku różniczkowego oraz podanie wybranych faktów z teorii optymalizacji - Dodatek A

Metoda najmniejszych kwadratów nieważona – warunki konieczne i wystarczające optymalności (minimum) estymat

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Warunek konieczny pierwszego rzędu:

$$\nabla J(\boldsymbol{x})\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T H\,\hat{\boldsymbol{x}} - H^T\tilde{\boldsymbol{y}} = \boldsymbol{0} \qquad (1)$$

Warunek konieczny drugiego rzędu:

$$\Delta\boldsymbol{x}^T\nabla^2 J(\boldsymbol{x})^T\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}}\Delta\boldsymbol{x} = \Delta\hat{\boldsymbol{x}}^T H^T H\Delta\hat{\boldsymbol{x}} \geq \boldsymbol{0} \quad \text{dla dowolnych} \quad \Delta\hat{\boldsymbol{x}}$$

$H^T H$ dodatnio półokreślona (2)

Metoda najmniejszych kwadratów nieważona – warunki konieczne i wystarczające optymalności (minimum) estymat

Warunek wystarczający drugiego rzędu:

$H^T H$ dodatnio określona (3)

Fakty:

- Macierz $H^T H$ jest zawsze dodatnio półokreślona (jako macierz symetryczna)
- Macierz $H^T H$ jest dodatnio określona, jeżeli macierz H ma najwyższy rząd równy n

Metoda najmniejszych kwadratów nieważona – rozwiązanie najlepszych estymat

Obliczanie wartości estymowanych nieznanych parametrów – układ równań normalnych wynikający z warunku koniecznego pierwszego rzędu

Układ równań normalnych

$$H^T H \, \hat{\boldsymbol{x}} = H^T \tilde{\boldsymbol{y}} \tag{4}$$

Jeżeli macierz $H^T H$ jest nieosobliwa - posiada macierz odwrotną - otrzymujemy **jawne rozwiązanie optymalnej estymaty**

$$\hat{\boldsymbol{x}} = \left(H^T H \right)^{-1} H^T \tilde{\boldsymbol{y}} \tag{5}$$

Metoda najmniejszych kwadratów nieważona – rozwiązanie najlepszych estymat

Fakty:

- Jawne rozwiązanie optymalnej estymaty wymaga nieosobliwości macierzy $H^T H$
- macierz $H^T H$ jest nieosobliwa jeżeli rząd macierzy H wynosi n, czyli liczba liniowo niezależnych równań obserwacji jest większa lub co najmniej równa liczbie poszukiwanych estymat x_i

Stąd warunek:

- zbiór funkcji bazowych powinien być liniowo niezależny

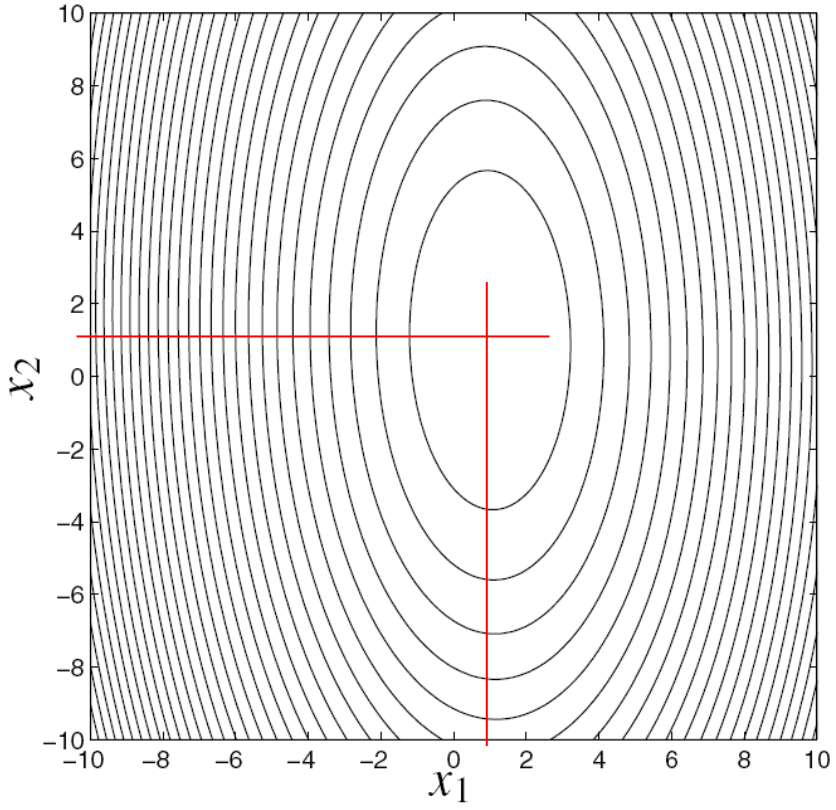
Przykład 3:

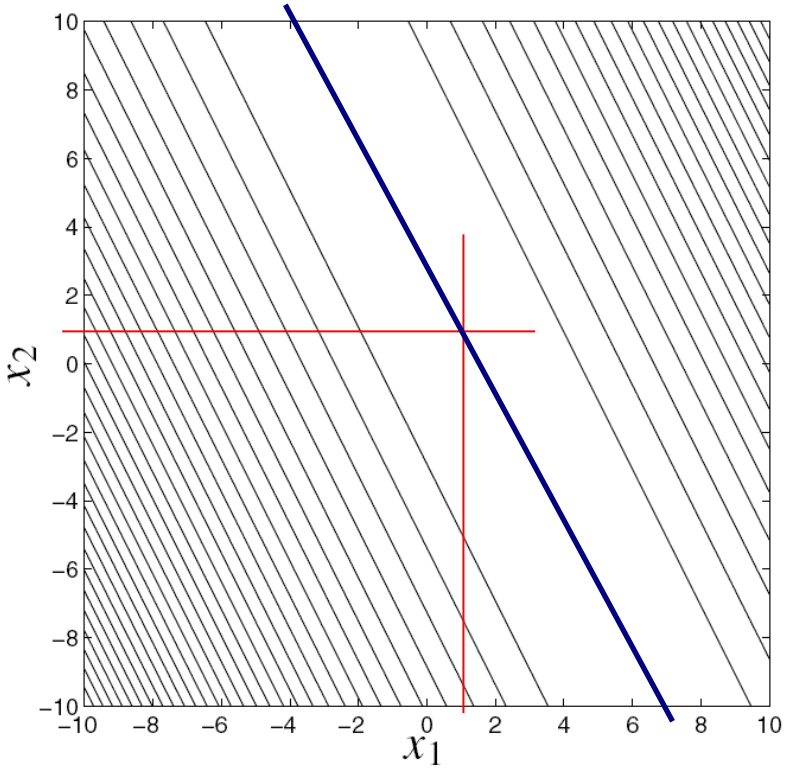
Prawdziwe wartości parametrów $\boldsymbol{x} = \begin{pmatrix} 1 & 1 \end{pmatrix}^T$

Proponowane zestawy funkcji bazowych

$$H_1 = \begin{bmatrix} \sin t & 2\cos t \end{bmatrix}$$

$$H_2 = \begin{bmatrix} \sin t & 2\sin t \end{bmatrix}$$

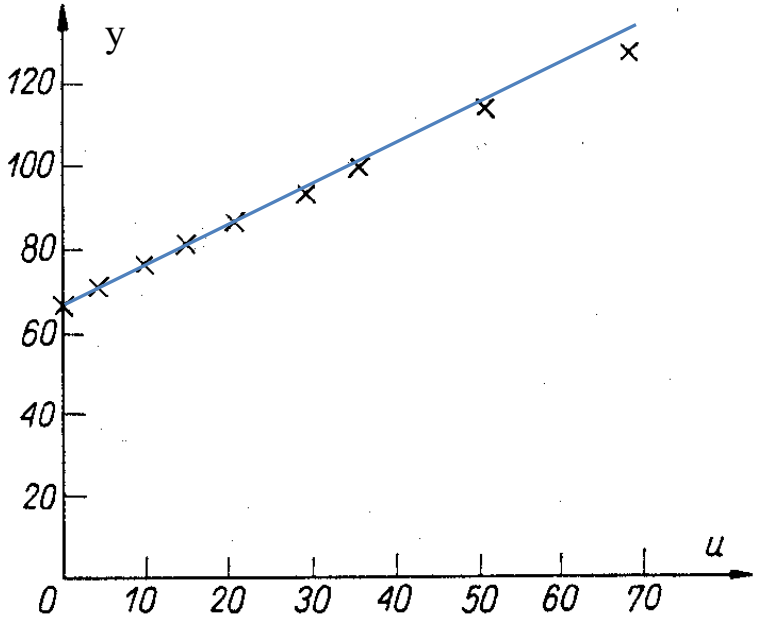




Przykład 4: rozpuszczalność azotanu sodu w zależności od temperatury

Rozwiązanie normalnego układu równań

$$\begin{bmatrix} \hat{b}_0 \\ \hat{b}_1 \end{bmatrix} = \begin{bmatrix} 67.51 \\ 0.6706 \end{bmatrix} \qquad \hat{y} = 67.51 + 0.6706u$$



Przykład 5: (estymacja parametrów prostego układu dynamicznego)

System

$$\dot{x} = ax + bu$$

Dyskretna reprezentacja systemu z przedziałem dyskretyzacji Δt

$$x(k+1) = A_D x(k) + B_D u(k)$$

gdzie:

$$A_D = e^{a\Delta t}$$

$$B_D = \int_0^{\Delta t} b e^{at} dt = \frac{b}{a}\left(e^{a\Delta t} - 1\right)$$

Zadanie: określić wartości stałych A_D oraz B_D wykorzystując zbiór pomiarów dyskretnych $\tilde{y}_k$ oraz u_k

Jak została zaproponowana reprezentacja dyskretna systemu – powtórzenie

Poszukujemy odpowiedzi systemu na dowolne wymuszenie w przedziale czasu $[t_0, t)$ – patrz wykłady z Podstaw automatyki

$$\dot{x}(t) = a \cdot x(t) + b \cdot u(t)$$

$$x(t_0) = y_0$$



Dla dowolnego wejścia u(t) określonego w przedziale $[t_0,t]$ odpowiedź systemu

$$x(t) = e^{a(t-t_0)}x_0 + \int_{t_0}^{t} e^{a(t-\tau)}bu(\tau)d\tau = e^{a(t-t_0)}x_0 + e^{at}\int_{t_0}^{t} e^{-a\tau}bu(\tau)d\tau$$

Przyjmując przedział dyskretyzacji T_s możemy policzyć

$$x(kT_s) = e^{a(kT_s - t_0)}x_0 + e^{akT_s}\int_{t_0}^{kT_s} e^{-a\tau}bu(\tau)d\tau$$

$$x((k+1)T_s) = e^{a((k+1)T_s - t_0)}x_0 + e^{a(k+1)T_s}\int_{t_0}^{(k+1)T_s} e^{-a\tau}bu(\tau)d\tau$$

Przemnażamy pierwszą zależność przez e^{aT_s} i odejmujemy od drugiej

$$e^{aT_s}x(kT_s) = e^{a((k+1)T_s - t_0)}x_0 + e^{a(k+1)T_s}\int_{t_0}^{kT_s} e^{-a\tau}bu(\tau)d\tau$$

$$x((k+1)T_s) - e^{aT_s}x(kT_s) = e^{a(k+1)T_s}\int_{kT_s}^{(k+1)T_s} e^{-a\tau}bu(\tau)d\tau$$

Ostatnia zależność po uporządkowaniu

$$x((k+1)T_s) = e^{aT_s}x(kT_s) + \int_{kT_s}^{(k+1)T_s} e^{a((k+1)T_s - \tau)}bu(\tau)d\tau$$

Zmieniamy zmienną całkowania

$$(k+1)T_s - \tau = t$$

Otrzymujemy

$$x\left((k+1)T_s\right) = e^{aT_s}x\left(kT_s\right) + \int_0^{T_s} e^{at}bu(t)\,dt$$

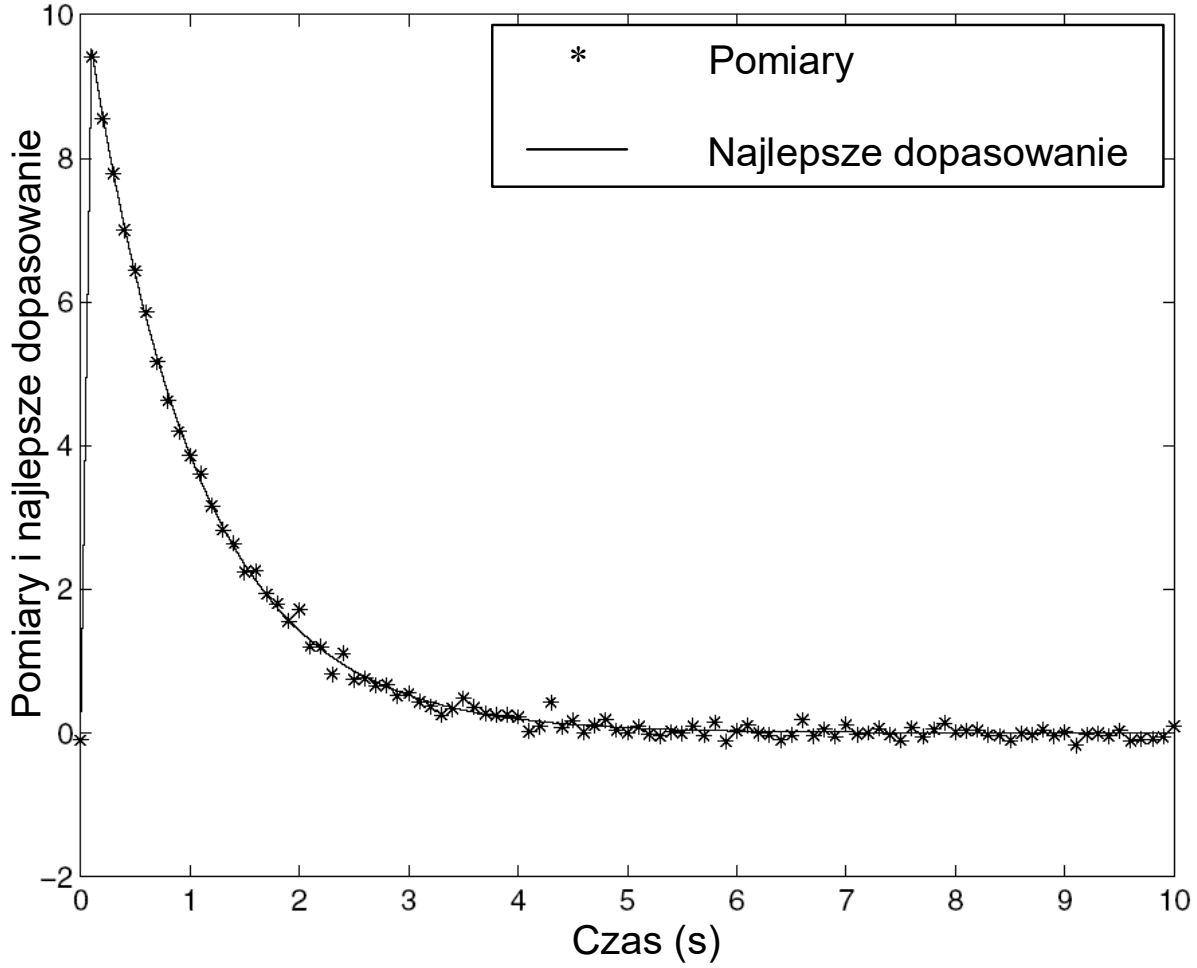
Przyjmując stałość wejścia w przedziale próbkowania

$$x\left((k+1)T_s\right) = \underbrace{e^{aT_s}}_{A_D}x\left(kT_s\right) + \underbrace{\int_0^{T_s} e^{at}b\,dt}_{B_D}\cdot u\left(kT_s\right)$$

$$x\left((k+1)\right) = A_D x(k) + B_D \cdot u(k)$$

Eksperyment pomiarowy:

Na wejście układu w chwili k=1 podano impuls (Dirac'a) o intensywności 100 i następnie obserwowano wyjście przez 101 chwil czasowych z Δt=0.1



Macierz wartości funkcji bazowych:

$$H = \begin{bmatrix} \tilde{x}_1 & u_1 \\ \tilde{x}_2 & u_2 \\ \vdots & \vdots \\ \tilde{x}_j & u_j \\ \vdots & \vdots \\ \tilde{x}_{100} & u_{100} \end{bmatrix}$$

$$x((k+1)) = A_D x(k) + B_D \cdot u(k)$$

Równanie obserwacji:

$$\begin{bmatrix} \tilde{x}_2 \\ \tilde{x}_3 \\ \vdots \\ \tilde{x}_{j+1} \\ \vdots \\ \tilde{x}_{101} \end{bmatrix} = H \begin{bmatrix} \hat{A}_D \\ \hat{B}_D \end{bmatrix} + \begin{bmatrix} \hat{e}_2 \\ \hat{e}_3 \\ \vdots \\ \hat{e}_{j+1} \\ \vdots \\ \hat{e}_{101} \end{bmatrix}$$

lub

$$\begin{bmatrix} \tilde{x}_2 \\ \tilde{x}_3 \\ \vdots \\ \tilde{x}_{j+1} \\ \vdots \\ \tilde{x}_{101} \end{bmatrix} = \begin{bmatrix} \tilde{x}_1 & u_1 \\ \tilde{x}_2 & u_2 \\ \vdots & \vdots \\ \tilde{x}_j & u_j \\ \vdots & \vdots \\ \tilde{x}_{100} & u_{100} \end{bmatrix} \begin{bmatrix} \hat{A}_D \\ \hat{B}_D \end{bmatrix} + \begin{bmatrix} \hat{e}_2 \\ \hat{e}_3 \\ \vdots \\ \hat{e}_{j+1} \\ \vdots \\ \hat{e}_{101} \end{bmatrix}$$

Korzystając z (5):

$$\begin{bmatrix} \widehat{A}_D \\ \widehat{B}_D \end{bmatrix} = \left(H^T H\right)^{-1} H^T \begin{bmatrix} \widetilde{x}_2 \\ \widetilde{x}_3 \\ \vdots \\ \widetilde{x}_{j+1} \\ \vdots \\ \widetilde{x}_{101} \end{bmatrix}$$

Otrzymamy:

$$\begin{bmatrix} \widehat{A}_D \\ \widehat{B}_D \end{bmatrix} = \begin{bmatrix} 0.9048 \\ 0.0950 \end{bmatrix}$$

„Kuchnia” naszego zadania:

Pomiary generowane były z wykorzystaniem następujących wartości prawdziwych

$$\begin{bmatrix} A_D \\ B_D \end{bmatrix} = \begin{bmatrix} 0.9048 \\ 0.0952 \end{bmatrix}$$

Symulacja błędu pomiaru: generator szumu gaussowskiego o zerowej wartości średniej i odchyleniu standardowym σ = 0.08

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa ważona

Poprzednie podejście: jednakowe znaczenie wszystkich pomiarów

Ważniejsze te pomiary, które wykonywane są z mniejszym błędem – dołączenie wag pomiarów do metody najmniejszych kwadratów

Znaleźć wartości nieznanych parametrów

$$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$$

minimalizujące

$$J = \frac{1}{2}\hat{\boldsymbol{e}}^T W \hat{\boldsymbol{e}}$$

gdzie $\hat{\boldsymbol{e}} = \tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}$

W - symetryczna macierz wag

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa ważona

Warunek konieczny pierwszego rzędu:

$$\nabla J(\boldsymbol{x})\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T W\, H\, \hat{\boldsymbol{x}} - H^T W\, \tilde{\boldsymbol{y}} = \boldsymbol{0} \tag{6}$$

Warunek dostateczny drugiego rzędu:

$$\nabla^2 J(\boldsymbol{x})^T \Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T W\, H \tag{7}$$

dodatnio określona

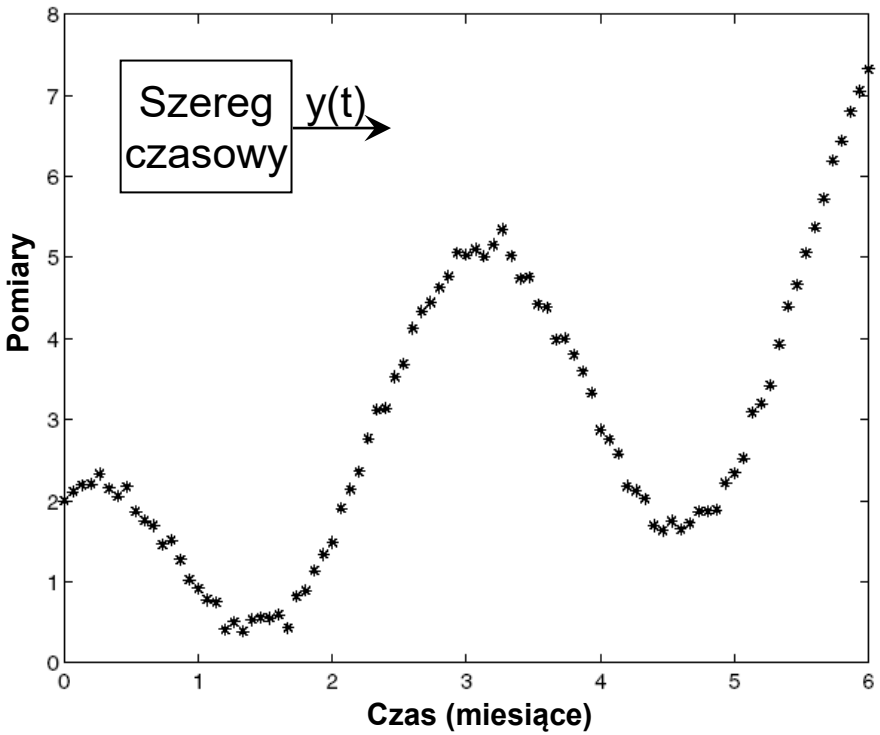
W dodatnio określona

Metoda najmniejszych kwadratów ważona – rozwiązanie najlepszych estymat

Jawne rozwiązanie optymalnej estymaty

$$\widehat{\boldsymbol{x}} = \left(H^T W\ H\right)^{-1} H^T W\ \tilde{\boldsymbol{y}} \tag{8}$$

Przykład 6: (nawiązanie do Przykład 1 (aproksymacja szeregu czasowego)



Wykorzystanie 31 pomiarów spośród 91 zebranych w okresie 6 miesięcy

Powzięto informację, że 3 pierwsze pomiary są obarczone mniejszym błędem niż pozostałe

Nie ma informacji o dokładności wartości par pomiarów

Proponowana macierz wag:

$$W = diag(w, w, w, 1, \ldots, 1)$$

Wykorzystujemy Model1:

$$Model\ 1: \quad y_1(t) = c_1 t + c_2\, sin(t) + c_3\, cos(2t)$$

t - czas [miesiące – m]

c_1, c_2, c_3 - stałe współczynniki – parametry Modelu 1

Pierwsza estymacja:

$w = 1$ 31 pomiarów

$$\left(\hat{c}_1, \hat{c}_2, \hat{c}_3\right)^T = \left(1.0278, 0.8750, 1.9884\right)^T$$

Wyniki gorsze niż przy wykorzystaniu dostępnych 91 pomiarów

Zestawienie wyników estymacji:

w	$\hat{\boldsymbol{x}}$	Norma błędów resztkowych wymuszanych
$1\text{x}10^{0}$	(1.0278, 0.8750, 1.9884)	$3.21\text{x}10^{-2}$
$1\text{x}10^{1}$	(1.0388, 0.8675, 2.0018)	$1.17\text{x}10^{-2}$
$1\text{x}10^{2}$	(1.0258, 0.8923, 2.0049)	$7.87\text{x}10^{-3}$
$1\text{x}10^{5}$	(0.9047, 1.0949, 2.0000)	$5.91\text{x}10^{-5}$
$1\text{x}10^{7}$	(0.9060, 1.0943, 2.0000)	$1.10\text{x}10^{-5}$
$1\text{x}10^{10}$	(0.9932, 1.0068, 2.0000)	$4.55\text{x}10^{-7}$
$1\text{x}10^{15}$	(0.9970, 1.0030, 2.0000)	$0.97\text{x}10^{-9}$

$$\boldsymbol{x} = \left(1, 1, 2\right)$$

Zastosowanie ważonej metody najmniejszych kwadratów może poprawić jakość estymacji

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Poprzednie podejścia:

- jednakowe znaczenie wszystkich pomiarów – wszystkie pomiary wykonywane z jednakową dokładnością (jednakowo wiarygodne)
- różne znaczenie poszczególnych pomiarów – część pomiarów charakteryzuje się większą dokładnością (większą wiarygodnością) inne mniejszą dokładnością (mniejszą wiarygodnością

Rozważymy jeszcze jedną możliwość:

- część pomiarów jest dokładna (wykonywana z błędem pomijalnie małym w stosunku do innych pomiarów)

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Wszystkie obserwacje-pomiary o liczebności m podzielimy na dwie kategorie:

- m_1 pomiarów-obserwacji wykonanych z ograniczoną dokładnością
- m_2 pomiarów-obserwacji dokładnych

$$m_1 + m_2 = m$$

$$\tilde{\boldsymbol{y}}_1 = \underbrace{\left(\tilde{y}_{11}, \ldots, \tilde{y}_{1j_1}, \ldots, \tilde{y}_{1m_1}\right)^T}_{m_1}$$

- wektor wartości y mierzonych z ograniczoną dokładnością

Pomiary-obserwacje w obrębie tej kategorii mogą być zróżnicowane – wprowadzenie macierzy W_1

$$\tilde{\boldsymbol{y}}_2 = \underbrace{\left(\tilde{y}_{21}, \ldots, \tilde{y}_{2j_2}, \ldots, \tilde{y}_{2m_2}\right)^T}_{m_2}$$

- wektor wartości y mierzonych dokładnie

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Dla wszystkich przeprowadzonych pomiarów określane są macierze wartości funkcji bazowych, odpowiednio H_1, dla pomiarów niedokładnych i H_2, dla pomiarów dokładnych

Macierze wartości funkcji bazowych

$$H_1 = \underbrace{\begin{pmatrix} h_1(t_{11}) \ldots h_i(t_{11}) \ldots h_n(t_{11}) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_{1j_1}) \ldots h_i(t_{1j_1}) \ldots h_n(t_{1j_1}) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_{1m_1}) \ldots h_i(t_{1m_1}) \ldots h_n(t_{1m_1}) \end{pmatrix}^T}_{n} \quad \left.\vphantom{\begin{pmatrix} a \\ b \\ c \\ d \\ e \end{pmatrix}}\right\} m_1$$

$$H_2 = \underbrace{\begin{pmatrix} h_1(t_{21}) \ldots\ldots\ldots h_i(t_{21}) \ldots\ldots\ldots h_n(t_{21}) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_{2j_2}) \ldots\ldots\ldots h_i(t_{2j_2}) \ldots\ldots\ldots h_n(t_{2j_2}) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(t_{m_2}) \ldots\ldots\ldots h_i(t_{m_2}) \ldots\ldots\ldots h_n(t_{m_2}) \end{pmatrix}^T}_{n} \quad \left.\vphantom{\begin{pmatrix} a \\ b \\ c \\ d \\ e \end{pmatrix}}\right\} m_2$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Dla pierwszej kategorii pomiarów:

$$\tilde{\boldsymbol{e}}_1 = \left(\tilde{e}_{11}, \ldots, \tilde{e}_{1j_1}, \ldots, \tilde{e}_{1m_1}\right)^T \neq \boldsymbol{0}$$

$$\hat{\boldsymbol{e}}_1 = \underbrace{\left(\hat{e}_{11}, \ldots, \hat{e}_{1j_1}, \ldots, \hat{e}_{1m_1}\right)^T}_{m_1} \neq \boldsymbol{0}$$

Dla drugiej kategorii pomiarów:

$$\tilde{\boldsymbol{e}}_2 = \left(\tilde{e}_{21}, \ldots, \tilde{e}_{2j_2}, \ldots, \tilde{e}_{2m_2}\right)^T = \boldsymbol{0}$$

$$\hat{\boldsymbol{e}}_2 = \underbrace{\left(\hat{e}_{21}, \ldots, \hat{e}_{2j_2}, \ldots, \hat{e}_{m_2}\right)^T}_{m_2} = \boldsymbol{0}$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Równanie obserwacji będzie miało postać:

$$\begin{bmatrix} \tilde{\boldsymbol{y}}_1 \\ \cdots \\ \tilde{\boldsymbol{y}}_2 \end{bmatrix} = \begin{bmatrix} H_1 \\ \cdots \\ H_2 \end{bmatrix} \hat{\boldsymbol{x}} + \begin{bmatrix} \hat{\boldsymbol{e}}_1 \\ \cdots \\ \boldsymbol{0} \end{bmatrix} \tag{1}$$

lub

$$\begin{cases} \tilde{\boldsymbol{y}}_1 = H_1 \hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}_1 & (2) \\ \tilde{\boldsymbol{y}}_2 = H_2 \hat{\boldsymbol{x}} & (3) \end{cases}$$

Przyjmiemy z naturalnych powodów:

$$n \geq m_2$$

$$n \leq m_1$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Poszukujemy wektora wartości estymowanych nieznanych parametrów

$$\hat{\boldsymbol{x}} = \left(\hat{\boldsymbol{x}}_1, \ldots, \hat{\boldsymbol{x}}_i, \ldots, \hat{\boldsymbol{x}}_n\right)^T$$ - wektor estymowanych wartości parametrów

Zadanie poszukiwania tego wektora możemy sformułować:

Znaleźć wektor $\hat{\boldsymbol{x}} = \left(\hat{\boldsymbol{x}}_1, \ldots, \hat{\boldsymbol{x}}_i, \ldots, \hat{\boldsymbol{x}}_n\right)^T$, który minimalizuje sumę kwadratów błędów resztkowych (residuów) **pomiarów niedokładnych**

$$J(\hat{\boldsymbol{x}}) = \frac{1}{2}\hat{\boldsymbol{e}}_1^T W_1 \hat{\boldsymbol{e}}_1 = \frac{1}{2}\left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right)^T W_1 \left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right) \quad (4)$$

spełniając ograniczenia równościowe **pomiarów dokładnych**

$$\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}} = \boldsymbol{0} \quad (5)$$

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi

Rozwiązanie postawionego zadania estymacji **metodą nieoznaczonych mnożników Lagrange'a**

Przedstawienie metody:

- wprowadzamy wektor dodatkowych zmiennych nazywanych nieoznaczonymi mnożnikami Lagrange'a λ; wymiar wektora jest równy liczbie ograniczeń równościowych
- ograniczenia równościowe przemnożone przez wektor mnożników Lagrange'a włączone zostają jako składnik do **rozszerzonej** funkcji celu
- wartości optymalne oryginalnych zmiennych oraz mnożników Lagrange'a wyznaczane są drogą rozwiązania układu równań będących zapisem warunku koniecznego pierwszego rzędu minimum rozszerzonej funkcji celu

Wektor nieoznaczonych mnożników Lagrange'a dla zagadnienia (4) – (5):

$$\boldsymbol{\lambda} = \left[\lambda_1, \ldots, \lambda_{j_2}, \ldots, \lambda_{m_2}\right]^T \tag{6}$$

Rozszerzona funkcja celu zagadnienia (4) – (5):

$$J_L\left(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right)^T W_1\left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right) + \boldsymbol{\lambda}^T\left(\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}}\right) = \tag{7}$$

$$\frac{1}{2}\left[\tilde{\boldsymbol{y}}_1^T W_1 \tilde{\boldsymbol{y}}_1 - 2\tilde{\boldsymbol{y}}_1^T W_1 H_1 \hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^{\boldsymbol{T}}\left(H_1^T W_1 H_1\right)\hat{\boldsymbol{x}}\right] + \boldsymbol{\lambda}^T\left(\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}}\right)$$

Warunki konieczne minimum rozszerzonej funkcji celu zagadnienia (4) – (5):

$$\nabla_x J_L\left(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}\right)\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = -H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)\hat{\boldsymbol{x}} - H_2^T \boldsymbol{\lambda} = \boldsymbol{0} \tag{8}$$

$$\nabla_\lambda J_L\left(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}\right)\Big|_{\lambda=\lambda^*} = \tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}} = \boldsymbol{0} \tag{9}$$

Rozwiązujemy (8) względem $\hat{\boldsymbol{x}}$

$$-H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)\hat{\boldsymbol{x}} - H_2^T \boldsymbol{\lambda} = \boldsymbol{0}$$

$$\hat{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)^{-1} H_2^T \boldsymbol{\lambda} \qquad (10)$$

Wynik (10) podstawiamy do (9)

$$\tilde{\boldsymbol{y}}_2 - H_2 \hat{\boldsymbol{x}} = \boldsymbol{0}$$

$$\tilde{\boldsymbol{y}}_2 - H_2\left[\left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)^{-1} H_2^T \boldsymbol{\lambda}\right] = \boldsymbol{0}$$

$$\tilde{\boldsymbol{y}}_2 - H_2\left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 - H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T \boldsymbol{\lambda} = \boldsymbol{0}$$

$$\boldsymbol{\lambda} = \left[H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1}\left[\tilde{\boldsymbol{y}}_2 - H_2\left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1\right] \qquad (11)$$

Wynik (11) podstawiamy do (10)

$$\boldsymbol{\lambda} = \left[H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1}\left[\tilde{\boldsymbol{y}}_2 - H_2\left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1\right]$$

$$\hat{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)^{-1} H_2^T \boldsymbol{\lambda}$$

$$\hat{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 +$$

$$+ \left(H_1^T W_1 H_1\right)^{-1} H_2^T \left[H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1}\left[\tilde{\boldsymbol{y}}_2 - H_2\left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1\right]$$

Macierz zależna od wartości funkcji bazowych (wejść) i wag pomiarów – macierz stała

Optymalne wartości estymowane nieznanych parametrów wyznaczone w oparciu o pomiary niedokładne (patrz (8) z poprzedniego wykładu)

Metoda najmniejszych kwadratów – jednokrotna estymacja liniowa z pomiarami dokładnymi – rozwiązanie najlepszych estymat

Możemy podać wynik rozwiązania zadania (4)-(5):

$$\hat{\boldsymbol{x}} = \bar{\boldsymbol{x}} + K\left(\tilde{\boldsymbol{y}}_2 - H_2\bar{\boldsymbol{x}}\right) \tag{12}$$

gdzie:

$$\bar{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 \tag{13}$$

$$K = \left(H_1^T W_1 H_1\right)^{-1} H_2^T \left[H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1} \tag{14}$$

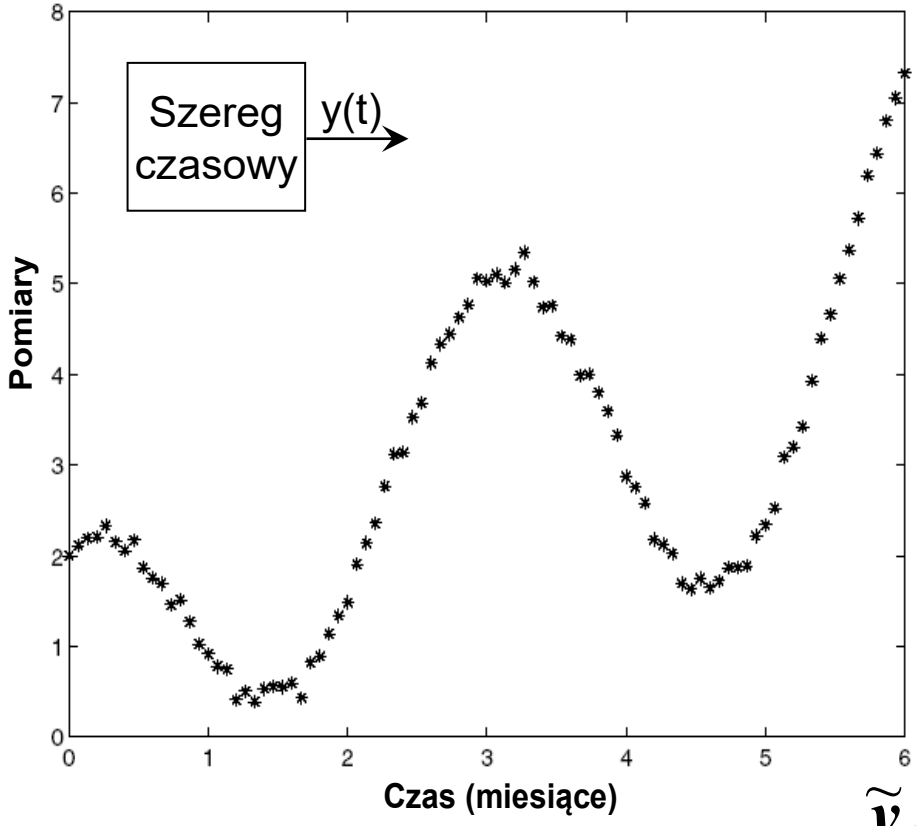
K – macierz wzmocnień

Optymalne wartości estymowane nieznanych parametrów wyznaczone w oparciu o pomiary niedokładne

Wartości y mierzone dokładnie

Predykcja wartości y z wykorzystaniem wartości estymowanych nieznanych parametrów wyznaczonych w oparciu o niedokładne pomiary

Przykład 7: (nawiązanie do Przykład 1)



Wykorzystanie 31 pomiarów spośród 91 zebranych w okresie 6 miesięcy

Trzy przypadki:

Przypadek 1:

$$\tilde{\boldsymbol{y}}_1 = [\tilde{y}_2, \tilde{y}_3, \ldots, \tilde{y}_{31}]^T, \; \tilde{\boldsymbol{y}}_2 = \tilde{y}_1$$

Przypadek 2:

$$\tilde{\boldsymbol{y}}_1 = [\tilde{y}_3, \tilde{y}_4, \ldots, \tilde{y}_{31}]^T, \; \tilde{\boldsymbol{y}}_2 = [\tilde{y}_1, \tilde{y}_2]^T$$

Przypadek 3:

$$\tilde{\boldsymbol{y}}_1 = [\tilde{y}_4, \tilde{y}_5, \ldots, \tilde{y}_{31}]^T, \; \tilde{\boldsymbol{y}}_2 = [\tilde{y}_1, \tilde{y}_2, \tilde{y}_3]^T$$

Zestawienie wyników estymacji:

Przypadek	$\bar{x}$	$\hat{x}$
1	(1.0261, 0.8766, 1.9869)	(1.0406, 0.8629, 2.0000)
2	(1.0233, 0.8789, 1.9840)	(0.9039, 1.0901, 2.0000)
3	(1.0192, 0.8820, 1.9793)	(0.9970, 1.0030, 2.0000)

$$x = (1, 1, 2)$$

Zastosowanie metody najmniejszych kwadratów z ograniczeniami może poprawić jakość estymacji

Dziękuję
– koniec materiału prezentowanego podczas wykładu



Dodatek A

Przypomnienie z rachunku różniczkowego oraz podanie wybranych faktów z teorii optymalizacji

Mamy funkcjonał:

$$F : R^n \rightarrow R$$

Rozwinięcie funkcjonału F w szereg Taylor'a w otoczeniu punktu x* ma postać:

$$F(\boldsymbol{x}) = F(\boldsymbol{x}^*) + \frac{\partial}{\partial x_1} F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (x_1 - x_1^*)$$

$$+ \frac{\partial}{\partial x_2} F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (x_2 - x_2^*) + \cdots + \frac{\partial}{\partial x_n} F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (x_n - x_n^*)$$

$$+ \frac{1}{2}\frac{\partial^2}{\partial x_1^2} F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (x_1 - x_1^*)^2 + \frac{1}{2}\frac{\partial^2}{\partial x_1 \partial x_2} F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (x_1 - x_1^*)(x_2 - x_2^*) + \cdots$$

W najprostszym przypadku:

$$F : R \to R$$

Rozwinięcie funkcjonału F w szereg Taylor'a w otoczeniu punktu x* ma postać:

$$F(x) = F(x^*) + \frac{d}{dx} F(x)\Big|_{x=x^*} (x - x^*) + \frac{1}{2} \frac{d^2}{dx^2} F(x)\Big|_{x=x^*} (x - x^*)^2 + \cdots + \frac{1}{n!} \frac{d^n}{dx^n} F(x)\Big|_{x=x^*} (x - x^*)^n + \cdots$$

Przykład 1 - skalarny:

$$F(x) = e^{-x}$$

Rozwinięcie w szereg Taylor'a w otoczeniu $x^* = 0$ **:**

$$F(x) = e^{-x} = e^{-0} - 1e^{-0}(x-0) + \frac{1}{2}e^{-0}(x-0)^2 - \frac{1}{6}e^{-0}(x-0)^3 + \cdots$$

$$F(x) = 1 - x + \frac{1}{2}x^2 - \frac{1}{6}x^3 + \cdots$$

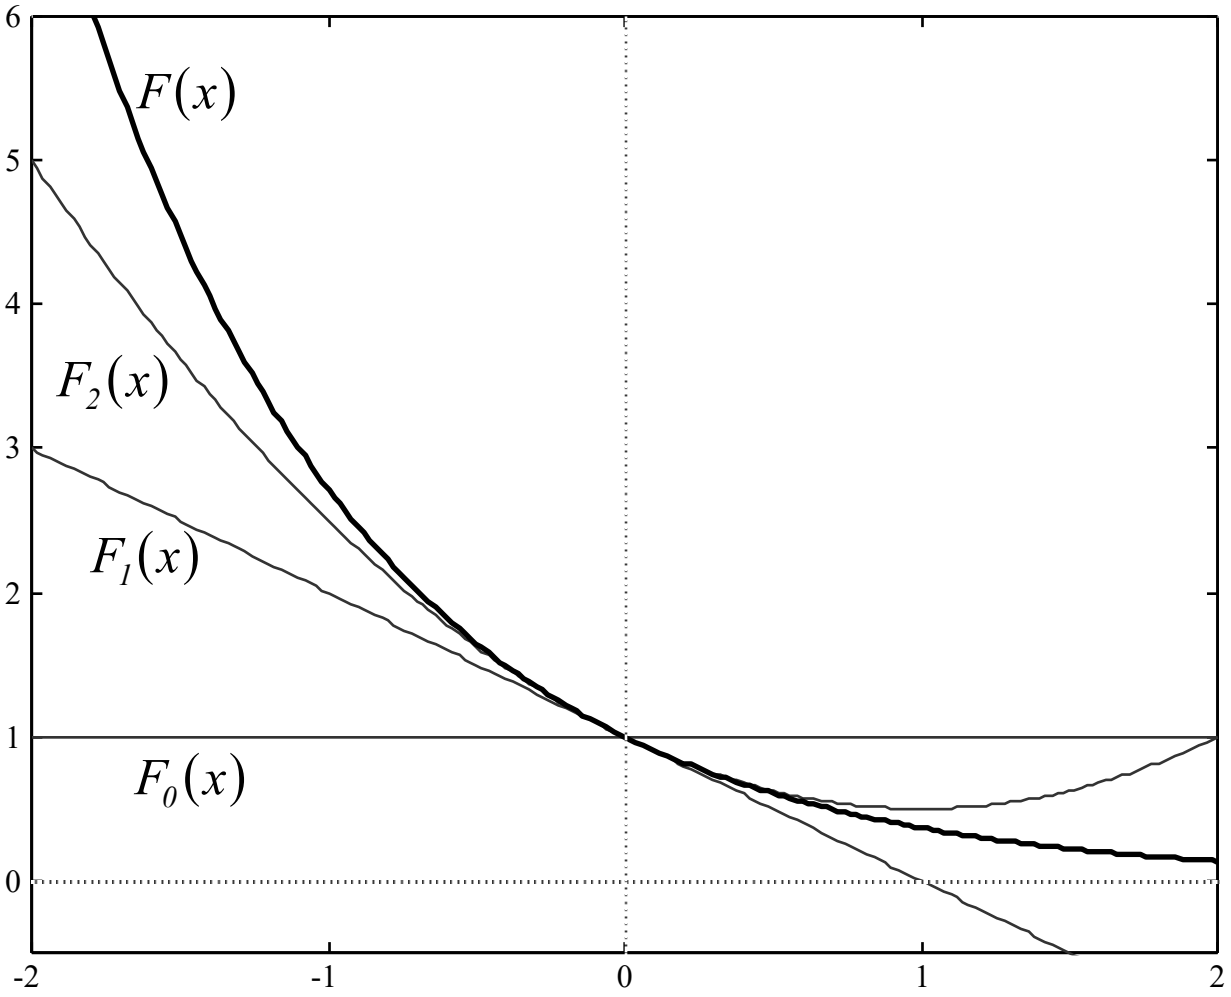
Aproksymacja $F(x)$ **skończoną liczbą wyrazów szeregu Taylor'a:**

$$F(x) = F_0(x) = 1$$

$$F(x) = F_1(x) = 1 - x$$

$$F(x) = F_2(x) = 1 - x + \frac{1}{2}x^2$$

Ilustracja graficzna:



Przykład 2 – skalarny:

$$F(x) = cos(x)$$

Rozwinięcie w szereg Taylor'a w otoczeniu $x^* = 0$

$$F(x) = cos\,(x) = cos\,(0) - sin\,(0)(x-0) - \frac{1}{2}cos\,(0)(x-0)^2 + \frac{1}{6}sin\,(0)(x-0)^3 + \cdots$$

$$F(x) = 1 - \frac{1}{2}x^2 + \frac{1}{24}x^4 + \cdots$$

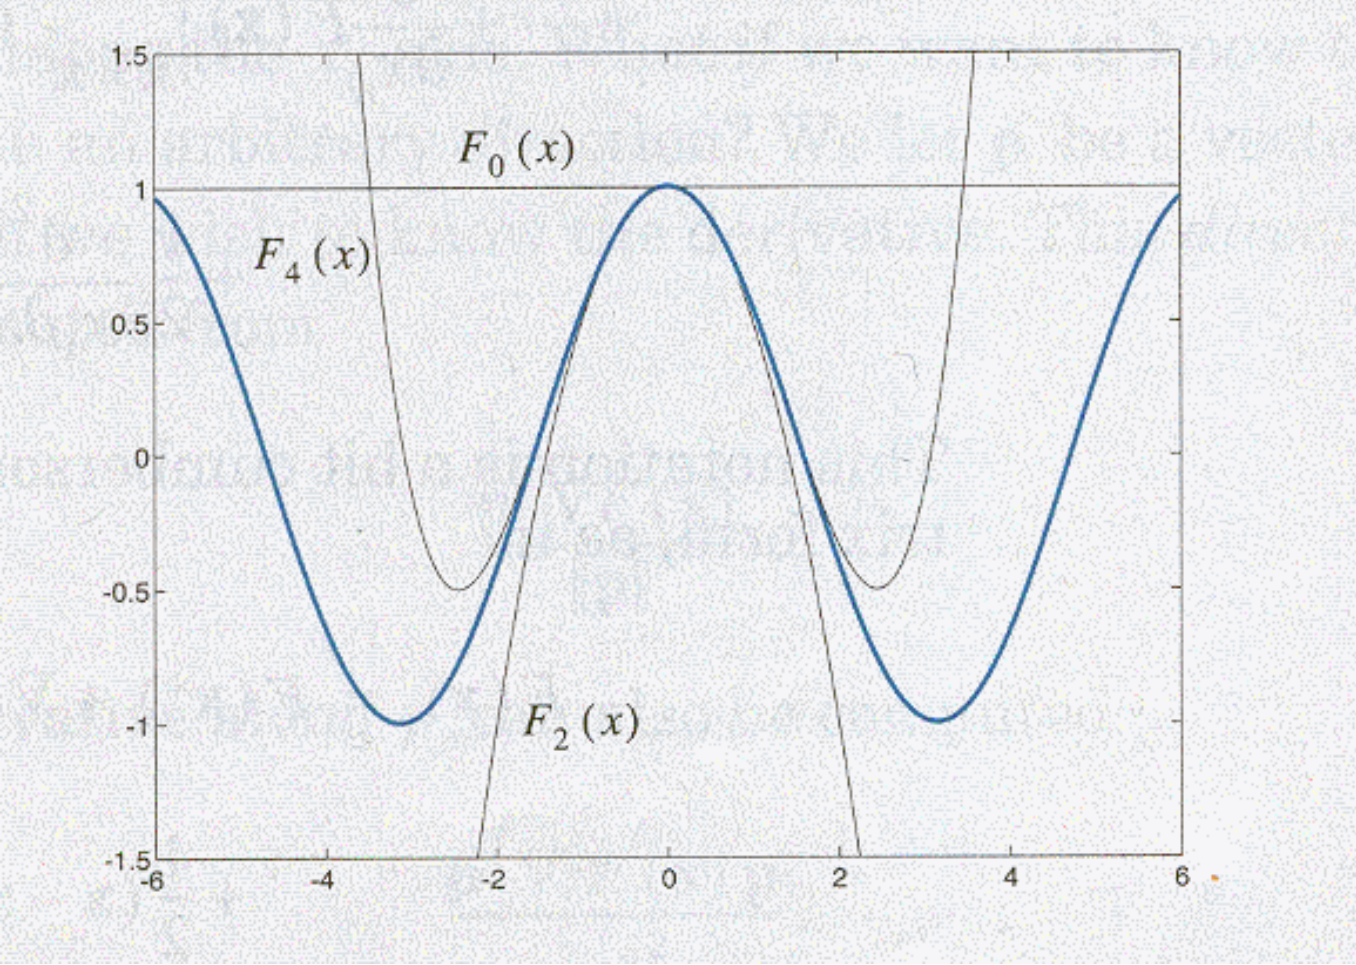
Aproksymacja $F(x)$ **skończoną liczbą wyrazów szeregu Taylor'a:**

$$F(x) = F_0(x) = 1$$

$$F(x) = F_2(x) = 1 - \frac{1}{2}x^2$$

$$F(x) = F_4(x) = 1 - \frac{1}{2}x^2 + \frac{1}{24}x^4$$

Ilustracja graficzna:



Jeżeli przyjąć oznaczenia:

jakobian - gradient funkcjonału

$$\nabla F(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial}{\partial x_1} F(\boldsymbol{x}) \\ \vdots \\ \frac{\partial}{\partial x_i} F(\boldsymbol{x}) \\ \vdots \\ \frac{\partial}{\partial x_n} F(\boldsymbol{x}) \end{bmatrix}$$

Warto pamiętać, że:

- Kierunek gradientu w punkcie x pokrywa się z kierunkiem normalnej do powierzchni stałej wartości funkcjonału przechodzącej przez punkt x.
- Zwrot gradientu w punkcie x odpowiada zwrotowi najszybszego wzrostu wartości funkcjonału w otoczeniu punktu x.

$$\nabla^2 F(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial^2}{\partial x_1^2} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_1 \partial x_i} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_1 \partial x_n} F(\boldsymbol{x}) \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2}{\partial x_i \partial x_1} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_i^2} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_i \partial x_n} F(\boldsymbol{x}) \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2}{\partial x_n \partial x_1} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_n \partial x_i} F(\boldsymbol{x}) & \cdots & \frac{\partial^2}{\partial x_n^2} F(\boldsymbol{x}) \end{bmatrix}$$

hessian funkcjonału

Postać macierzowa szeregu Taylor'a:

$$F(\boldsymbol{x}) = F(\boldsymbol{x}^*) + \nabla F(\boldsymbol{x})^T \Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (\boldsymbol{x} - \boldsymbol{x}^*)$$

$$+ \frac{1}{2} (\boldsymbol{x} - \boldsymbol{x}^*)^T \nabla^2 F(\boldsymbol{x}) \Big|_{\boldsymbol{x}=\boldsymbol{x}^*} (\boldsymbol{x} - \boldsymbol{x}^*) + \cdots$$

Pierwsza pochodna (nachylenie) funkcjonału $F(\boldsymbol{x})$ wzdłuż osi x_i :

$$\frac{\partial F(\boldsymbol{x})}{\partial x_i}$$ - i-ty element gradientu

Druga pochodna (krzywizna) funkcjonału $F(\boldsymbol{x})$ wzdłuż osi x_i :

$$\frac{\partial^2 F(\boldsymbol{x})}{\partial x_i^2}$$ - (i,i)-ty element hessianu

Pierwsza pochodna (nachylenie) funkcjonału $F(\boldsymbol{x})$ wzdłuż wektora $\boldsymbol{p}$:

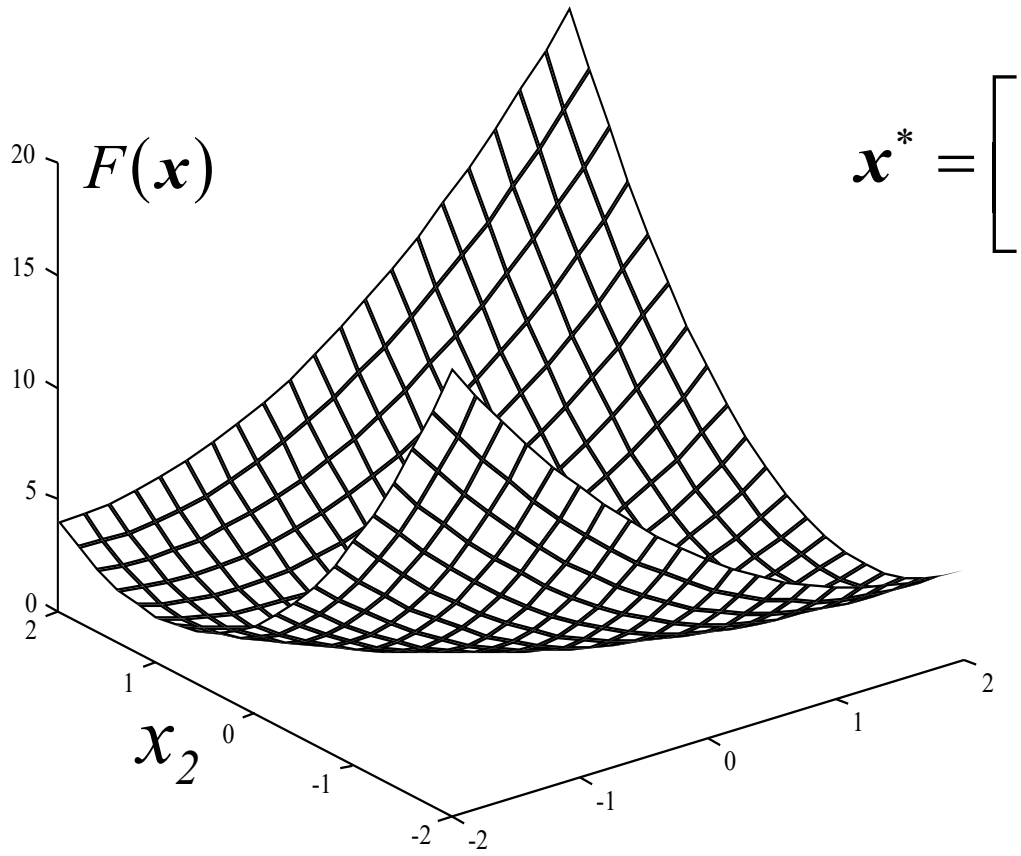
$$\nabla_{\boldsymbol{p}} F(\boldsymbol{x}) = \frac{\boldsymbol{p}^T \nabla F(\boldsymbol{x})}{\| \boldsymbol{p} \|}$$

Druga pochodna (krzywizna) funkcjonału $F(\boldsymbol{x})$ wzdłuż wektora $\boldsymbol{p}$:

$$\nabla_{\boldsymbol{p}}^2 F(\boldsymbol{x}) = \frac{\boldsymbol{p}^T \nabla^2 F(\boldsymbol{x}) \boldsymbol{p}}{\| \boldsymbol{p} \|^2}$$

Przykład 3:

$$F(\boldsymbol{x}) = x_1^2 + 2x_1x_2 + 2x_2^2$$



$$\boldsymbol{x}^* = \begin{bmatrix} 0.5 \\ 0 \end{bmatrix} \qquad \boldsymbol{p} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Ilustracja graficzna:

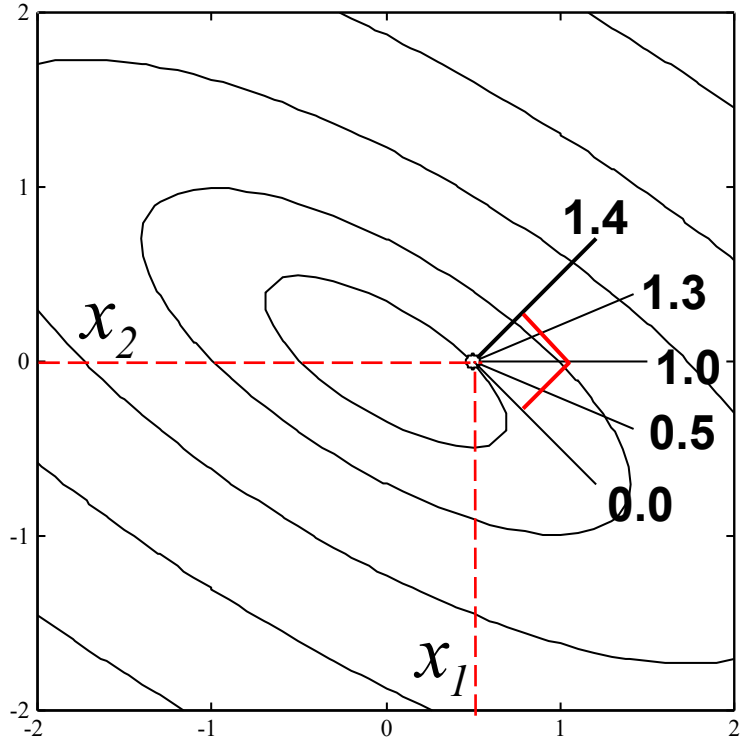
$$\nabla F(\boldsymbol{x})\big|_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} \dfrac{\partial}{\partial x_1} F(\boldsymbol{x}) \\ \dfrac{\partial}{\partial x_2} F(\boldsymbol{x}) \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 2x_1 + 2x_2 \\ 2x_1 + 4x_2 \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Pochodne kierunkowe:

$$\frac{\boldsymbol{p}^T \nabla F(\boldsymbol{x})}{\|\boldsymbol{p}\|} = \frac{\begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix}}{\left\| \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\|} = \frac{[0]}{\sqrt{2}} = 0$$

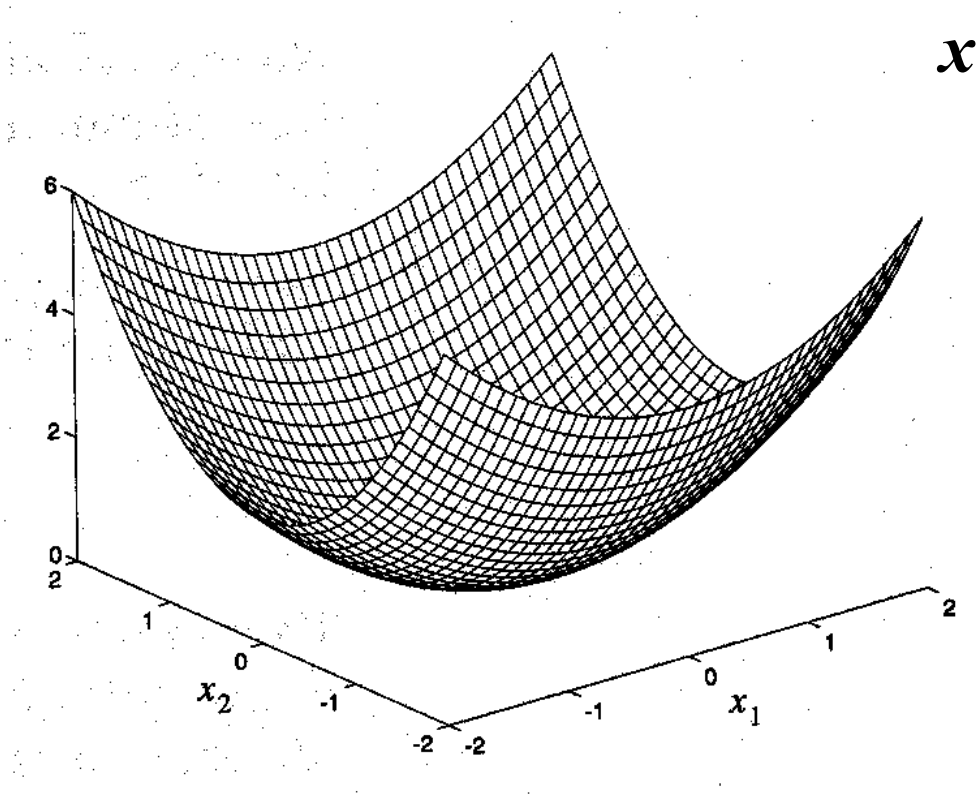
$$\frac{\nabla F(\boldsymbol{x})^T \nabla F(\boldsymbol{x})}{\|\nabla F(\boldsymbol{x})\|} = \frac{\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix}}{\left\| \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\|} = \frac{[2]}{\sqrt{2}} = \sqrt{2} \approx 1.4$$

Pochodne kierunkowe:



Przykład 4:

$$F(\boldsymbol{x}) = x_1^2 + 2x_2^2$$



$$\boldsymbol{x}^* = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix} \qquad \boldsymbol{p} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$$

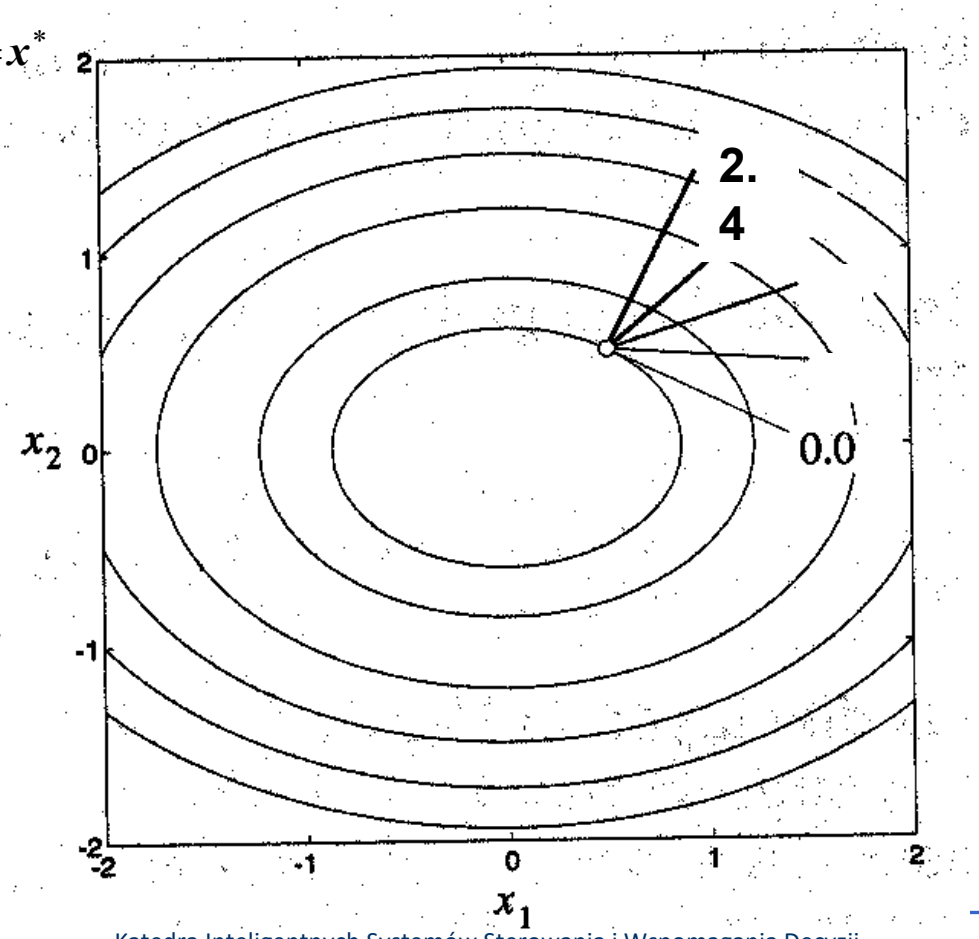
Ilustracja graficzna:

$$\nabla F(\boldsymbol{x})\big|_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} \dfrac{\partial}{\partial x_1} F(\boldsymbol{x}) \\ \dfrac{\partial}{\partial x_2} F(\boldsymbol{x}) \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

Pochodne kierunkowe:

$$\frac{\boldsymbol{p}^T \nabla F(\boldsymbol{x})}{\|\boldsymbol{p}\|} = \frac{\begin{bmatrix} 2 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix}}{\left\| \begin{bmatrix} 2 \\ -1 \end{bmatrix} \right\|} = \frac{[0]}{\sqrt{5}} = 0$$

$$\frac{\nabla F(\boldsymbol{x})^T \nabla F(\boldsymbol{x})}{\|\nabla F(\boldsymbol{x})\|} = \frac{\begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix}}{\left\| \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\|} = \frac{[5]}{\sqrt{5}} = \sqrt{5} \approx 2.4$$



Optymalność

Minimum globalne:

Punkt $\boldsymbol{x}^*$ jest unikatowym minimum globalnym funkcjonału $F(\boldsymbol{x})$,

jeżeli zachodzi $F(\boldsymbol{x}^*) < F(\boldsymbol{x}^* + \Delta\boldsymbol{x})$ dla wszystkich $\Delta\boldsymbol{x} \neq \boldsymbol{0}$

Minimum silne (lokalne):

Punkt $\boldsymbol{x}^*$ jest minimum silnym (lokalnym) funkcjonału $F(\boldsymbol{x})$,

jeżeli istnieje skalar $\delta > 0$, taki, że zachodzi $F(\boldsymbol{x}^*) < F(\boldsymbol{x}^* + \Delta\boldsymbol{x})$

dla wszystkich $\Delta\boldsymbol{x}$ takich, że $0 < \| \boldsymbol{x} \| < \delta$

Minimum słabe (lokalne):

Punkt $\boldsymbol{x}^*$ jest minimum słabym (lokalnym) funkcjonału $F(\boldsymbol{x})$, jeżeli

nie jest minimum silnym, a istnieje skalar $\delta > 0$, taki, że zachodzi

$F(\boldsymbol{x}^*) \leq F(\boldsymbol{x}^* + \Delta\boldsymbol{x})$ dla wszystkich $\Delta\boldsymbol{x}$ takich, że $0 < \| \boldsymbol{x} \| < \delta$

Przykład 5:

$$F(\boldsymbol{x}) = 3x^4 - 7x^2 - \frac{1}{2}x + 6$$

Minima lokalne silne

$x \approx 1.1$

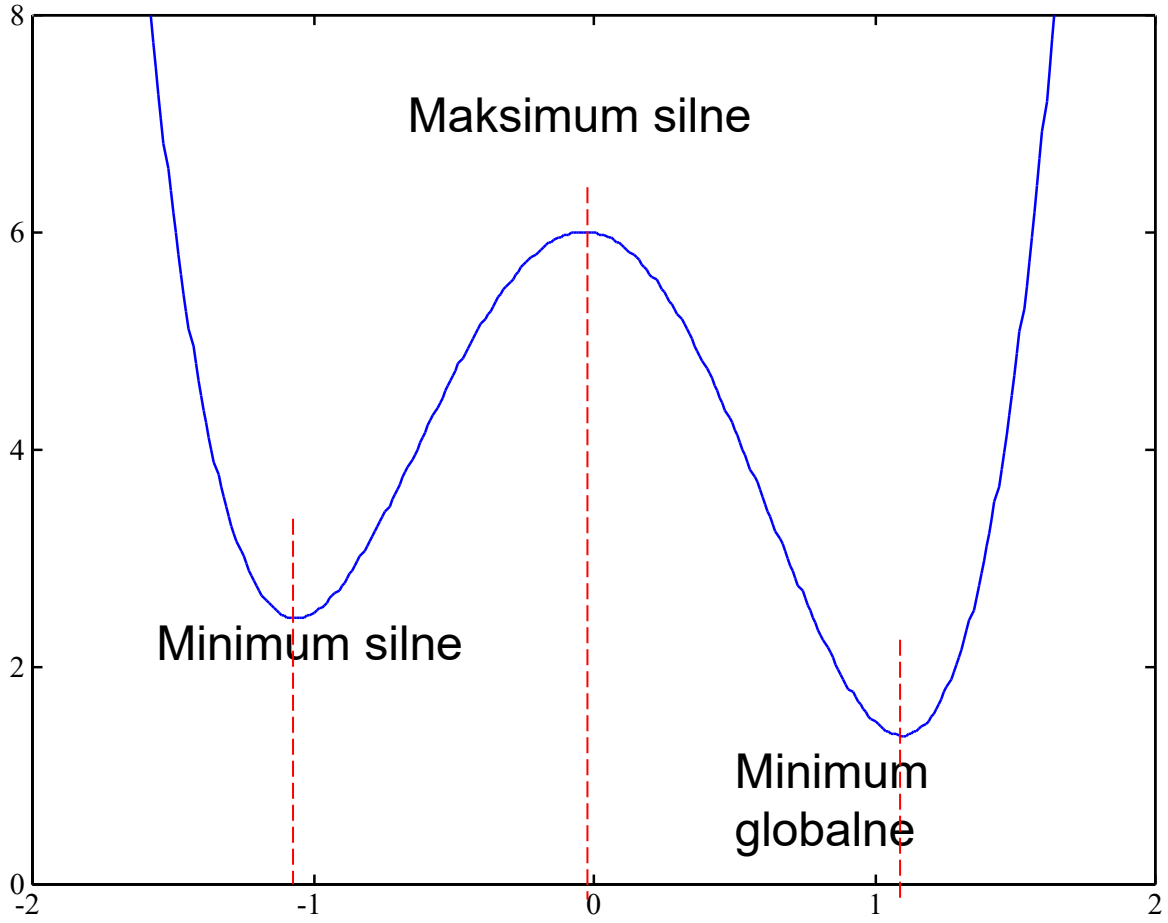
$x \approx -1.1$

Minimum globalne

$x \approx 1.1$

Maksimum lokalne silne

$x = 0$



Przykład 6 - wektorowy:

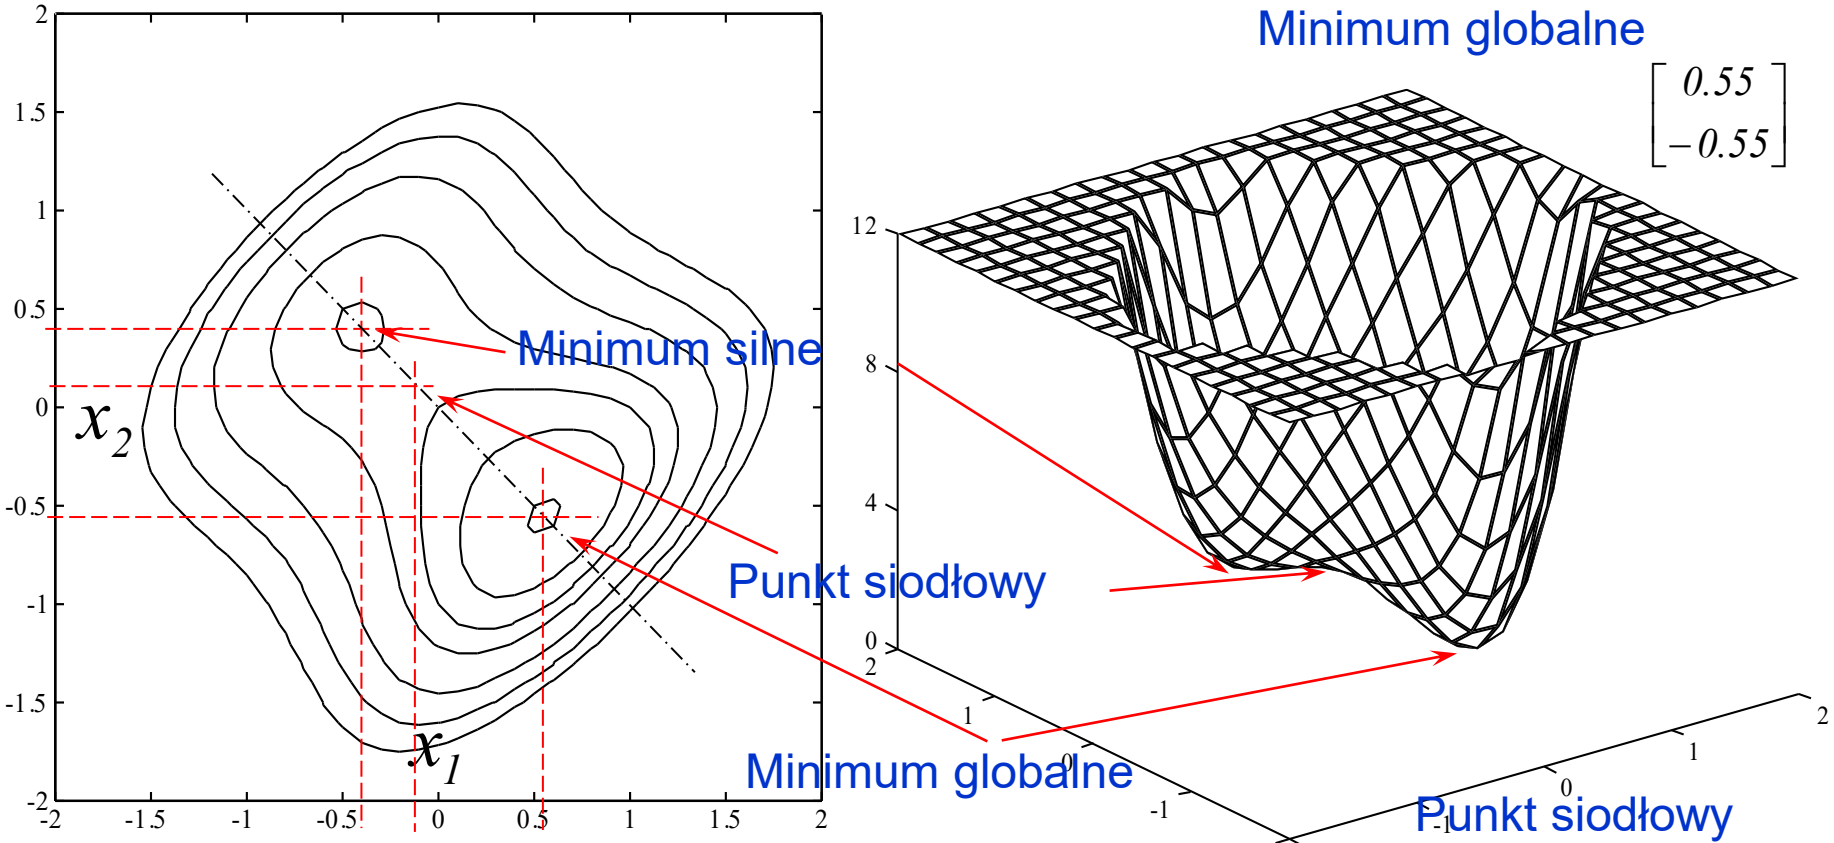
$$F(\boldsymbol{x}) = (x_2 - x_1)^4 + 8x_1x_2 - x_1 + x_2 + 3$$

Minima lokalne silne

$$\begin{bmatrix} -0.42 \\ 0.42 \end{bmatrix}; \begin{bmatrix} 0.55 \\ -0.55 \end{bmatrix}$$

Minimum globalne

$$\begin{bmatrix} 0.55 \\ -0.55 \end{bmatrix}$$



$$\begin{bmatrix} -0.13 \\ 0.13 \end{bmatrix}$$

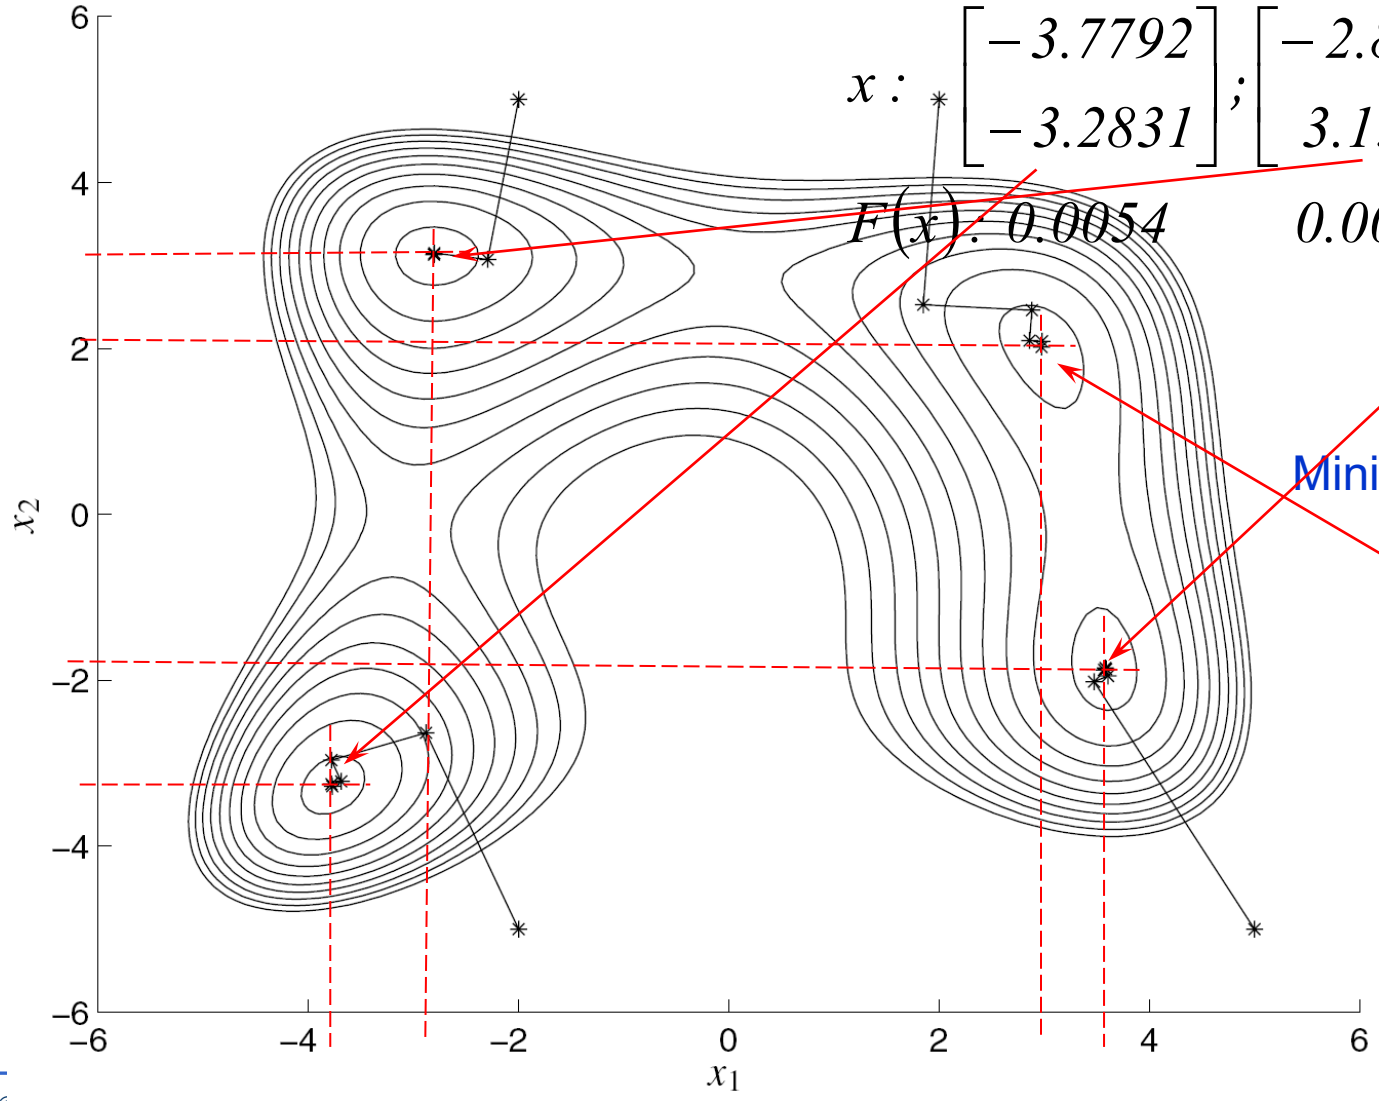
Przykład 7 - wektorowy:

$$F(\boldsymbol{x}) = \left(x_1^2 + x_2 - 11\right)^2 + \left(x_1 + x_2^2 - 7\right)^2$$

Minima lokalne silne

$$x: \begin{bmatrix} -3.7792 \\ -3.2831 \end{bmatrix}; \begin{bmatrix} -2.8051 \\ 3.1313 \end{bmatrix}; \begin{bmatrix} 3.5843 \\ -1.8483 \end{bmatrix}$$

$$F(x): 0.0054 \qquad 0.0085 \qquad 0.0011$$



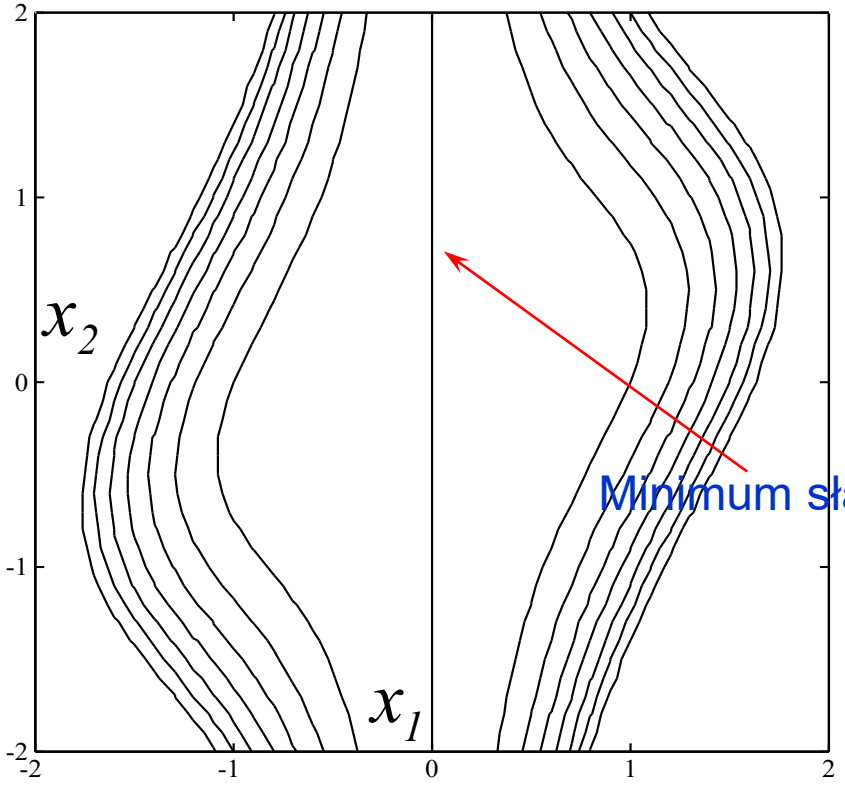
Minimum globalne

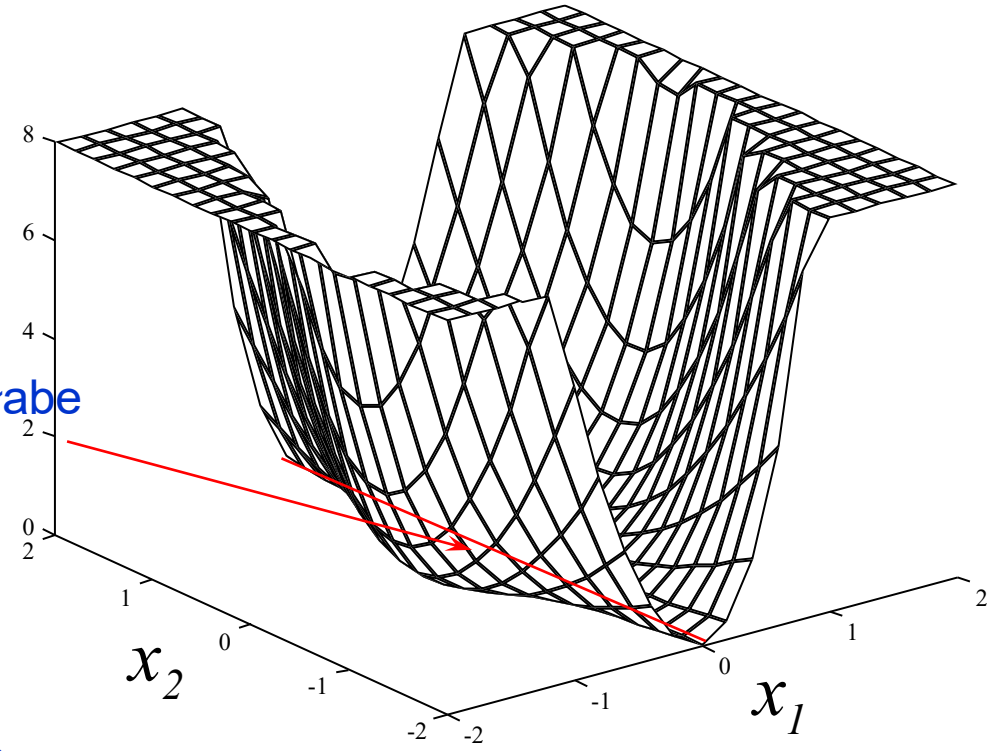
$$x: \begin{bmatrix} 3 \\ 2 \end{bmatrix}$$

$$F(x): 0$$

Przykład 8 - wektorowy:

$$F(\boldsymbol{x}) = \left(x_1^2 - 1.5x_1x_2 + 2x_2^2\right)x_1^2$$





Minimum lokalne słabe

wzdłuż prostej $x_1 = 0$

Warunki konieczne minimum

Rozwinięcie $F(\boldsymbol{x})$ w szereg Taylor'a w otoczeniu $\boldsymbol{x}^*$, takiego, że $\boldsymbol{x} = \boldsymbol{x}^* + \Delta\boldsymbol{x}$

$$F(\boldsymbol{x}) = F(\boldsymbol{x}^* + \Delta\boldsymbol{x}) = F(\boldsymbol{x}^*) + \nabla F(\boldsymbol{x})^T \Big|_{\boldsymbol{x}=\boldsymbol{x}^*} \Delta\boldsymbol{x}$$

$$+ \frac{1}{2} \Delta\boldsymbol{x}^T \nabla^2 F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{x}^*} \Delta\boldsymbol{x} + \cdots$$

Warunki konieczne minimum

Warunek pierwszego rzędu:

Jeżeli x^* jest punktem lokalnego minimum i F jest różniczkowalne w sposób ciągły w otwartym otoczeniu x^*, wówczas

$$\nabla F(\boldsymbol{x})\big|_{\boldsymbol{x}=\boldsymbol{x}^*} = \boldsymbol{0}$$

Optymalność

Warunek drugiego rzędu:

Jeżeli x^* jest punktem lokalnego minimum i $\nabla^2 F$ jest ciągłe w pewnym otwartym otoczeniu x^*, wówczas

$$\nabla F(\boldsymbol{x})\big|_{\boldsymbol{x}=\boldsymbol{x}^*} = \boldsymbol{0}$$

$$\Delta \boldsymbol{x}^T \nabla^2 F(\boldsymbol{x})^T \Big|_{\boldsymbol{x}=\boldsymbol{x}^*} \Delta \boldsymbol{x} \geq \boldsymbol{0} \quad \text{dla dowolnych} \quad \Delta \boldsymbol{x}$$

Przykład 9:

$$F(\boldsymbol{x}) = x_1^4 + x_2^2$$

Warunek punkt stacjonarnego

$$\nabla F(\boldsymbol{x}) = \begin{bmatrix} 4x_1^3 \\ 2x_2 \end{bmatrix} = \boldsymbol{0}$$

Punkt stacjonarny - jedyny

$$\boldsymbol{x}^* = \boldsymbol{0}$$

Sprawdzenie warunków rzędu drugiego

$$\nabla^2 F(\boldsymbol{x}) = \begin{bmatrix} \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_1^2} & \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_1 \partial x_2} \\ \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_2 \partial x_1} & \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_2^2} \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{0}} = \begin{bmatrix} 12x_1^2 & 0 \\ 0 & 2 \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{0}} = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$$

Optymalność

$$\Delta \boldsymbol{x}^T \nabla^2 F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{0}} \Delta \boldsymbol{x} = \begin{bmatrix} \Delta x_1 & \Delta x_2 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix}$$

$$= \begin{bmatrix} 0 & 2\Delta x_2 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix} = \begin{bmatrix} 2\Delta x_2^2 \end{bmatrix} > 0$$

Punkt $x^*=0$ spełnia warunki konieczne pierwszego i drugiego rzędu dla minimum

Optymalność

Warunki określoności macierzy hessianu można badać przez sprawdzenie wartości własnych tej macierzy

Macierz hessianu jest dodatnio określona, jeżeli wszystkie jej wartości własne są dodatnie

Macierz hessianu jest dodatnio półokreślona, jeżeli wszystkie jej wartości własne są nieujemne

Przykład 10:

$$F(\boldsymbol{x}) = x_1^2 + 2x_1x_2 + 2x_2^2 + x_1$$

Warunek punkt stacjonarnego

Punkt stacjonarny - jedyny

$$\nabla F(\boldsymbol{x}) = \begin{bmatrix} 2x_1 + 2x_2 + 1 \\ 2x_1 + 4x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow \boldsymbol{x}^* = \begin{bmatrix} -1 \\ 0.5 \end{bmatrix}$$

Sprawdzenie warunków rzędu drugiego

$$\nabla^2 F(\boldsymbol{x}) = \begin{bmatrix} \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_1^2} & \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_1 \partial x_2} \\ \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_2 \partial x_1} & \dfrac{\partial^2 F(\boldsymbol{x})}{\partial x_2^2} \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 2 & 2 \\ 2 & 4 \end{bmatrix}_{\boldsymbol{x}=\boldsymbol{x}^*} = \begin{bmatrix} 2 & 2 \\ 2 & 4 \end{bmatrix}$$

Pozyskanie informacji o określoności macierzy hessianu

$$\Delta \boldsymbol{x}^T \nabla^2 F(\boldsymbol{x})\Big|_{\boldsymbol{x}=\boldsymbol{0}} \Delta \boldsymbol{x} = \begin{bmatrix} \Delta x_1 & \Delta x_2 \end{bmatrix} \begin{bmatrix} 2 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix}$$

$$= \begin{bmatrix} 2\Delta x_1 + 2\Delta x_2 & 2\Delta x_1 + 4\Delta x_2 \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \end{bmatrix}$$

$$= \begin{bmatrix} (2\Delta x_1 + 2\Delta x_2)\Delta x_1 + (2\Delta x_1 + 4\Delta x_2)\Delta x_2 \end{bmatrix}$$

$$= \begin{bmatrix} 2\Delta x_1^2 + 4\Delta x_1 \Delta x_2 + 4\Delta x_2^2 \end{bmatrix}$$

Nie można stwierdzić czy macierz hessianu jest dodatnio określona lub dodatnio półokreślona

Wartości własne hessianu

$$\left|\nabla^2 F(\boldsymbol{x}) - \lambda \boldsymbol{I}\right| = \left|\begin{bmatrix} 2-\lambda & 2 \\ 2 & 4-\lambda \end{bmatrix}\right| = (2-\lambda)(4-\lambda) - 4$$

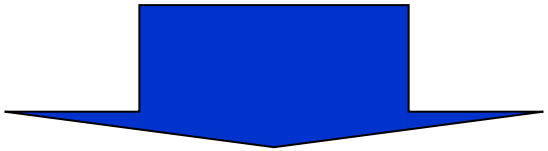
$$= \lambda^2 - 6\lambda + 4 = 0$$

$$\Delta = 36 - 16 = 20 \quad \sqrt{\Delta} = \sqrt{20} \cong 4.47$$

$$\lambda_1 = \frac{6 - 4.47}{2} = \frac{1.53}{2} = 0.765 \quad \lambda_2 = \frac{6 + 4.47}{2} = \frac{10.47}{2} = 5.235$$

Optymalność

$$\lambda_1 = 0.765 > 0 \quad \lambda_2 = 5.235 > 0$$



Minimum silne w $\boldsymbol{x}^* = \begin{bmatrix} -1 \\ 0.5 \end{bmatrix}$

Warunki wystarczające minimum

Warunek drugiego rzędu:

Jeżeli dla pewnego x^*, $\nabla^2 F$ jest ciągłe w pewnym otwartym jego otoczeniu i $\nabla F(x^*) = 0$ i $\nabla^2 F(x^*)$ jest dodatnio określona, wówczas x^* jest silnym minimum lokalnym

Warunek globalnego minimum

Jeżeli F jest funkcją wypukłą (a nawet tylko pseudowypukłą), wówczas każde minimum lokalne jest minimum globalnym. Jeżeli dodatkowo F jest różniczkowalna, wówczas każdy punkt stacjonarny jest globalnym minimum

Forma kwadratowa

$$F(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T \boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}^T \boldsymbol{x} + c$$

gdzie: A - macierz symetryczna; (jeżeli macierz A nie jest symetryczna, to może być zastąpiona przez macierz symetryczną dającą te same wartości F(x) - to samo przekształcenie F(x))

Pożyteczne właściwości gradientu:

$$\nabla\left(\boldsymbol{h}^T \boldsymbol{x}\right) = \nabla\left(\boldsymbol{x}^T \boldsymbol{h}\right) = \boldsymbol{h}$$ gdzie $\boldsymbol{h}$ jest stałym wektorem

$$\nabla\left(\boldsymbol{x}^T \boldsymbol{Q}\,\boldsymbol{x}\right) = \boldsymbol{Q}\,\boldsymbol{x} + \boldsymbol{Q}^T\,\boldsymbol{x} = 2\boldsymbol{Q}\,\boldsymbol{x}$$ dla symetrycznych $\boldsymbol{Q}$

Forma kwadratowa

Gradient formy kwadratowej

$$\nabla F(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}$$

Hessian formy kwadratowej

$$\nabla^2 F(\boldsymbol{x}) = \boldsymbol{A}$$

Słuszne są twierdzenia:

- Jeżeli wartości własne hessianu są wszystkie dodatnie – forma posiada pojedyncze silne minimum
- Jeżeli wartości własne hessianu są wszystkie ujemne – forma posiada pojedyncze silne maksimum
- Jeżeli pewne wartości własne hessianu są dodatnie, a inne ujemne – forma posiada pojedynczy punkt siodłowy
- Jeżeli wszystkie wartości własne hessianu są nieujemne, ale niektóre są równe zeru – forma albo posiada słabe minimum albo nie ma punktu stacjonarnego
- Jeżeli wszystkie wartości własne hessianu są niedodatnie, ale niektóre są równe zeru – forma albo posiada słabe maksimum albo nie ma punktu stacjonarnego

Koniec zestawu slajdów