

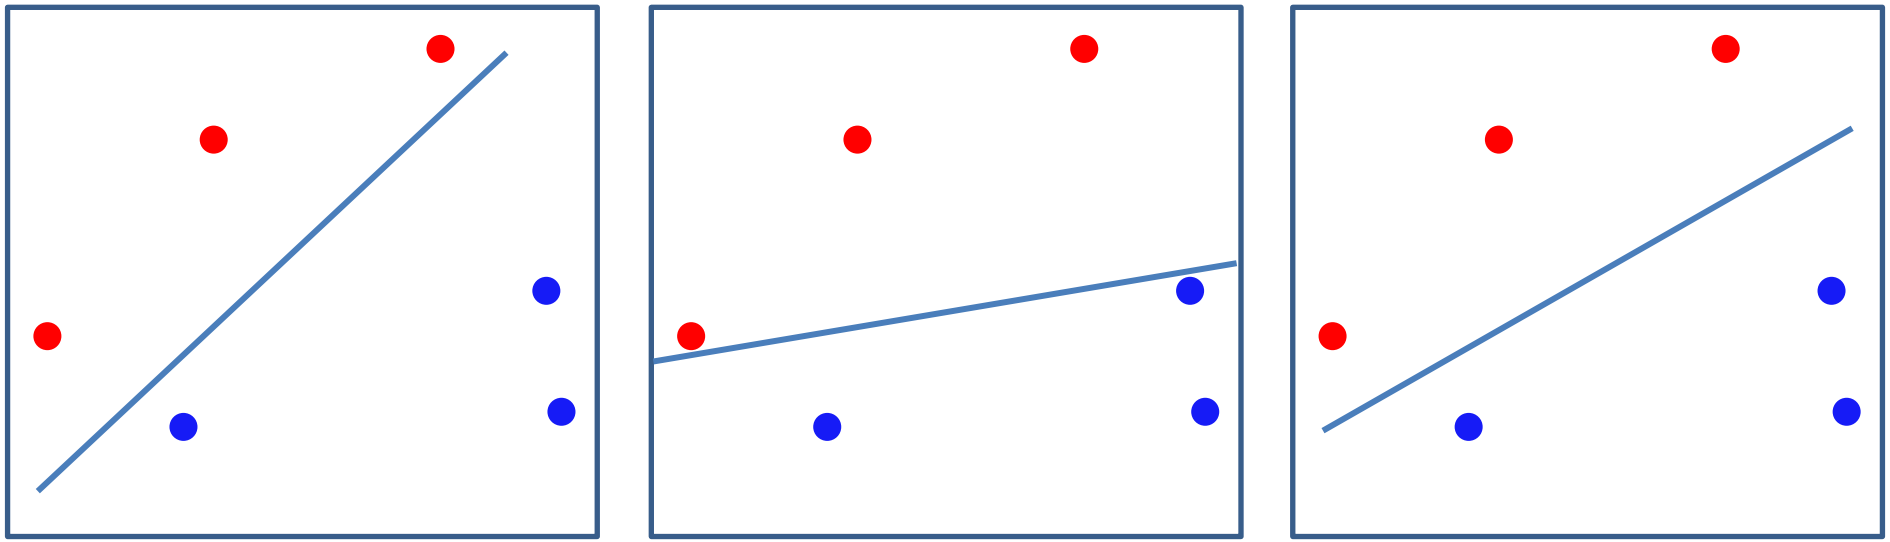
Modelowanie i identyfikacja

Wykład 14: Maszyny Wektorów Nośnych (Support Vector Machines - SVM)

Wydział Elektrotechniki i Automatyki
Katedra Inteligentnych Systemów Sterowania i Wspomagania Decyzji
dr hab. inż. Michał Grochowski

Charakterystyka problemu

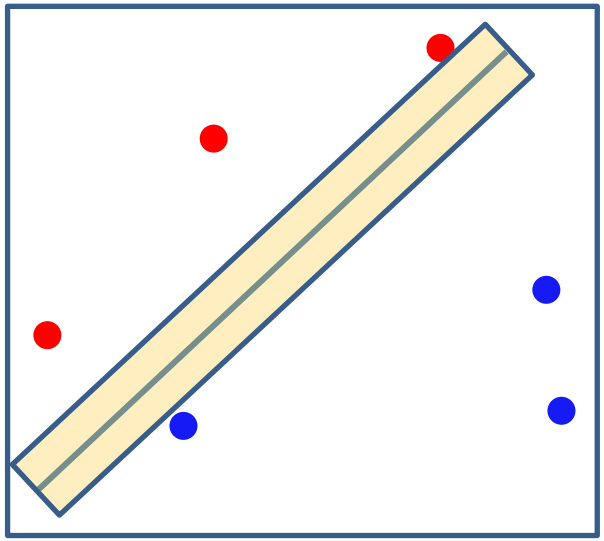
Jak rozdzielić dane ??

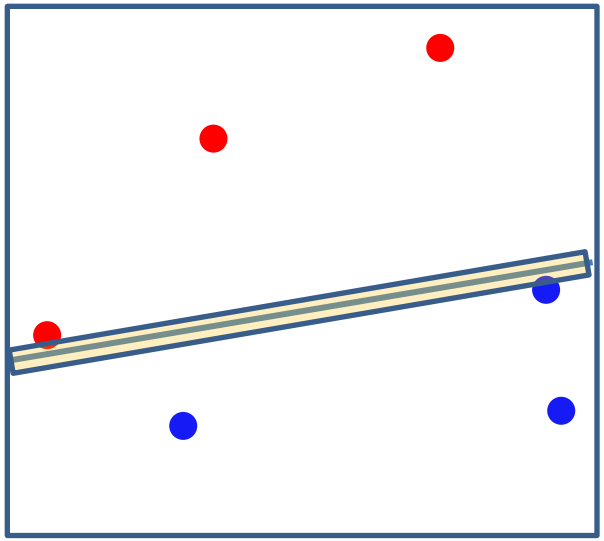


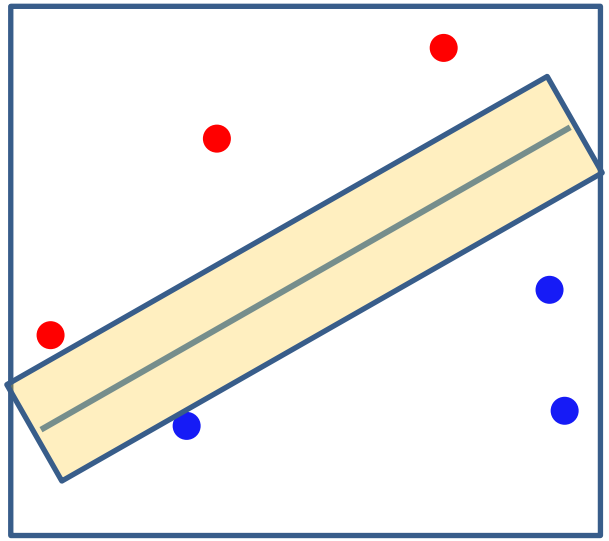
Nieskończenie wiele możliwości !!!

Charakterystyka problemu

Który margines jest najlepszy ??





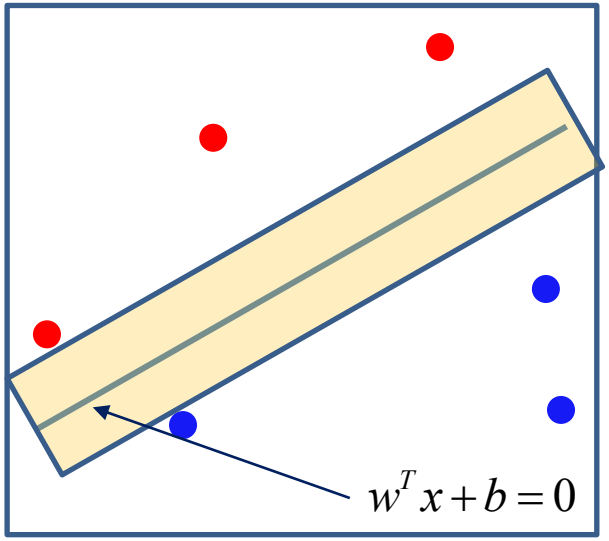


Która z linii maksymalizuje ten margines ??

Charakterystyka problemu

Niech: $\{(x_i, y_i)\}_{i=1}^{N}$ oznacza zbiór danych,

gdzie x_i jest wzorcem wejściowym, a y_i oznacza przynależność *i* -tego wejścia do danej klasy, „+1” lub „-1”.



Załóżmy (na chwilę) że punkty są liniowo separowalne.

Linia (płaszczyzna, hiperpłaszczyzna) decyzyjna opisana jest zależnością:

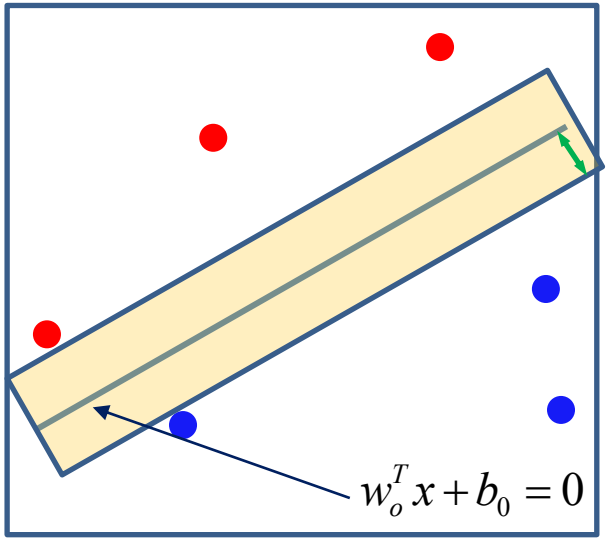
$$w^T x + b = 0 \tag{1}$$

gdzie ***x*** jest wektorem wejściowym, ***w*** jest „nastawialnym” wektorem (np. wag), ***b*** jest progiem.

Charakterystyka problemu

Możemy zapisać:

$$w^T x_i + b \geq 0 \qquad dla \qquad y_i = +1$$
$$w^T x_i + b < 0 \qquad dla \qquad y_i = -1$$



(2)

Optymalna linia (płaszczyzna, hiperpłaszczyzna) decyzyjna maksymalizująca margines ρ opisana jest zależnością:

$$w_o^T x + b_0 = 0$$

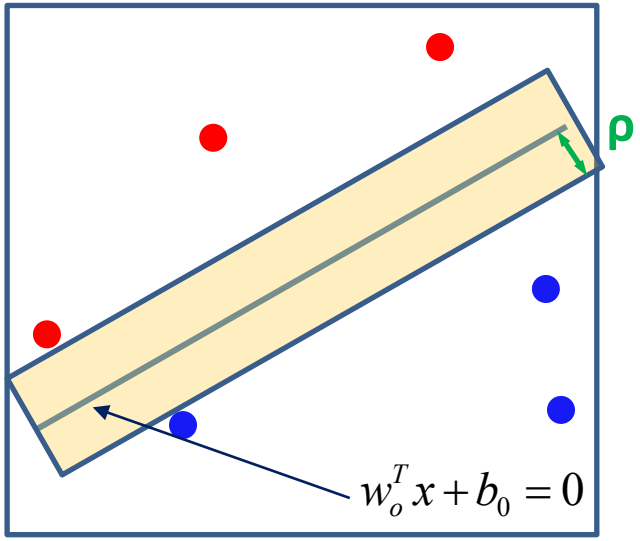
(3)

Nieco podstawowych przekształceń ...

$$w^T x_i + b \geq 0 \quad dla \quad y_i = +1$$
$$w^T x_i + b < 0 \quad dla \quad y_i = -1$$

Wiemy że (z (2)):

$$\left| w^T x + b \right| \geq 0 \tag{4}$$



Możemy więc przyjąć że (normalizacja):

$$\left| w^T x + b \right| = 1 \tag{5}$$

Możemy więc zapisać:

$$w_o^T x_i + b_o \geq +1 \quad dla \quad y_i = +1$$
$$w_o^T x_i + b_o < -1 \quad dla \quad y_i = -1 \tag{6}$$

lub:

$$y_i (w_o^T x_i + b_o) = +1$$

Nieco podstawowych przekształceń …

Interpretacja geometryczna (intuicyjna)

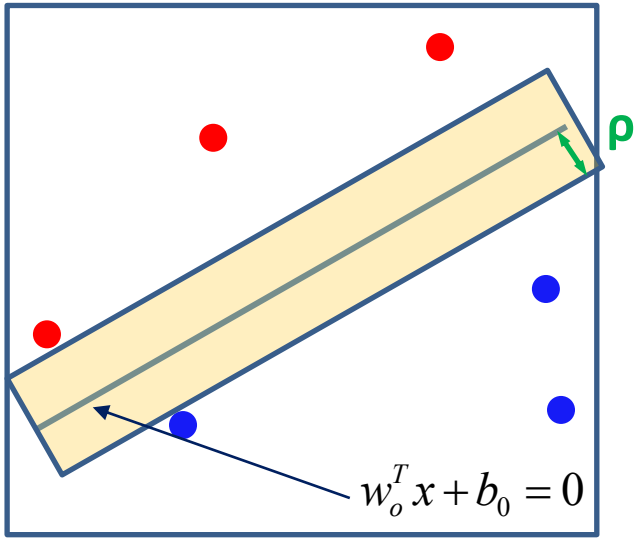
• Punkty z równaniem:

$$w^T x + b = +1 \text{ i } w^T x + b = -1$$

tworzą dwie równoległe hiperpłaszczyzny.

• Pomiędzy nimi znajduje się maksymalny margines. Płaszczyzna decyzyjna leży dokładnie pośrodku:

$$w^T x + b = 0$$



(4)

Nieco podstawowych przekształceń …

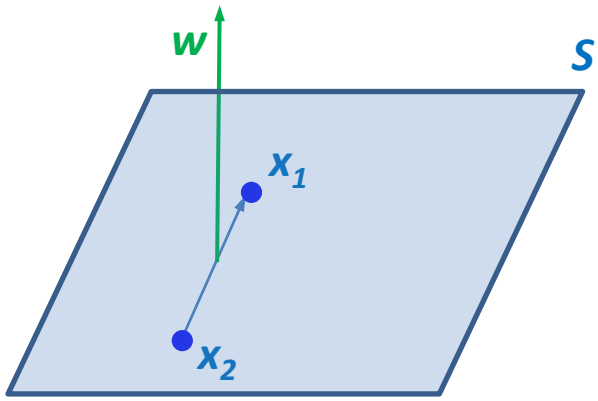
Odległość od płaszczyzny decyzyjnej

Niech x_i będzie punktem leżącym najbliżej płaszczyzny: $w^T x + b = 0$

oraz: $\left| w^T x + b \right| = 1$



Wektor ***w*** jest prostopadły do płaszczyzny ***S*** w przestrzeni wejść ***X***.



Dowolne punkty x_1 oraz x_2 należące do płaszczyzny ***S***, spełniają jej równanie, więc:

$$w^T x_1 + b = 0 \qquad w^T x_2 + b = 0$$

więc: $w^T (x_1 - x_2) = 0$

Stąd ***w*** jest ortogonalny do jakiegokolwiek wektora na płaszczyźnie ***S***

$$\left| w^T x + b \right| \geq 0$$

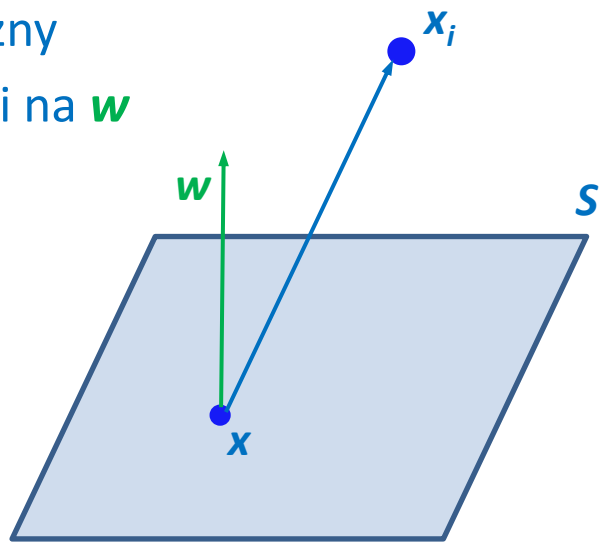
Nieco podstawowych przekształceń …

Odległość od płaszczyzny decyzyjnej

Odległość pomiędzy $\boldsymbol{x}_i$ i płaszczyzną:

… weźmy jakikolwiek punkt $\boldsymbol{x}$ należący do płaszczyzny

… utwórzmy wektor $\boldsymbol{x}_i - \boldsymbol{x}$ i dokonajmy jego projekcji na $\boldsymbol{w}$



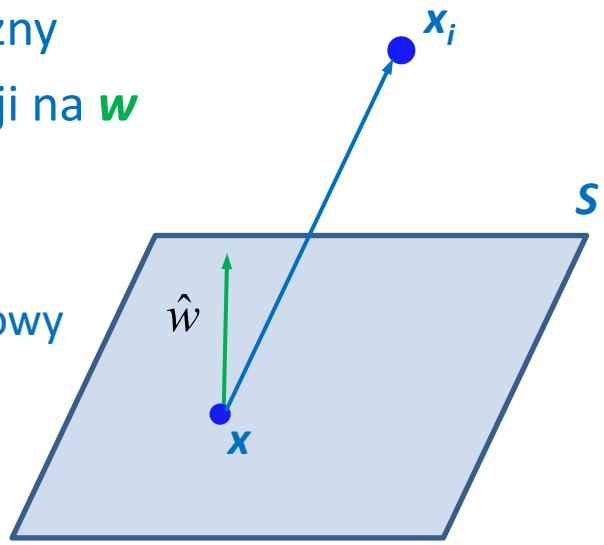
Nieco podstawowych przekształceń …

Odległość od płaszczyzny decyzyjnej

Odległość pomiędzy x_i i płaszczyzną (L):

… weźmy jakikolwiek punkt x należący do płaszczyzny

… utwórzmy wektor $x_i - x$ i dokonajmy jego projekcji na w



Matematyka …

$$\hat{w} = \frac{w}{\|w\|}$$

$\hat{w}$ - wektor jednostkowy

odległość L:

$$L = \left|\hat{w}^T (x_i - x)\right|$$

$$L = \frac{1}{\|w\|}\left|w^T x_i - w^T x\right| = \frac{1}{\|w\|}\left|w^T x_i + b - w^T x - b\right| = \frac{1}{\|w\|}$$

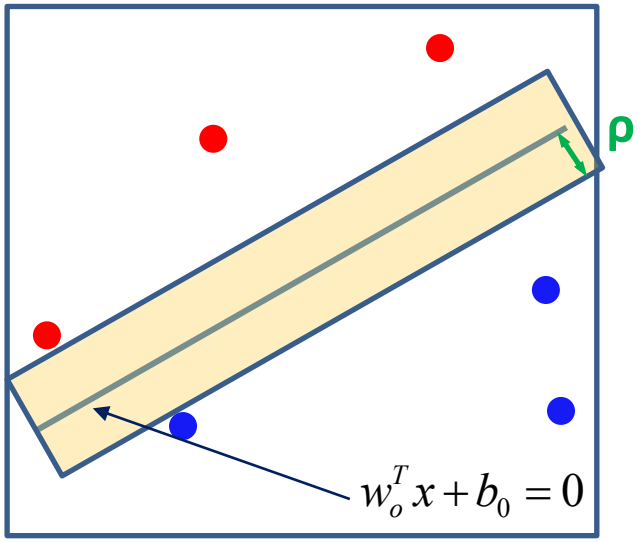
ponieważ:

$$\left|w^T x + b\right| = 0 \quad \text{oraz} \quad \left|w^T x_i + b\right| = 1$$

Problem optymalizacyjny

Zmaksymalizować odległość L = ρ

$$\max \frac{1}{\|w\|} = \min w^T w$$



Zadanie optymalizacji:

$$\min_{w \in R} \; g(w) = \frac{1}{2} w^T w$$

przy ograniczeniach (z równania 6):

$$y_i (w^T x_i + b) \geq 1 \qquad dla \qquad i = 1, 2, ..., N$$

gdzie:

$$w \in R^d, \; b \in R$$

Problem optymalizacyjny

Problem optymalizacji kwadratowej z ograniczeniami - liniowo kwadratowy

Zadanie optymalizacji (kwadratowej, g(w) jest wypukła):

$$\min_{w \in R} \; g(w) = \frac{1}{2} w^T w$$

przy ograniczeniach (liniowych względem ***w***):

$$y_i (w^T x_i + b) \geq 1 \qquad dla \qquad i = 1, 2, ..., N$$

Tak sformułowany problem jest prymalnym zagadnieniem optymalizacyjnym.

Możemy go rozwiązać stosując metodę mnożników Lagranga
oraz warunków Kukna – Tuckera (lub Karush – Kukna – Tuckera, w skrócie *KKT*).

Problem optymalizacyjny

Sformułowanie prymalne

Funkcja Lagranga:

$$L(w,b,\lambda)=\frac{1}{2}w^T w-\sum_{i=1}^{N}\lambda_i\left[y_i\left(w^T x_i+b\right)-1\right]$$

λ_i - mnożniki Lagranga

Minimalizujemy względem ***w*** oraz ***b***,
a jednocześnie maksymalizujemy względem $\boldsymbol{\lambda}$ $(\lambda_i \geq 0)$!!!

Warunki optymalności:

$$\frac{\delta L(w,b,\lambda)}{\delta w}=0$$

$$\frac{\delta L(w,b,\lambda)}{\delta b}=0$$

stąd:

$$w=\sum_{i=1}^{N}\lambda_i y_i x_i \quad \text{oraz} \quad \sum_{i=1}^{N}\lambda_i y_i=0$$

Problem optymalizacyjny

Sformułowanie dualne

Możemy podstawić:

$$w = \sum_{i=1}^{N} \lambda_i y_i x_i \quad \text{oraz} \quad \sum_{i=1}^{N} \lambda_i y_i = 0$$

do:

$$L(w,b,\lambda) = \frac{1}{2} w^T w - \sum_{i=1}^{N} \lambda_i \left[y_i \left(w^T x_i + b \right) - 1 \right]$$

otrzymując ($Q(\lambda)=L(w,b,\lambda)$):

$$Q(\lambda) = \sum_{i=1}^{N} \lambda_i - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \left[y_i y_j \lambda_i \lambda_j x_i^T x_j \right]$$

Którego szukamy maksimum po λ_i, przy ograniczeniach:

$$\lambda_i \geq 0, \quad i = 1,\ldots,N \quad \text{oraz} \quad \sum_{i=1}^{N} \lambda_i y_i = 0$$

Problem optymalizacyjny

Sformułowanie dualne

Niech: $\{(x_i, y_i)\}_{i=1}^{N}$ oznacza zbiór danych (treningowych),

Znajdź współczynniki Lagranga $\{\lambda_i\}_{i=1}^{N}$, które minimalizują funkcję:

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[y_i y_j \lambda_i \lambda_j x_i^T x_j\right] - \sum_{i=1}^{N}\lambda_i$$

przy ograniczeniach:

$$\lambda_i \geq 0, \quad i = 1, \ldots, N$$

$$\sum_{i=1}^{N}\lambda_i y_i = 0$$

Problem optymalizacyjny

Sformułowanie dualne

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\lambda^T \begin{bmatrix} y_1 y_1 x_1^T x_1 & y_1 y_2 x_1^T x_2 & \cdots & y_1 y_N x_1^T x_N \\ y_2 y_1 x_2^T x_1 & y_2 y_2 x_2^T x_2 & \cdots & y_2 y_N x_2^T x_N \\ \cdots & \cdots & & \cdots \\ y_N y_1 x_N^T x_1 & y_N y_2 x_N^T x_2 & \cdots & y_N y_N x_N^T x_N \end{bmatrix} \lambda + (-1^T)\lambda$$

przy ograniczeniach:

$$y^T \lambda = 0$$

$$0 \le \lambda \le \infty$$

Problem optymalizacyjny

Sformułowanie dualne

Uwagi:

- problem dualny oparty jest całkowicie o dane wejściowe (treningowe, pomiarowe);
- funkcja optymalizowana zależy wyłącznie od iloczynu skalarnego wejść.

$$\left\{ x_i^T \cdot x_j \right\}_{i,j=1}^{N}$$

Cechy wektorów nośnych

Sformułowanie dualne

Rozwiązanie:

$$\lambda_o = \lambda_{o,1}, \ldots, \lambda_{o,N}$$

$\boldsymbol{\lambda_o}$ – optymalne mnożniki Lagranga

Z warunków *KKT*:

$$\lambda_i \left[y_i \left(w^T x_i + b \right) - 1 \right] = 0$$

Wszystkie niezerowe mnożniki Lagranga $\boldsymbol{\lambda_{o,i}}$ określają
wektory nośne (podtrzymujące) x_i.
Takich wektorów jest $\boldsymbol{N_S}$

$$\lambda_{o,i} > 0 \Rightarrow x_i$$

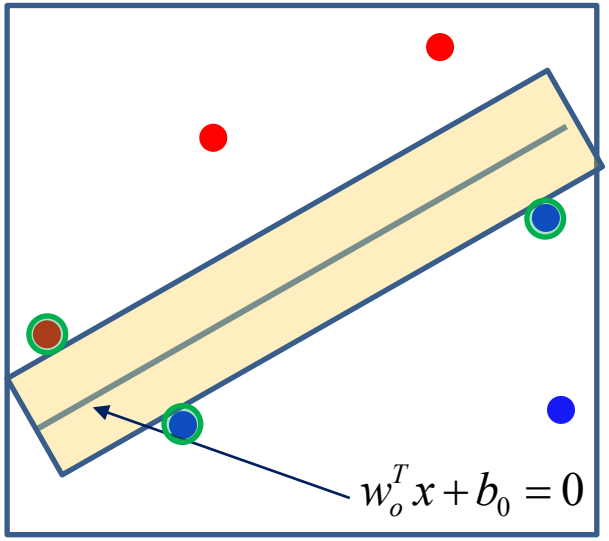
wektory nośne (podtrzymujące) SV

Cechy wektorów nośnych

Sformułowanie dualne

Rozwiązanie:

x_i leżące najbliżej optymalnej linii (płaszczyzny, hiperpłaszczyzna) decyzyjnej są wektorami nośnymi (podtrzymującymi). x_i „dotykają” marginesu ρ.



Wektory nośne spełniają:

$$y_i\left(w^T x_i + b\right) = 1$$

Cechy wektorów nośnych

$$w = \sum_{i=1}^{N} \lambda_i y_i x_i \qquad \sum_{i=1}^{N} \lambda_i y_i = 0$$

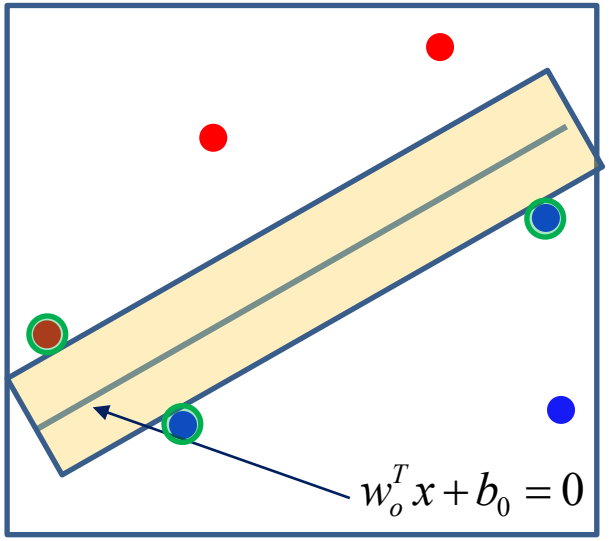
Sformułowanie dualne

Rozwiązanie:

Wyznaczamy optymalny wektor $\boldsymbol{w_o}$:

$$w_o = \sum_{i=1}^{Ns} \lambda_{o,i} y_i x_i$$

$\boldsymbol{N_S}$ – ilość niezerowych $\boldsymbol{\lambda_{o,i}}$



Wyznaczamy optymalny wektor $\boldsymbol{b_o}$:

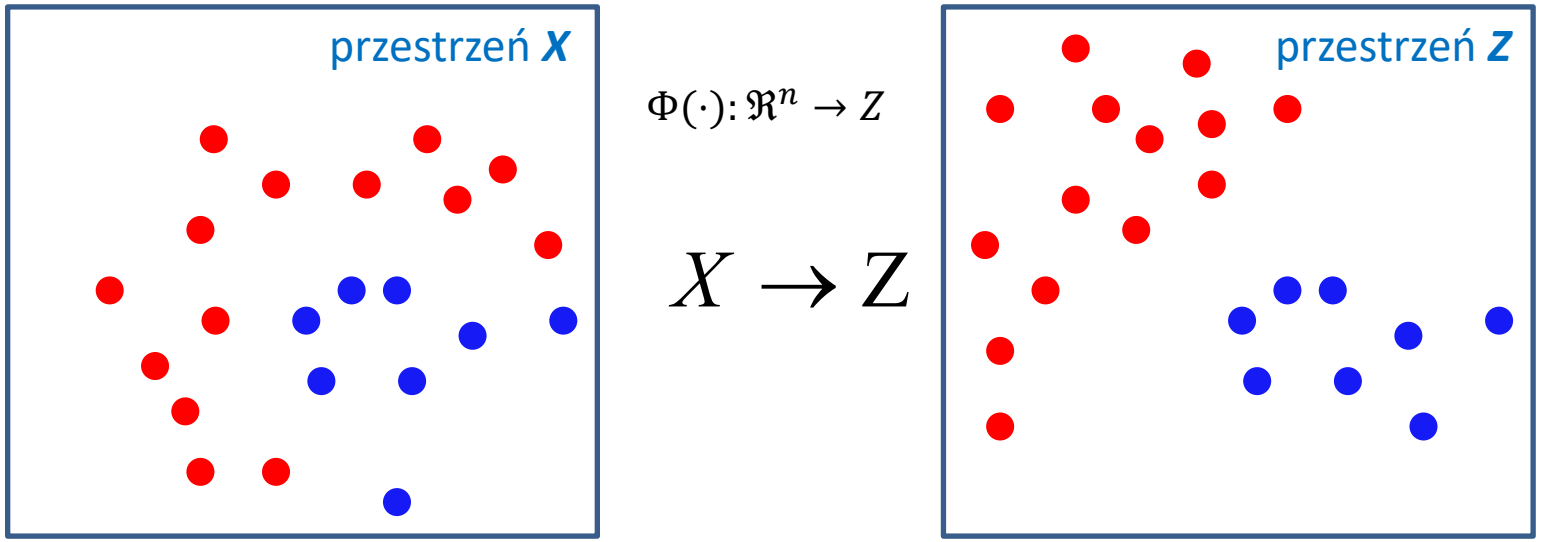
$$b_0 = 1 - w_o^T x^{(S)} \qquad dla \;\; y^{(S)} = 1$$

$$b_0 = 1 - \sum_{i=1}^{Ns} \lambda_{o,i} y_i x_i x^{(S)}$$

Problemy liniowo nieseparowalne

Transformacja do innej przestrzeni (*X* → *Z*)

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[y_i y_j \lambda_i \lambda_j x_i^T x_j\right] - \sum_{i=1}^{N}\lambda_i$$

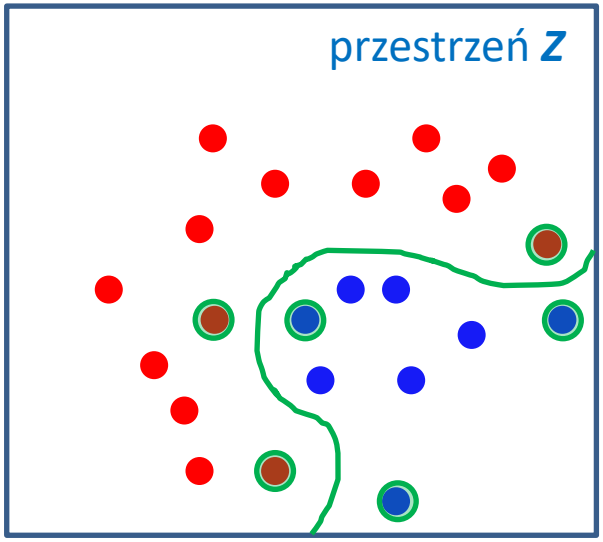


$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[y_i y_j \lambda_i \lambda_j z_i^T z_j\right] - \sum_{i=1}^{N}\lambda_i$$

Problemy liniowo nieseparowalne

Cechy wektorów nośnych

Wektory nośne leżą w przestrzeni ***Z !!!***



W przestrzeni ***X*** możemy jedynie obserwować ich „obraz”***!!!***

Również marginesy określane są w przestrzeni ***Z !!!***

Problemy liniowo nieseparowalne

Co potrzebujemy z przestrzeni *Z* ?

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[y_i y_j \lambda_i \lambda_j z_i^T z_j\right] - \sum_{i=1}^{N}\lambda_i$$

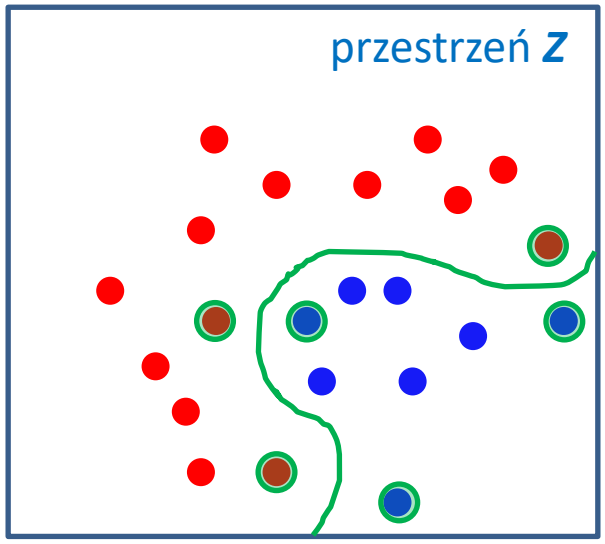
Wyznaczenie obrazów ***z*** w postaci jawnej, o ile jest możliwe w przypadku skończenie wymiarowej przestrzeni cech *F* (aczkolwiek bardzo kosztowne obliczeniowo dla przestrzeni o większej liczbie wymiarów), to w przypadku nieskończenie wymiarowej przestrzeni jest nierealizowalne.

Rozwiązaniem jest zastosowanie tzw. sztuczki jądra (ang. *kernel trick*) zaprezentowanej po raz pierwszy w pracy (M.A Aizerman, 1964).

kernel trick – „sztuczka jądra”

Jak wygląda przestrzeń *F* ??





$x = (x_1, x_2, x_3 \ldots)$

$x' = (x'_1, x'_2, x'_3 \ldots)$

Mając dwa punkty $\mathbf{x}$ i $\mathbf{x}' \in \mathcal{X}$, potrzebujemy $\mathbf{z}^T\mathbf{z}'$

Niech $\mathbf{z}^T\mathbf{z}' = K(\mathbf{x}, \mathbf{x}')$ (jądro) będzie „iloczynem skalarnym” punktów $\mathbf{x}$ i $\mathbf{x}'$

kernel trick – „sztuczka jądra”

Przykład:
Niech x=(x_1; x_2), natomiast jako nieliniową transformację Φ(·) wybieramy wielomian 2go stopnia.

$$z = \Phi(x) = \left(1, x_1, x_2, x_1^2, x_2^2, x_1 x_2\right)$$

$$K(\mathbf{x}, \mathbf{x}') = \mathbf{z}^T \mathbf{z}' = 1 + x_1 x_1' + x_2 x_2' + x_1^2 {x_1'}^2 + x_2^2 {x_2'}^2 + x_1 x_1' x_2 x_2'$$

kernel trick – „sztuczka jądra”

Czy możemy obliczyć $K(\mathbf{x}, \mathbf{x}')$ bez transformowania $\mathbf{x}$ i $\mathbf{x}'$ do przestrzeni $\boldsymbol{Z}$?

Rozważmy

$$K(\mathbf{x}, \mathbf{x}') = (1 + \mathbf{x}^{\mathrm{T}}\mathbf{x}')^2 = (1 + x_1 x_1' + x_2 x_2')^2$$

$$= 1 + x_1^2 x_1'^2 + x_2^2 x_2'^2 + 2x_1 x_1' + 2x_2 x_2' + 2x_1 x_1' x_2 x_2'$$

To jest iloczyn skalarny elementów:

$$(1, x_1^2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1 x_2)$$

$$(1, x_1'^2, x_2'^2, \sqrt{2}x_1', \sqrt{2}x_2', \sqrt{2}x_1' x_2')$$

więc wybrane *k(x,y)* może być jądrem (kernelem).

kernel trick – „sztuczka jądra”

Jądro wielomianowe

$\mathcal{X} = \mathbb{R}^d$ oraz $\Phi: \mathcal{X} \to \mathcal{Z}$ jest wielomianem rzędu $\boldsymbol{Q}$.

„Równoważne” jądro:

$$K(\mathbf{x}, \mathbf{x}') = (1 + \mathbf{x}^{\mathrm{T}}\mathbf{x}')^{\boldsymbol{Q}} = (1 + x_1 x_1' + x_2 x_2' + \cdots + x_d x_d')^{\boldsymbol{Q}}$$

Porównaj dla $d = 10$ i $Q = 100$.

Można dostosować skalę:

$$K(\mathbf{x}, \mathbf{x}') = (a\mathbf{x}^{\mathrm{T}}\mathbf{x}' + b)^{\boldsymbol{Q}}$$

© dr hab. inż. Michał Grochowski

kernel trick – „sztuczka jądra”

Jądro Gaussa (RBF)

Wzór definiujący jądro RBF (Gaussa) dla wektorów $\mathbf{x}$ i $\mathbf{x}'$ wygląda następująco:

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma ||\mathbf{x} - \mathbf{x}'||^2)$$

Zakładając dla uproszczenia $\gamma = \frac{1}{2}$, najpierw rozpisujemy kwadrat odległości między wektorami (normę) używając iloczynu skalarnego:

$$||\mathbf{x} - \mathbf{x}'||^2 = ||\mathbf{x}||^2 + ||\mathbf{x}'||^2 - 2(\mathbf{x}^\mathsf{T}\mathbf{x}')$$

Podstawiając to do wzoru bazowego i rozbijając wynik, otrzymujemy:

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{1}{2}||\mathbf{x}||^2\right) \cdot \exp\left(-\frac{1}{2}||\mathbf{x}'||^2\right) \cdot \exp(\mathbf{x}^\mathsf{T}\mathbf{x}')$$

Jądro Gaussa (RBF)

Kluczem do zrozumienia nieskończonego wymiaru jest ostatni człon: $\exp(\mathbf{x}^\mathsf{T}\mathbf{x}')$

Funkcję e^z można rozwinąć w szereg Taylora w punkcie 0, dla funkcji wykładniczej:

$$e^z = 1 + z + \frac{z^2}{2!} + \frac{z^3}{3!} + \cdots + \frac{z^n}{n!} + \cdots = \sum_{j=0}^{\infty} \frac{z^j}{j!}$$

zastępując z iloczynem skalarnym $\mathbf{x}^\mathsf{T}\mathbf{x}'$, otrzymujemy nieskończoną sumę:

$$\exp(\mathbf{x}^\mathsf{T}\mathbf{x}') = \sum_{j=0}^{\infty} \frac{(\mathbf{x}^\mathsf{T}\mathbf{x}')^j}{j!} = 1 + (\mathbf{x}^\mathsf{T}\mathbf{x}') + \frac{(\mathbf{x}^\mathsf{T}\mathbf{x}')^2}{2!} + \frac{(\mathbf{x}^\mathsf{T}\mathbf{x}')^3}{3!} + \cdots$$

Łącząc wszystko w jedną całość, pełny, nieskończony rozkład jądra RBF dla dwóch elementów przyjmuje postać:

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{1}{2}\mathbf{x}^2\right)\exp\left(-\frac{1}{2}\mathbf{x}'^2\right)\sum_{j=0}^{\infty} \frac{(\mathbf{x}^\mathsf{T}\mathbf{x}')^j}{j!}$$

Jądro Gaussa (RBF)

$$K(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{1}{2}\mathbf{x}^2\right)\exp\left(-\frac{1}{2}\mathbf{x}'^2\right)\sum_{j=0}^{\infty}\frac{(\mathbf{x}^\mathsf{T}\mathbf{x}')^j}{j!}$$

Poszczególne elementy tej nieskończonej sumy to w rzeczywistości kolejne jądra wielomianowe.

Oznacza to, że funkcja RBF zawiera w sobie liniowe cechy wejściowe (wymiar 1), ich kwadraty (wymiar 2), sześciany (wymiar 3), i tak dalej aż do nieskończoności. Odpowiada to stworzeniu wektora cech $\Phi(\mathbf{x})$ o nieskończonej długości.

Dzięki sztuczce jądrowej (kernel trick) nie musimy wyznaczać każdego z tych nieskończonych wymiarów osobno, a następnie na nich przeprowadzać obliczeń.

Zamiast tego, po prostu oblicza się wartość funkcji RBF w przestrzeni oryginalnej (niewielki wymiar), co daje w efekcie matematycznie identyczny wynik, jak gdybyśmy przenieśli punkty do nieskończenie wymiarowej przestrzeni i tam obliczyli ich iloczyn skalarny.

kernel PCA (kPCA) – opis metody

kernel trick – „sztuczka jądra”

Metody wyznaczania jądra:

1. „konstruowanie – sprawdzanie”
2. Sprawdzanie warunków odpowiednich założeń matematycznych (warunki Mercera)
3. Liczenie na szczęście ☺ …

kernel PCA (kPCA) – opis metody

kernel trick – „sztuczka jądra”

Warunki Mercera:

Funkcja K(x,x’) może stanowić funkcję jądra, jeżeli:

1. Jest symetryczna, np.: $k(x,x') = x*x'=x'*x$

2. Macierz:

$$K = \begin{bmatrix} k_{1,1} & \cdots & k_{1,m} \\ \vdots & k_{i,j} & \vdots \\ k_{m,1} & \cdots & k_{m,m} \end{bmatrix} \qquad k_{ij}=k(x_i,x_j)$$

jest półdodatnio określona dla dowolnych wektorów x.

kernel PCA (kPCA) – opis metody

kernel trick – „sztuczka jądra”

Wybór funkcji jądra jest istotny ponieważ determinuje odwzorowanie Φ(•).

Najczęściej spotykane funkcje jądra to:

- wielomianowa: $k(x,y) = (x^T y)^d$, przy $d = const$
- Gaussa: $k(x,y) = \exp\left(-\frac{\|x-y\|^2}{2\delta^2}\right)$, przy $\delta > 0$
- odwrotnej formy kwadratowej: $k(x,y) = \frac{1}{\sqrt{\|x-y\|^2+c}}$, przy $c = const, c > 0$
- sigmoidalna: $k(x,y) = tanh(\gamma x^T y + \Theta)$, przy $\gamma, \Theta = const$

Szczególnym przypadkiem funkcji wielomianowej jest funkcja wielomianowa pierwszego rzędu i odpowiada ona przekształceniu liniowemu: $\Phi(\cdot): \Re^n \to \Re^n$

Problemy liniowo nieseparowalne

Co potrzebujemy z przestrzeni *Z* ?

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\left[y_i y_j \lambda_i \lambda_j \left(z_i^T z_j\right)\right] - \sum_{i=1}^{N}\lambda_i$$

Uwaga: Nie potrzebujemy wektorów z_i i z_j a jedynie ich iloczynów skalarnych !!!

Ograniczenia:

$$\lambda_i \geq 0, \quad i = 1,\ldots,N$$

$$\sum_{i=1}^{N}\lambda_i y_i = 0$$

Otrzymujemy:

$$f(x) = sign(w_o z^T + b_o)$$

gdzie:

$$w_o = \sum_{i=1}^{Ns}\lambda_{o,i} y_i z_i$$

potrzebujemy: $z_i^T z_j$

$$b_0 : \quad y_i(w_o^T z_j^{(S)} + b_o) = 1$$

potrzebujemy: $z_i^T z_j$

Problemy liniowo nieseparowalne

Obliczenia w przestrzeni *Z (kernel trick)*

Dla dowolne punktów x_1 oraz x_2 należących do X, chcemy policzyć $z_1^T z_2$

Niech:

$$z_1^T z_2 = k(x_1, x_2)$$

Będzie jądrem (kernel) – „iloczyn skalarny” x_1 oraz x_2

Np: Gaussa:

$$k(x,y) = \exp\left(-\frac{\|x-y\|^2}{2\delta^2}\right), \text{ przy } \delta > 0$$

Problemy liniowo nieseparowalne

Obliczenia w przestrzeni *Z (kernel trick)*

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\lambda^T \begin{bmatrix} y_1 y_1 x_1^T x_1 & y_1 y_2 x_1^T x_2 & \cdots & y_1 y_N x_1^T x_N \\ y_2 y_1 x_2^T x_1 & y_2 y_2 x_2^T x_2 & \cdots & y_2 y_N x_2^T x_N \\ \cdots & \cdots & & \cdots \\ y_N y_1 x_N^T x_1 & y_N y_2 x_N^T x_2 & \cdots & y_N y_N x_N^T x_N \end{bmatrix} \lambda + (-1^T)\lambda$$

$$X \rightarrow \mathrm{Z}$$

$$\min_{\lambda} Q(\lambda) = \frac{1}{2}\lambda^T \begin{bmatrix} y_1 y_1 k(x_1, x_1) & y_1 y_2 k(x_1, x_2) & \cdots & y_1 y_N k(x_1, x_N) \\ y_2 y_1 k(x_2, x_1) & y_2 y_2 k(x_2, x_2) & \cdots & y_2 y_N k(x_2, x_N) \\ \cdots & \cdots & & \cdots \\ y_N y_1 k(x_N, x_1) & y_N y_2 k(x_N, x_2) & \cdots & y_N y_N k(x_N, x_N) \end{bmatrix} \lambda + (-1^T)\lambda$$

Problemy liniowo nieseparowalne

Obliczenia w przestrzeni *Z (kernel trick)*

Wyraźmy f(x) przy pomocy K(-,-):

$$z_1^T z_2 = k(x_1, x_2)$$

$$f(x) = sign(w_o z^T + b_o)$$

$$w_o = \sum_{i=1}^{Ns} \lambda_{o,i} y_i z_i \qquad \text{to:} \qquad f(x) = sign(\sum_{i=1}^{Ns} \lambda_i y_i K(x_i, x) + b_o)$$

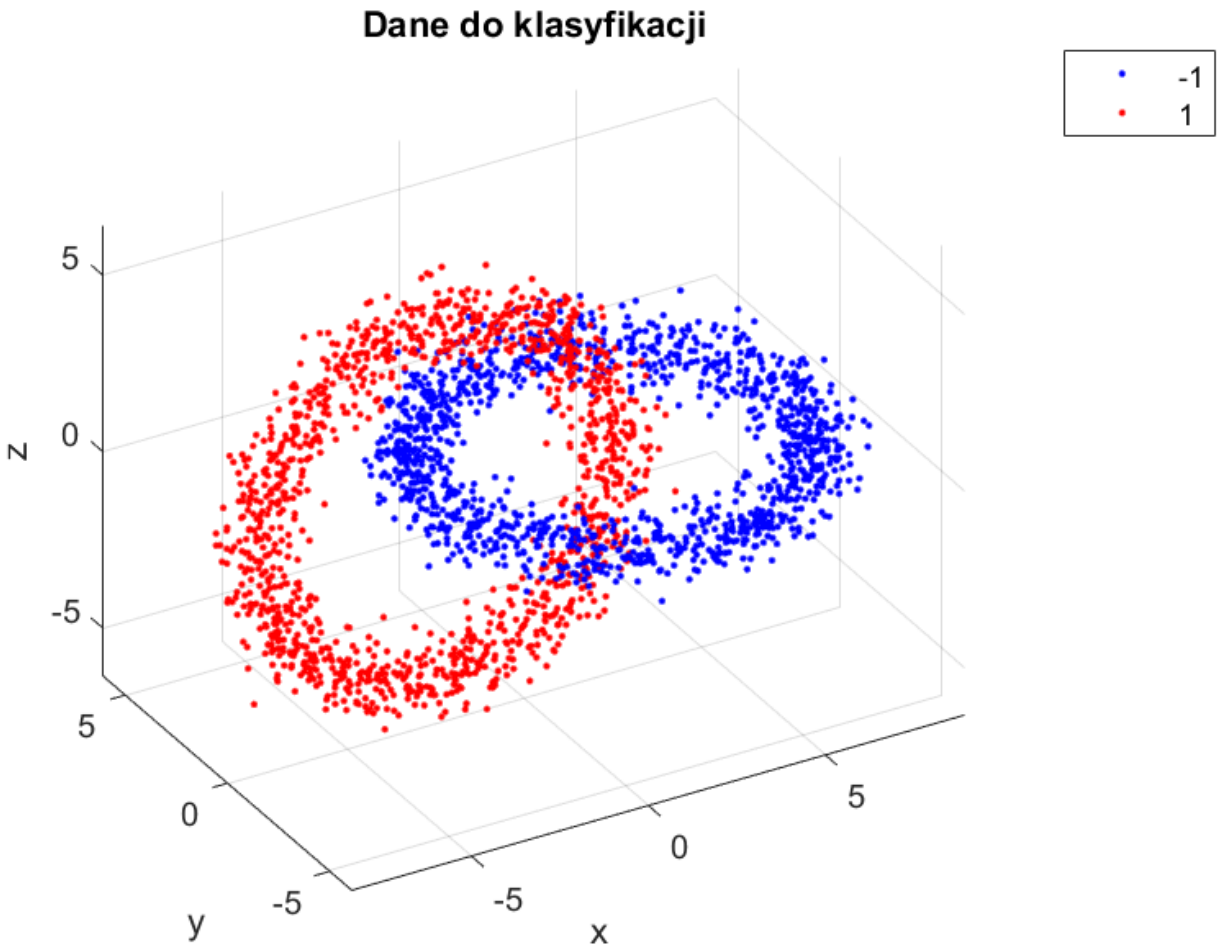
gdzie:

$$b_0 = y_i - \sum_{i=1}^{Ns} \lambda_i y_i K(x_i, x)$$

dla każdego niezerowego λ_i :

$$\lambda_i > 0$$

Przykład



Problem optymalizacyjny z uwzględnieniem tzw. „soft margin”

Problem optymalizacji kwadratowej z ograniczeniami - liniowo kwadratowy

Zadanie optymalizacji:

$$\min_{w,b,s}\left(\frac{1}{2}w^T w + C\sum s_i\right),$$

$$y_i(w^T x_i + b) \geq 1 - s_i,$$

$$s_i \geq 0,$$

s_i – margines,
C – parametr odpowiedzialny za „miękkość” ograniczeń

Problem optymalizacyjny z uwzględnieniem tzw. „soft margin”

Parametry funkcji jądra - interpretacja

Zadanie optymalizacji:

$$\min_{w,b,s}\left(\frac{1}{2}w^T w + C\sum s_i\right),$$

$$y_i(w^T x_i + b) \geq 1 - s_i,$$

$$s_i \geq 0,$$

Parametr C kontroluje kompromis pomiędzy:
- maksymalizacją marginesu,
- minimalizacją liczby błędów klasyfikacji.

Duże wartości C powodują silne karanie błędów, co prowadzi do modeli o wysokiej złożoności i ryzyku przeuczenia.

Małe wartości C zwiększają tolerancję na błędy, prowadząc do gładszych granic decyzyjnych, ale z ryzykiem niedouczenia.

Problem optymalizacyjny z uwzględnieniem tzw. „soft margin”

Problem optymalizacji kwadratowej z ograniczeniami - liniowo kwadratowy

Przy jądrze w postaci funkcji Gaussa:

$$k(x,y) = \exp\left(-\frac{\|x-y\|^2}{2\delta^2}\right), \text{ przy } \delta > 0$$

Parametr σ kontroluje zasięg wpływu pojedynczych próbek:

- małe wartości σ powodują, że każda próbka wpływa jedynie na niewielki obszar przestrzeni cech, co prowadzi do bardzo złożonych granic decyzyjnych.
- duże wartości σ powodują wygładzenie granicy decyzyjnej i uogólnienie modelu.

Parametr σ odpowiada zatem za zdolność do generalizacji modelu modelu.

Dziękuję za uwagę