POLITECHNIKA GDAŃSKA

Modelowanie i Identyfikacja

(MiI2023)

Materiał wykładowy: 3 – Modelowanie parametryczne – metoda najmniejszych kwadratów, ważona metoda najmniejszych kwadratów

Wydział Elektrotechniki i Automatyki

Katedra Inteligentnych Systemów Sterowania i Wspomagania Decyzji

dr hab. inż. Kazimierz Duzinkiewicz

dr inż. Bartosz Puchalski

Metody identyfikacji wykorzystujące modele parametryczne

- Celem jest znalezienie funkcji *f*, która reprezentuje informację jaką możemy wywnioskować o wielkościach wyjściowych *Y* przy danych wielkościach wejściowych *X*.

Podejście parametryczne cechuje się dwoma etapami

1. Zakładamy a priori postać funkcji *f*, np. zakładamy że *f* jest funkcją liniową:

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

Zamiast skupiać się na bezpośrednim odnalezieniu funkcji *f* *p*-zmiennych szukamy $p + 1$ parametrów $\beta_0, \beta_1, \ldots, \beta_p$ tej funkcji.

2. Po wybraniu modelu potrzebujemy metody, za pomocą której, wpasujemy model do danych treningowych, tj. określimy wartości parametrów $\beta_0, \beta_1, \ldots, \beta_p$ w taki sposób, że

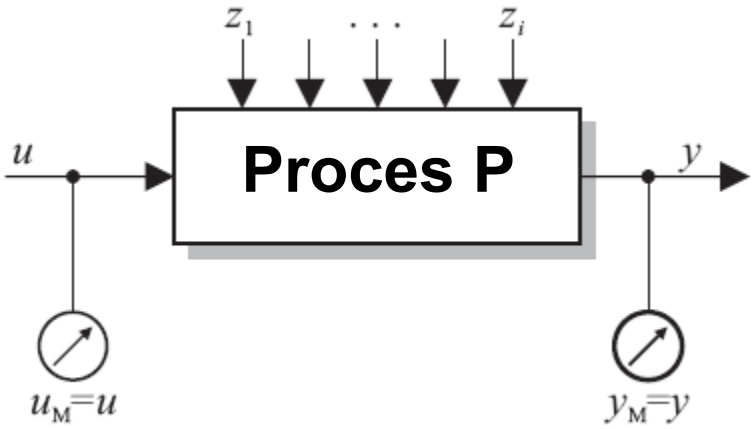
$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

Typowo w tym celu wykorzystuje się *metodę najmniejszych kwadratów*, jednakże istniej wiele sposobów na wpasowanie modelu do danych.

Powody stosowania podejścia eksperymentalnego (identyfikacji)

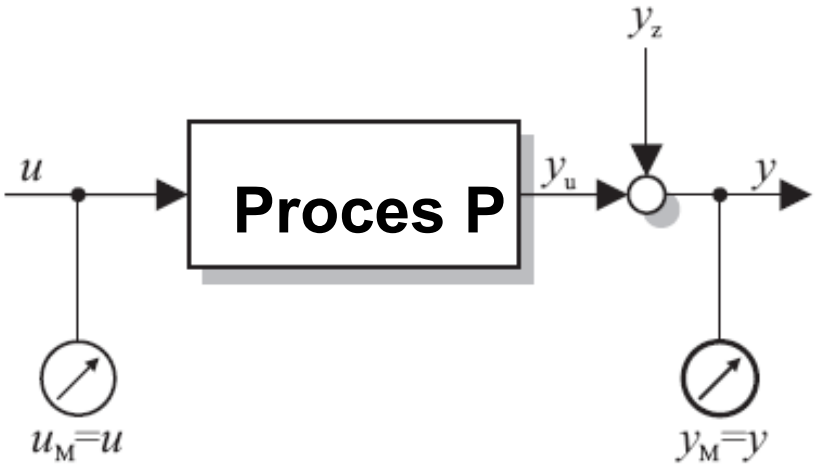
- Analiza teoretyczna systemu może okazać się złożona nawet dla prostych systemów
- Przeważnie, parametry modelu wyprowadzone z rozważań teoretycznych nie są wystarczająco dokładne
- Nie wszystkie mechanizmy wewnętrznego zachowania się systemu są znane
- Mechanizmy wewnętrznego zachowania nie mogą być opisane matematycznie z wymaganą dokładnością
- System jest bardzo złożony i teoretyczna analiza jest zbyt czasochłonna
- Identyfikowany model może być uzyskany w krótszym czasie i mniejszym wysiłkiem niż model teoretyczny

Przebieg i problemy procesu identyfikacji systemu dynamicznego



Identyfikację określa się jako eksperymentalne wyznaczenie modelu zachowania się systemu (struktura i parametry). Wykorzystuje się mierzone sygnały i określa zachowanie systemu przy założeniu struktury modelu. Różnica pomiędzy systemem i modelem (błąd) powinna być tak mała jak to możliwe

Przebieg i problemy procesu identyfikacji systemu dynamicznego – c.d.



Będziemy rozważali głownie procesy liniowe. Wówczas poszczególne składniki zakłóceń $z_1, \ldots, z_i$ mogą być zagregowane w jedno reprezentatywne zakłócenie i dodawane do sygnału użytecznego $y_u(t)$ w postaci sygnału $y_z(t)$

Przebieg i problemy procesu identyfikacji systemu dynamicznego – c.d.

Ograniczenia jakie należy brać pod uwagę w procesie identyfikacji

1. Dostępny czas pomiarów T_M jest zawsze ograniczony, albo z powodów technicznych, albo czasowej zmiany parametrów procesu lub z powodów ekonomicznych (budżet eksperymentu), zatem

$$T_M \leq T_{M,max}$$

2. Maksymalna dopuszczalna zmiana sygnału wejściowego, tzn. wartość sygnału testowego u_0 jest zawsze ograniczona, albo z powodów technicznych, albo z powodu założenia o liniowości zachowania systemu słusznego tylko w pewnym obszarze warunków operacyjnych, zatem

$$u_{min} \leq u(t) \leq u_{max}$$

Przebieg i problemy procesu identyfikacji systemu dynamicznego – c.d.

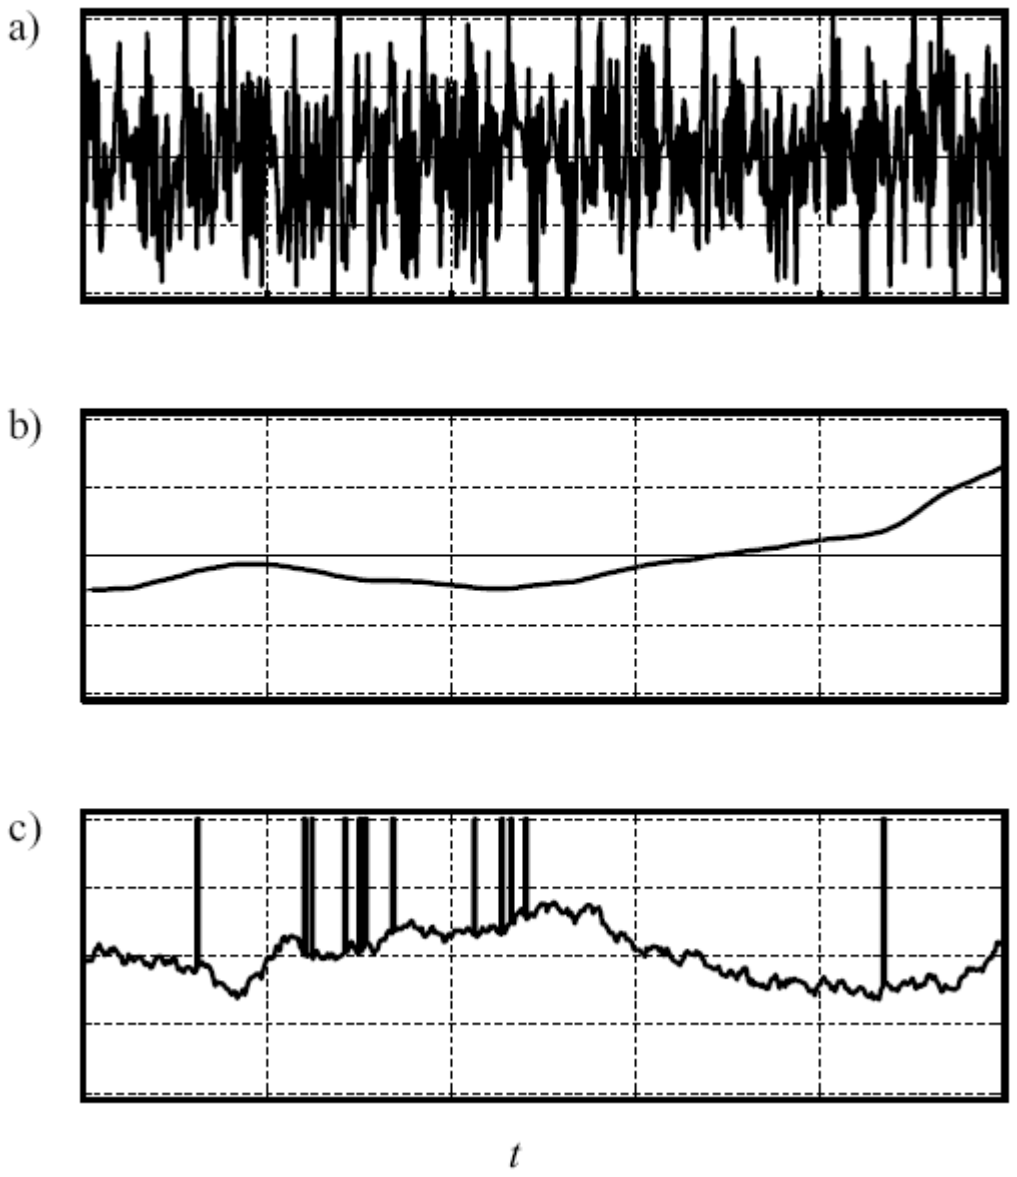
Ograniczenia jakie należy brać pod uwagę w procesie identyfikacji – c.d.

3. Maksymalna dopuszczalna zmiana sygnału wyjściowego, tzn. wartość sygnału testowego y_0 może również być ograniczona, albo z powodów technicznych, albo z powodu założenia o liniowości zachowania systemu słusznego tylko w pewnym obszarze warunków operacyjnych, zatem

$$y_{min} \leq y(t) \leq y_{max}$$

4. Należy brać pod uwagę, że zakłócenia zawierają zwykle różne składowe, które można sklasyfikować w grupy

Przykłady różnych składowych zakłóceń



a. Wysokiej częstotliwości quasi-stacjonarny stochastyczny szum n(t)

$$E\{n(t)\} = 0$$

b. Niskiej częstotliwości niestacjonarny stochastyczny lub deterministyczny sygnał (np. dryft, sygnał periodyczny z okresem jeden dzień lub jeden rok) d(t)

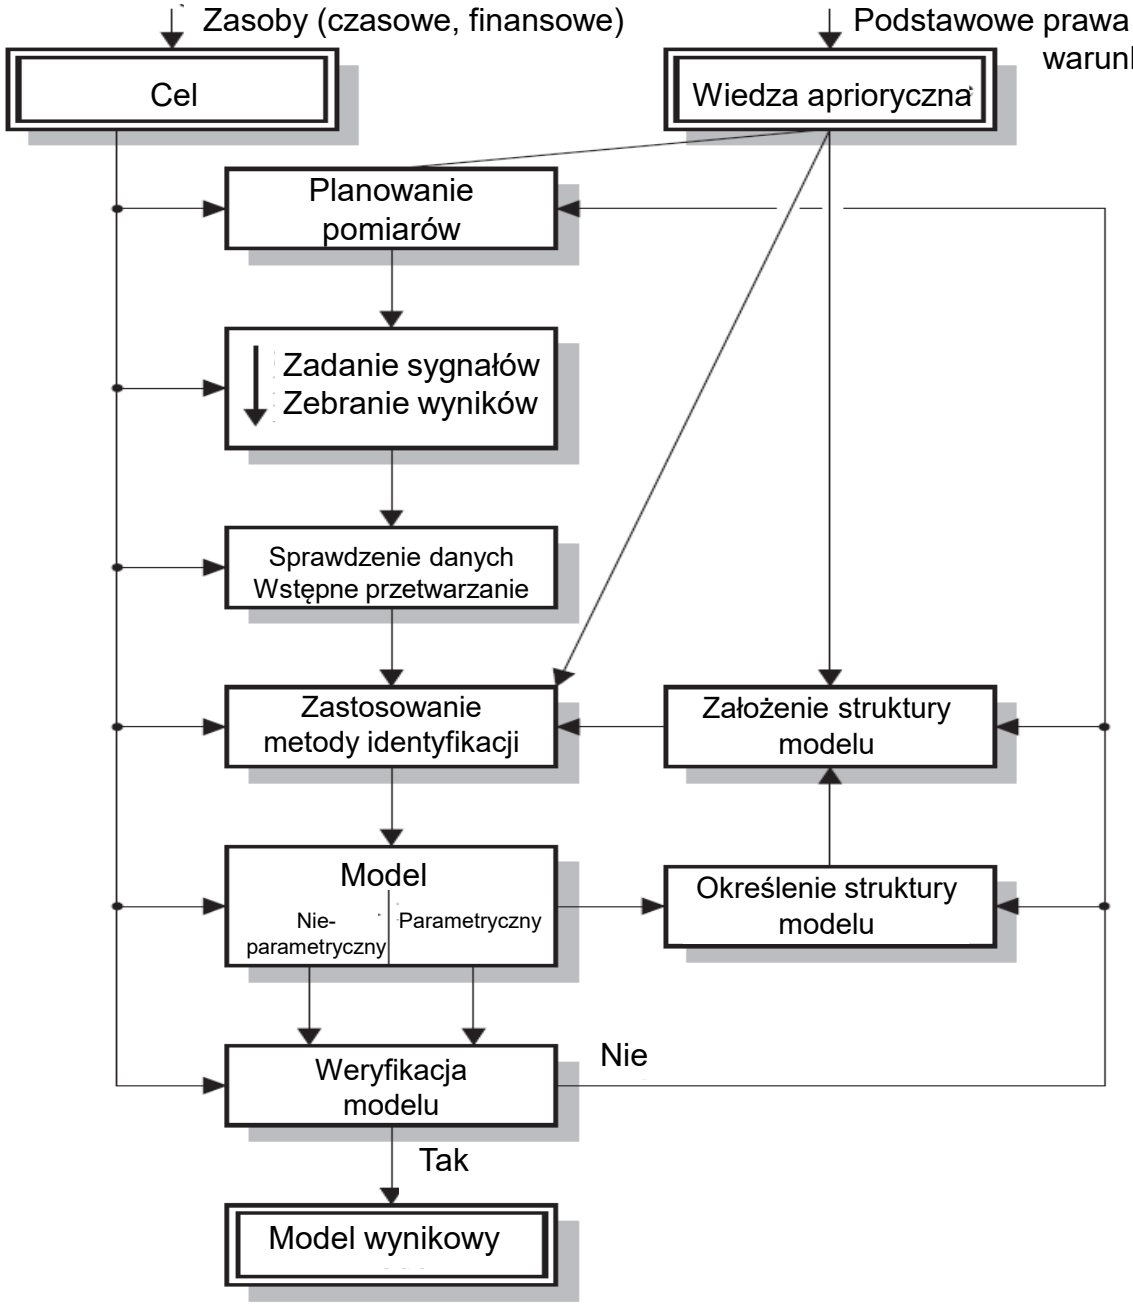
c. Sygnały zakłóceń o nieznanym charakterze (np. pomiary oddalone – outliers) h(t)

Podsumowanie:

Efektywna metoda identyfikacji musi być w stanie określić zachowanie się systemu tak dokładnie jak to jest możliwe przy ograniczeniach wnoszonych przez:

- dane zakłócenia $y_z(t) = n(t) + d(t) + h(t)$
- ograniczony czas pomiaru $T_M \leq T_{M,max}$
- ograniczoną amplitudę sygnału testowego $u_{min} \leq u(t) \leq u_{max}$
- ograniczoną amplitudę sygnału wyjściowego $y_{min} \leq y(t) \leq y_{max}$
- cel identyfikacji

Podstawowa sekwencja procesu identyfikacji



Identyfikacja - metoda najmniejszych kwadratów

Typowa forma zadania estymacji parametrów

- Dany jest system dynamiczny, dla którego proponowany jest model matematyczny oparty na doświadczeniu proponującego i który:
  - zgodny jest ze wszystkimi znanymi prawami rządzącymi zachowaniem się systemu,
  - pozwala wykorzystać dostępne w systemie pomiary dla porównania zachowania się modelu i systemu
  - jego struktura spełnia wymagania pozwalające uzyskać pożądaną dokładność

  ale zawiera szereg niezbyt dobrze znanych parametrów
- Należy określić „najlepsze” estymaty wszystkich nieznanych dobrze parametrów tak, aby model matematyczny zapewniał „optymalną estymatę” zachowania systemu

W procesie estymacji z każdą włączoną w ten proces zmienną/wielkością związane są **trzy wartości**:

x - wartość prawdziwa (rzeczywista) zmiennej

$\tilde{x}$ - wartość mierzona zmiennej

$\hat{x}$ - wartość estymowana zmiennej

Co można powiedzieć o tych wartościach?

x - wartość praktycznie nieznana

$\tilde{x}$ - wartość uzyskiwana z czujnika lub z innego pomiaru, nigdy nierówna wartości prawdziwej, obarczona błędem pomiaru

$\hat{x}$ - wartość zmiennej uzyskiwana jako wynik procesu estymacji

W zadaniu estymacji zmienne x – parametry modelu

Dwa błędy:

1. Błąd pomiaru (measurement error)

błąd pomiaru

$$\tilde{x} = x + \tilde{e}$$

$$\tilde{e} = \tilde{x} - x$$

wartość mierzona — wartość prawdziwa

2. Błąd resztkowy, błąd dopasowania (residual error)

błąd resztkowy – residuum)

$$\tilde{x} = \hat{x} + \hat{e}$$

$$\hat{e} = \tilde{x} - \hat{x}$$

wartość mierzona — wartość estymowana

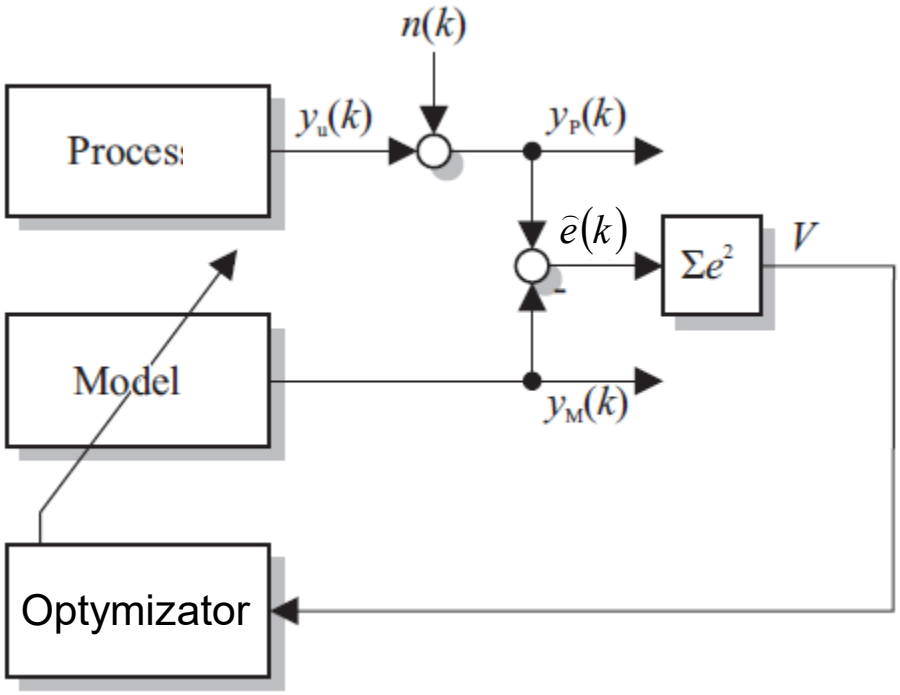
Co można powiedzieć o tych błędach:

$\tilde{e}$ - wartość praktycznie nigdy nieznana; mechanizm generujący ten błąd zwykle jest aproksymowany przez pewien znany proces (np. szum gaussowski o zerowej wartości średniej i znanej wariancji σ^2;

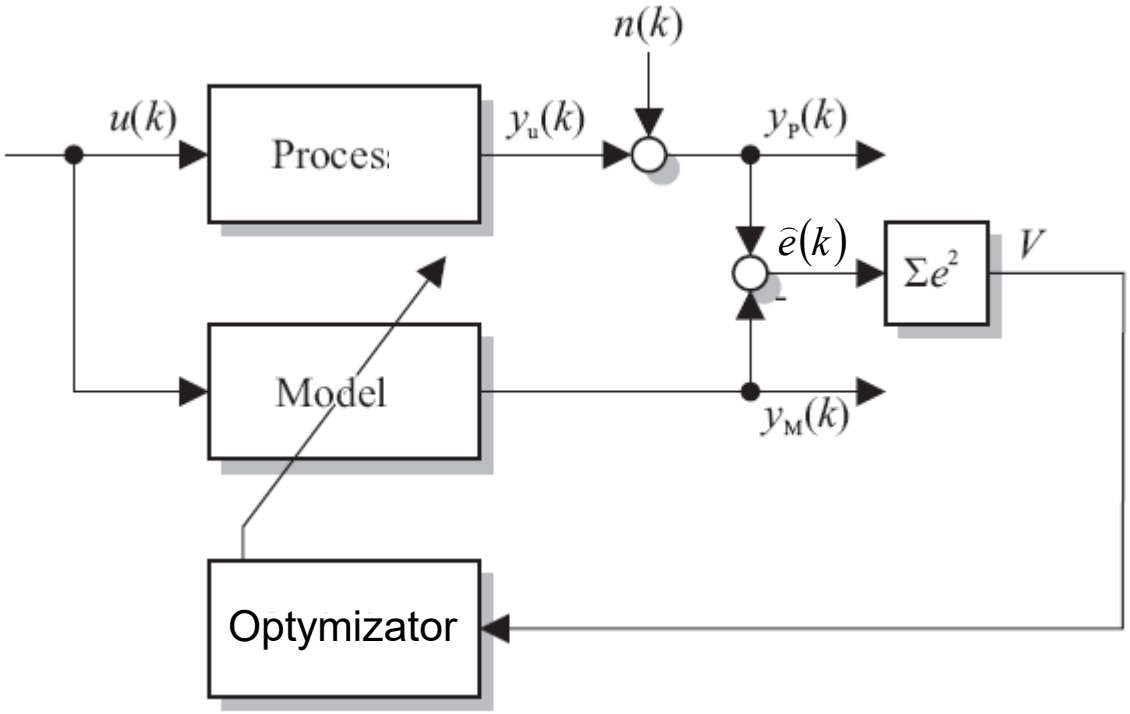
$\hat{e}$ - wartość znana w momencie wyznaczenia wartości estymowanej zmiennej

Schematyczne przedstawienie ogólnej struktury metody najmniejszych kwadratów

Wariant I



Wariant II



Metoda najmniejszych kwadratów - jednokrotna estymacja liniowa – (linear batch estimation)

Dane:

Pomiary $$\left\{\tilde{y}_1, u_1; \tilde{y}_2, u_2; \ldots; \tilde{y}_j, u_j; \ldots; \tilde{y}_m, u_m\right\} \quad (1)$$

Proponowany model:

Liniowy względem parametrów

$$y(u) = \sum_{i=1}^{n} x_i h_i(u) \quad (2)$$

$\{h_1(u), h_2(u), \ldots, h_i(u), \ldots, h_n(u)\}$ - określony zbiór niezależnych **funkcji bazowych** (3)

Parametry nieznane

$$x_i; \quad i = \overline{1,n}$$

Założenie:

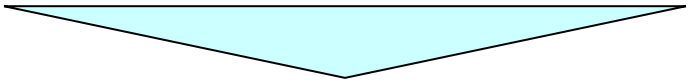
$$m \geq n$$

Liczba pomiarów jest większa lub równa liczbie identyfikowanych parametrów modelu

Poszukiwanie:

Estymaty $\hat{x}_i; \quad i = \overline{1,n}$ nieznanych parametrów $x_i; \quad i = \overline{1,n}$

Kryterium jakości doboru wartości estymowanych parametrów – jak dobrze proponowany model dokonuje predykcji pomiarów



Argument kryterium – błędy resztkowe (residua)

$$\hat{e}_j = \tilde{y}_j - \hat{y}_j, \quad j = \overline{1,m}$$

Liczba błędów resztkowych – liczba pomiarów

$$\hat{e}_j = \tilde{y}_j - \hat{y}_j, \quad j = \overline{1,m}$$

Zależności:

$$\tilde{y}_j \equiv \tilde{y}(u_j) = \sum_{i=1}^{n} x_i h_i(u_j) + \tilde{e}_j, \quad j = \overline{1,m}$$ ← **- model pomiaru** (4)

$$\hat{y}_j \equiv \hat{y}(u_j) = \sum_{i=1}^{n} \hat{x}_i h_i(u_j), \quad j = \overline{1,m}$$ (5)

Przyjmujemy

$$\tilde{y}_j = \hat{y}_j + \hat{e}_j = \sum_{i=1}^{n} \hat{x}_i h_i(u_j) + \hat{e}_j, \quad j = \overline{1,m}$$ (6)

Ostatnia zależność w zwartej postaci:

$$\tilde{\boldsymbol{y}} = H\hat{\boldsymbol{x}} + \hat{\boldsymbol{e}} \qquad (6a)$$

$\tilde{\boldsymbol{y}} = \left(\tilde{y}_1, \tilde{y}_2, \ldots, \tilde{y}_j, \ldots, \tilde{y}_m\right)^T$ - wektor wartości mierzonych y

$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$ - wektor estymowanych wartości parametrów

$\hat{\boldsymbol{e}} = \left(\hat{e}_1, \hat{e}_2, \ldots, \hat{e}_j, \ldots, \hat{e}_m\right)^T$ - wektor błędów resztkowych (dopasowania, residuów)

$$H = \begin{pmatrix} h_1(u_1) & h_2(u_1) \ldots h_i(u_1) \ldots h_n(u_1) \\ h_1(u_2) & h_2(u_2) \ldots h_i(u_2) \ldots h_n(u_2) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(u_j) & h_2(u_j) \ldots h_i(u_j) \ldots h_n(u_j) \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ h_1(u_m) & h_2(u_m) \ldots h_i(u_m) \ldots h_n(u_m) \end{pmatrix}$$

Macierz obserwacji

Równanie (6a) – **równanie obserwacji**

Metoda najmniejszych kwadratów – przypadek liniowy (względem parametrów)

Metoda najmniejszych kwadratów Gauss'a proponuje jako optymalny wybór dla wartości nieznanych parametrów, wartość

$$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$$

który minimalizuje sumę kwadratów błędów resztkowych (residuów)

$$J = \frac{1}{2}\hat{\boldsymbol{e}}^T\hat{\boldsymbol{e}}$$

z (6a) $\tilde{\boldsymbol{y}} = H\hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}$

$$\hat{\boldsymbol{e}} = \tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}$$

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Co możemy powiedzieć o $J(\hat{x})$:

$$J = \frac{1}{2}(\tilde{y} - H\hat{x})^T(\tilde{y} - H\hat{x}) = \frac{1}{2}(\tilde{y}^T\tilde{y} - 2\tilde{y}^T H\hat{x} + \hat{x}^T H^T H\hat{x})$$

1. Możemy napisać - $J(\hat{x})$

$$J : R^n \rightarrow R$$ - J jest funkcjonałem

Metoda najmniejszych kwadratów → zadanie minimalizacji funkcjonału bez ograniczeń; zadanie minimalizacji bez ograniczeń

Dla danego w oparciu o równania obserwacji funkcjonału J(x) poszukujemy wartości x^* dającej minimalną wartość tego funkcjonału

2. Metoda najmniejszych kwadratów → Funkcja celu ma postać formy kwadratowej

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Forma kwadratowa

$$F(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} + \boldsymbol{d}^T\boldsymbol{x} + c$$

gdzie: A - macierz symetryczna

$$\boldsymbol{A} = H^T H \qquad \boldsymbol{d}^T = -\tilde{\boldsymbol{y}}^T H \qquad c = \frac{1}{2}\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}}$$

Warunki konieczne i wystarczające minimum metody najmniejszych kwadratów

$$J = \frac{1}{2}\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right)^T\left(\tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}\right) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}^T\tilde{\boldsymbol{y}} - 2\tilde{\boldsymbol{y}}^T H\hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^T H^T H\hat{\boldsymbol{x}}\right)$$

Warunek konieczny pierwszego rzędu (oznacza, że $J(x)$ nie zmienia się dla $x = \hat{x}$)

$$\nabla J(\boldsymbol{x})\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T H\,\hat{\boldsymbol{x}} - H^T\tilde{\boldsymbol{y}} = \boldsymbol{0} \qquad (1)$$

Warunek konieczny drugiego rzędu (oznacza, $x = \hat{x}$ jest w tzw. „misce”)

$$\Delta\boldsymbol{x}^T\nabla^2 J(\boldsymbol{x})^T\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}}\Delta\boldsymbol{x} = \Delta\hat{\boldsymbol{x}}^T H^T H\Delta\hat{\boldsymbol{x}} \geq \boldsymbol{0} \quad \text{dla dowolnych} \quad \Delta\hat{\boldsymbol{x}}$$

$$H^T H \qquad \text{dodatnio półokreślona} \qquad (2)$$

Warunek wystarczający drugiego rzędu:

$H^T H$ dodatnio określona (3)

Fakty:

- Macierz $H^T H$ jest zawsze dodatnio półokreślona (jako macierz symetryczna)
- Macierz $H^T H$ jest dodatnio określona, jeżeli macierz H ma najwyższy rząd równy n

Analiza warunków koniecznych minimum metody najmniejszych kwadratów

Warunki, o których była mowa wcześniej można otrzymać z prostej analizy:

1. Aby $\hat{\boldsymbol{x}}$ było lokalnym minimum musi ono być mniejsze niż wszystkie wartości wokół niego

$$J(\hat{\boldsymbol{x}}) \leq J(\hat{\boldsymbol{x}} + \Delta\hat{\boldsymbol{x}}) \quad \Leftrightarrow \quad J(\hat{\boldsymbol{x}} + \Delta\hat{\boldsymbol{x}}) - J(\hat{\boldsymbol{x}}) \geq 0$$

2. Rozwiniecie w szereg Taylora funkcji $J(\hat{\boldsymbol{x}})$ jest następujące

$$J(\hat{\boldsymbol{x}} + \Delta\hat{\boldsymbol{x}}) = J(\hat{\boldsymbol{x}}) + \nabla J(\hat{\boldsymbol{x}})^{\mathrm{T}} \Delta\hat{\boldsymbol{x}} + \Delta\hat{\boldsymbol{x}}^{\mathrm{T}} \frac{1}{2} \nabla^2 J(\hat{\boldsymbol{x}}) \Delta\hat{\boldsymbol{x}}$$

3. Wiemy, że w minimum gradient funkcji jest równy zero $\nabla J(\hat{\boldsymbol{x}}) = \mathbf{0}$, zatem

$$J(\hat{\boldsymbol{x}} + \Delta\hat{\boldsymbol{x}}) - J(\hat{\boldsymbol{x}}) = \Delta\hat{\boldsymbol{x}}^{\mathrm{T}} \frac{1}{2} \nabla^2 J(\hat{\boldsymbol{x}}) \Delta\hat{\boldsymbol{x}}$$

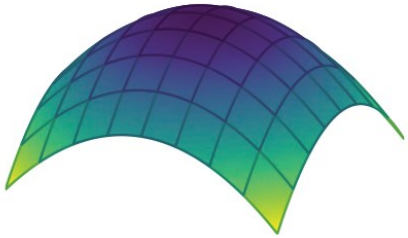
3. Więc

$$\Delta\hat{\boldsymbol{x}}^{\mathrm{T}} \frac{1}{2} \underbrace{\nabla^2 J(\hat{\boldsymbol{x}})}_{\boldsymbol{A}} \Delta\hat{\boldsymbol{x}} \geq \mathbf{0}$$

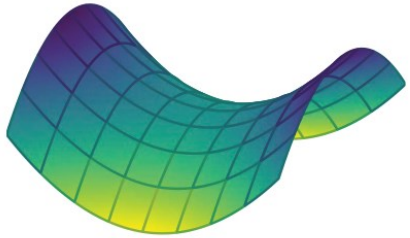
$\boldsymbol{A}$ jest Hesjanem, a w naszym przypadku dodatkowo $\boldsymbol{A} = \boldsymbol{H}^{\boldsymbol{T}}\boldsymbol{H}$

Powyższe wyrażenie jest definicją macierzy dodatnio półokreślonej.

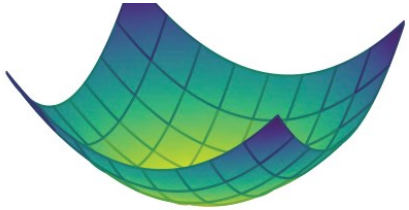
Analiza warunku koniecznego i wystarczającego minimum metody najmniejszych kwadratów



Lokalne maksimum. Gradient wynosi zero, ale Hesjan jest ujemnie określony



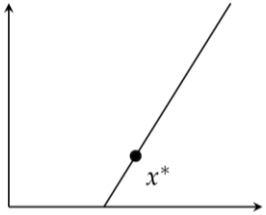
Siodło. Gradient wynosi zero, ale nie jest to lokalne minimum.



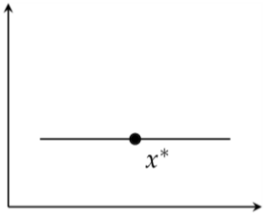
Miska. Gradient jest zerowy, a Hesjan jest dodatnio określony. Jest to lokalne minimum.



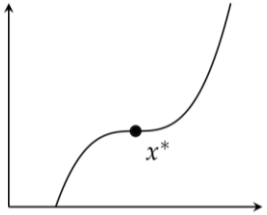
Spełniony jest warunek wystarczający



Warunek konieczny I rz.: niespełniony
Warunek konieczny II rz.: spełniony



Warunek konieczny I rz.: spełniony
Warunek konieczny II rz.: spełniony



Warunek konieczny I rz.: spełniony
Warunek konieczny II rz.: spełniony

Obliczanie wartości estymowanych nieznanych parametrów – układ równań normalnych wynikający z warunku koniecznego pierwszego rzędu

Układ równań normalnych

$$H^T H \, \hat{\boldsymbol{x}} = H^T \tilde{\boldsymbol{y}} \tag{4}$$

Jeżeli macierz $H^T H$ jest nieosobliwa - posiada macierz odwrotną - otrzymujemy **jawne rozwiązanie optymalnej estymaty**

$$\hat{\boldsymbol{x}} = \left(H^T H \right)^{-1} H^T \tilde{\boldsymbol{y}} \tag{5}$$

Fakty:

- Jawne rozwiązanie optymalnej estymaty wymaga nieosobliwości macierzy $H^T H$
- macierz $H^T H$ jest nieosobliwa jeżeli rząd macierzy H wynosi n, czyli liczba liniowo niezależnych równań obserwacji jest większa lub co najmniej równa liczbie poszukiwanych estymat x_i

Stąd warunek (bez dowodu):

- zbiór funkcji bazowych powinien być liniowo niezależny

Przykład 1: (estymacja parametrów prostego układu dynamicznego)

System

$$\dot{x} = ax + bu$$

Dyskretna reprezentacja systemu z przedziałem dyskretyzacji Δt

$$x(k+1) = A_D x(k) + B_D u(k)$$

gdzie:

$$A_D = e^{a\Delta t}$$

$$B_D = \int_0^{\Delta t} be^{at}\,dt = \frac{b}{a}\left(e^{a\Delta t} - 1\right)$$

Zadanie: określić wartości stałych A_D oraz B_D wykorzystując zbiór pomiarów dyskretnych $\tilde{y}_k$ oraz u_k

Jak została zaproponowana reprezentacja dyskretna systemu

Poszukujemy odpowiedzi systemu na dowolne wymuszenie w przedziale czasu $[t_0, t)$

$$\dot{x}(t) = a \cdot x(t) + b \cdot u(t)$$

$$x(t_0) = y_0$$



Dla dowolnego wejścia u(t) określonego w przedziale $[t_0,t]$ odpowiedź systemu

$$x(t) = e^{a(t-t_0)}x_0 + \int_{t_0}^{t} e^{a(t-\tau)}bu(\tau)d\tau = e^{a(t-t_0)}x_0 + e^{at}\int_{t_0}^{t} e^{-a\tau}bu(\tau)d\tau$$

Przyjmując przedział dyskretyzacji T_s możemy policzyć

$$x(kT_s) = e^{a(kT_s - t_0)}x_0 + e^{akT_s}\int_{t_0}^{kT_s} e^{-a\tau}bu(\tau)d\tau$$

$$x((k+1)T_s) = e^{a((k+1)T_s - t_0)}x_0 + e^{a(k+1)T_s}\int_{t_0}^{(k+1)T_s} e^{-a\tau}bu(\tau)d\tau$$

Przemnażamy pierwszą zależność przez e^{aT_s} i odejmujemy od drugiej

$$e^{aT_s}x(kT_s) = e^{a((k+1)T_s - t_0)}x_0 + e^{a(k+1)T_s}\int_{t_0}^{kT_s} e^{-a\tau}bu(\tau)d\tau$$

$$x((k+1)T_s) - e^{aT_s}x(kT_s) = e^{a(k+1)T_s}\int_{kT_s}^{(k+1)T_s} e^{-a\tau}bu(\tau)d\tau$$

Ostatnia zależność po uporządkowaniu

$$x((k+1)T_s) = e^{aT_s}x(kT_s) + \int_{kT_s}^{(k+1)T_s} e^{a((k+1)T_s - \tau)}bu(\tau)d\tau$$

Zmieniamy zmienną całkowania

$$(k+1)T_s - \tau = t$$

Otrzymujemy

$$x\left((k+1)T_s\right) = e^{aT_s}x\left(kT_s\right) + \int_0^{T_s} e^{at}bu(t)dt$$

Przyjmując stałość wejścia w przedziale próbkowania

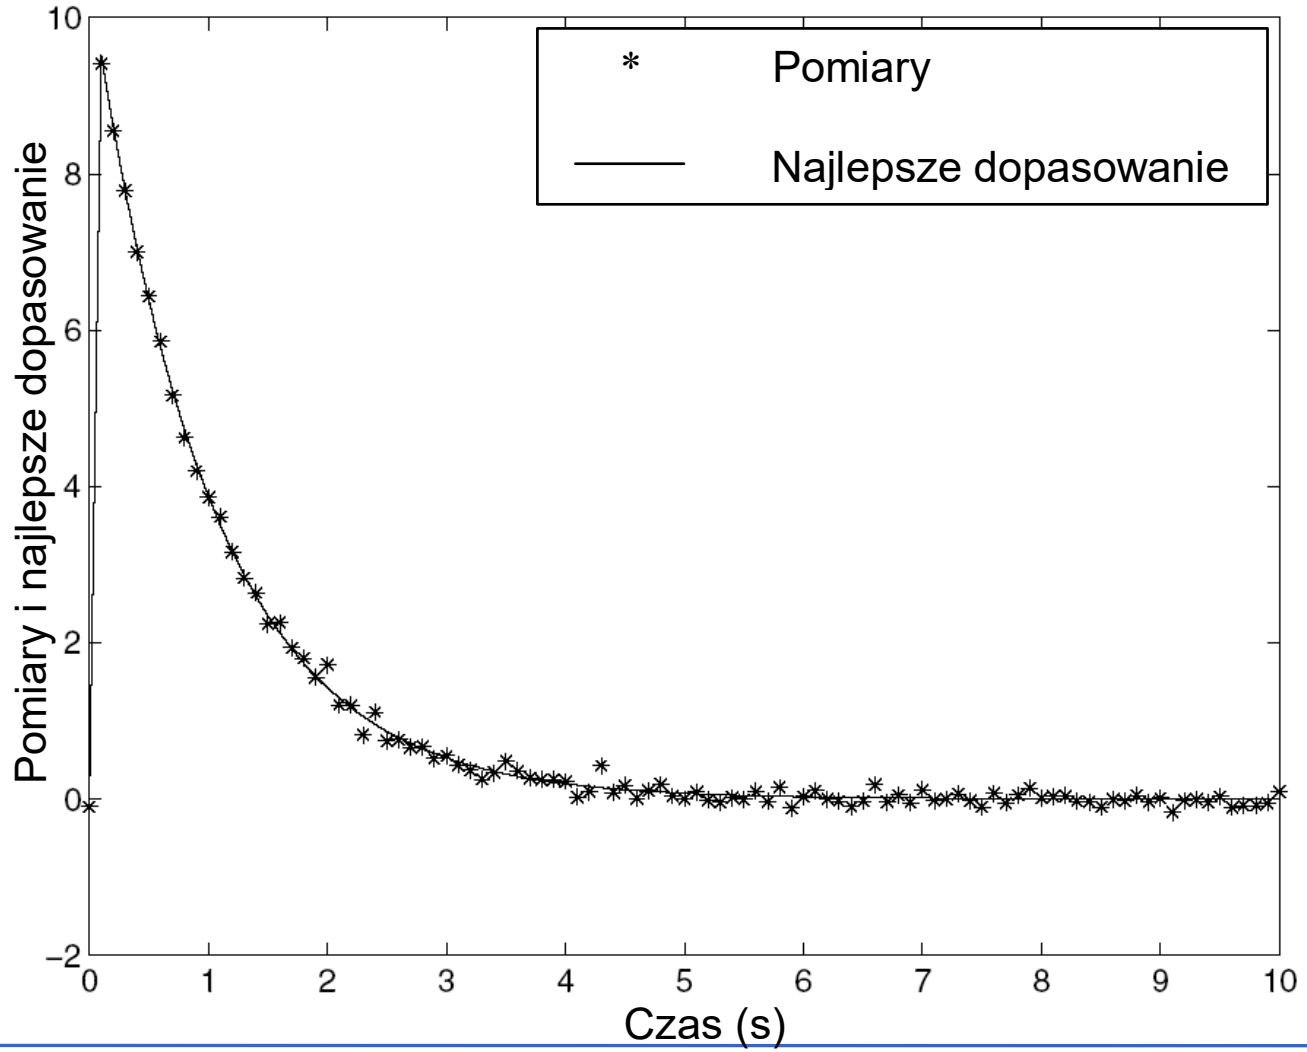
$$x\left((k+1)T_s\right) = e^{aT_s}x\left(kT_s\right) + \int_0^{T_s} e^{at}b\,dt \cdot u\left(kT_s\right)$$

A_D

B_D

Eksperyment pomiarowy:

Na wejście układu w chwili k=1 podano impuls (Dirac'a) o intensywności 100 i następnie obserwowano wyjście przez 101 chwil czasowych z Δt=0.1



Macierz wartości funkcji bazowych:

$$H = \begin{bmatrix} \tilde{y}_1 & u_1 \\ \tilde{y}_2 & u_2 \\ \vdots & \vdots \\ \tilde{y}_j & u_j \\ \vdots & \vdots \\ \tilde{y}_{100} & u_{100} \end{bmatrix}$$

Równanie obserwacji:

$$\begin{bmatrix} \tilde{y}_2 \\ \tilde{y}_3 \\ \vdots \\ \tilde{y}_{j+1} \\ \vdots \\ \tilde{y}_{101} \end{bmatrix} = H \begin{bmatrix} \hat{A}_D \\ \hat{B}_D \end{bmatrix} + \begin{bmatrix} \hat{e}_2 \\ \hat{e}_3 \\ \vdots \\ \hat{e}_{j+1} \\ \vdots \\ \hat{e}_{101} \end{bmatrix}$$

Korzystając z (5):

$$\begin{bmatrix} \widehat{A}_D \\ \widehat{B}_D \end{bmatrix} = \left(H^T H\right)^{-1} H^T \begin{bmatrix} \widetilde{y}_2 \\ \widetilde{y}_3 \\ \vdots \\ \widetilde{y}_{j+1} \\ \vdots \\ \widetilde{y}_{101} \end{bmatrix}$$

Otrzymamy:

$$\begin{bmatrix} \widehat{A}_D \\ \widehat{B}_D \end{bmatrix} = \begin{bmatrix} 0.9048 \\ 0.0950 \end{bmatrix}$$

Kuchnia naszego zadania:

Pomiary generowane były z wykorzystaniem następujących wartości prawdziwych

$$\begin{bmatrix} A_D \\ B_D \end{bmatrix} = \begin{bmatrix} 0.9048 \\ 0.0952 \end{bmatrix}$$

Symulacja błędu pomiaru: generator szumu gaussowskiego o zerowej wartości średniej i odchyleniu standardowym σ = 0.08

Metoda ważonych najmniejszych kwadratów

Poprzednie podejście: jednakowe znaczenie wszystkich pomiarów

Ważniejsze te pomiary, które wykonywane są z mniejszym błędem – dołączenie wag pomiarów do metody najmniejszych kwadratów

Znaleźć wartości nieznanych parametrów

$$\hat{\boldsymbol{x}} = \left(\hat{x}_1, \hat{x}_2, \ldots, \hat{x}_i, \ldots, \hat{x}_n\right)^T$$

minimalizujące

$$J = \frac{1}{2}\hat{\boldsymbol{e}}^T W \hat{\boldsymbol{e}}$$

gdzie $\hat{\boldsymbol{e}} = \tilde{\boldsymbol{y}} - H\hat{\boldsymbol{x}}$

W - symetryczna macierz wag

Warunek konieczny pierwszego rzędu:

$$\nabla J(\boldsymbol{x})\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T W\, H\, \hat{\boldsymbol{x}} - H^T W\, \tilde{\boldsymbol{y}} = \boldsymbol{0} \qquad (1)$$

Warunek wystarczający drugiego rzędu:

$$\nabla^2 J(\boldsymbol{x})^T \Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = H^T W\, H \qquad (2)$$

dodatnio określona

W dodatnio określona

Jawne rozwiązanie optymalnej estymaty

$$\hat{\boldsymbol{x}} = \left(H^T W\, H\right)^{-1} H^T W\, \tilde{\boldsymbol{y}} \qquad (3)$$

Poprzednie podejścia:

- jednakowe znaczenie wszystkich pomiarów – wszystkie pomiary wykonywane z jednakową dokładnością (jednakowo wiarygodne)
- różne znaczenie poszczególnych pomiarów – część pomiarów charakteryzuje się większą dokładnością (większą wiarygodnością) inne mniejszą dokładnością (mniejszą wiarygodnością



Jeszcze jedna możliwość:

- część pomiarów jest dokładna (wykonywana z błędem pomijalnie małym w stosunku do innych pomiarów)

Wszystkie obserwacje-pomiary o liczebności m podzielimy na dwie kategorie:

- m_1 pomiarów-obserwacji wykonanych z ograniczoną dokładnością
- m_2 pomiarów-obserwacji dokładnych

$$m_1 + m_2 = m$$

$$\tilde{\boldsymbol{y}}_1 = \underbrace{\left(\tilde{y}_{11}, \ldots, \tilde{y}_{1j_1}, \ldots, \tilde{y}_{1m_1}\right)^T}_{m_1}$$

- wektor wartości y mierzonych z ograniczoną dokładnością

Pomiary-obserwacje w obrębie tej kategorii mogą być zróżnicowane – wprowadzenie macierzy W_1

$$\tilde{\boldsymbol{y}}_2 = \underbrace{\left(\tilde{y}_{21}, \ldots, \tilde{y}_{2j_2}, \ldots, \tilde{y}_{2m_2}\right)^T}_{m_2}$$

- wektor wartości y mierzonych dokładnie

Dla wszystkich przeprowadzonych pomiarów określane są macierze wartości funkcji bazowych, odpowiednio H_1, dla pomiarów niedokładnych i H_2, dla pomiarów dokładnych

Macierze wartości funkcji bazowych

$$H_1 = \underbrace{\begin{pmatrix} h_1(u_{11}) \dots h_i(u_{11}) \dots h_n(u_{11}) \\ \dots\dots\dots\dots\dots\dots\dots\dots \\ h_1(u_{1j_1}) \dots h_i(u_{1j_1}) \dots h_n(u_{1j_1}) \\ \dots\dots\dots\dots\dots\dots\dots\dots \\ h_1(u_{1m_1}) \dots h_i(u_{1m_1}) \dots h_n(u_{1m_1}) \end{pmatrix}}_{n} \Big\} m_1$$

$$H_2 = \underbrace{\begin{pmatrix} h_1(u_{21}) \dots\dots\dots h_i(u_{21}) \dots\dots\dots h_n(u_{21}) \\ \dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots \\ h_1(u_{2j_2}) \dots\dots\dots h_i(u_{2j_2}) \dots\dots\dots h_n(u_{2j_2}) \\ \dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots\dots \\ h_1(u_{m_2}) \dots\dots\dots h_i(u_{m_2}) \dots\dots\dots h_n(u_{m_2}) \end{pmatrix}}_{n} \Big\} m_2$$

Dla pierwszej kategorii pomiarów:

$$\tilde{\boldsymbol{e}}_1 = \left(\tilde{e}_{11}, \ldots, \tilde{e}_{1j_1}, \ldots, \tilde{e}_{1m_1}\right)^T \neq \boldsymbol{0}$$

$$\hat{\boldsymbol{e}}_1 = \underbrace{\left(\hat{e}_{11}, \ldots, \hat{e}_{1j_1}, \ldots, \hat{e}_{1m_1}\right)^T}_{m_1} \neq \boldsymbol{0}$$

Dla drugiej kategorii pomiarów:

$$\tilde{\boldsymbol{e}}_2 = \left(\tilde{e}_{21}, \ldots, \tilde{e}_{2j_2}, \ldots, \tilde{e}_{2m_2}\right)^T = \boldsymbol{0}$$

$$\hat{\boldsymbol{e}}_2 = \underbrace{\left(\hat{e}_{21}, \ldots, \hat{e}_{2j_2}, \ldots, \hat{e}_{m_2}\right)^T}_{m_2} = \boldsymbol{0}$$

Równanie obserwacji będzie miało postać:

$$\begin{bmatrix} \tilde{\boldsymbol{y}}_1 \\ \cdots \\ \tilde{\boldsymbol{y}}_2 \end{bmatrix} = \begin{bmatrix} H_1 \\ \cdots \\ H_2 \end{bmatrix} \hat{\boldsymbol{x}} + \begin{bmatrix} \hat{\boldsymbol{e}}_1 \\ \cdots \\ \boldsymbol{0} \end{bmatrix} \tag{1}$$

lub

$$\begin{cases} \tilde{\boldsymbol{y}}_1 = H_1 \hat{\boldsymbol{x}} + \hat{\boldsymbol{e}}_1 & (2) \\ \tilde{\boldsymbol{y}}_2 = H_2 \hat{\boldsymbol{x}} & (3) \end{cases}$$

Przyjmiemy z naturalnych powodów:

$$n \geq m_2$$

$$n \leq m_1$$

Poszukujemy wektora wartości estymowanych nieznanych parametrów

$$\hat{\boldsymbol{x}} = \left(\hat{\boldsymbol{x}}_1, \ldots, \hat{\boldsymbol{x}}_i, \ldots, \hat{\boldsymbol{x}}_n\right)^T$$ - wektor estymowanych wartości parametrów

Zadanie poszukiwania tego wektora możemy sformułować:

Znaleźć wektor $\hat{\boldsymbol{x}} = \left(\hat{\boldsymbol{x}}_1, \ldots, \hat{\boldsymbol{x}}_i, \ldots, \hat{\boldsymbol{x}}_n\right)^T$, który minimalizuje sumę kwadratów błędów resztkowych (dopasowania, residuów) **pomiarów niedokładnych**

$$J\left(\hat{\boldsymbol{x}}\right) = \frac{1}{2}\hat{\boldsymbol{e}}_1^{\,T} W_1 \hat{\boldsymbol{e}}_1 = \frac{1}{2}\left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right)^T W_1 \left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right) \qquad (4)$$

spełniając ograniczenia równościowe **pomiarów dokładnych**

$$\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}} = \boldsymbol{0} \qquad (5)$$

Rozwiązanie postawionego zadania estymacji **metodą nieoznaczonych mnożników Lagrange'a**

Wektor nieoznaczonych mnożników Lagrange'a dla zagadnienia (4) – (5):

$$\boldsymbol{\lambda} = \left[\lambda_1, \ldots, \lambda_{j_2}, \ldots, \lambda_{m_2}\right]^T \tag{6}$$

Rozszerzona funkcja celu zagadnienia (4) – (5):

$$J_L(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}) = \frac{1}{2}\left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right)^T W_1 \left(\tilde{\boldsymbol{y}}_1 - H_1\hat{\boldsymbol{x}}\right) + \boldsymbol{\lambda}^T\left(\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}}\right) = \tag{7}$$

$$\frac{1}{2}\left[\tilde{\boldsymbol{y}}_1^T W_1 \tilde{\boldsymbol{y}}_1 - 2\tilde{\boldsymbol{y}}_1^T W_1 H_1 \hat{\boldsymbol{x}} + \hat{\boldsymbol{x}}^{\boldsymbol{T}}\left(H_1^T W_1 H_1\right)\hat{\boldsymbol{x}}\right] + \boldsymbol{\lambda}^T\left(\tilde{\boldsymbol{y}}_2 - H_2\hat{\boldsymbol{x}}\right)$$

Warunki konieczne minimum rozszerzonej funkcji celu zagadnienia (4) – (5):

$$\nabla_{\boldsymbol{x}} J_L\left(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}\right)\Big|_{\boldsymbol{x}=\hat{\boldsymbol{x}}} = -H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)\hat{\boldsymbol{x}} - H_2^T \boldsymbol{\lambda} = \boldsymbol{0} \tag{8}$$

$$\nabla_{\boldsymbol{\lambda}} J_L\left(\hat{\boldsymbol{x}}, \boldsymbol{\lambda}\right)\Big|_{\boldsymbol{\lambda}=\boldsymbol{\lambda}^*} = \tilde{\boldsymbol{y}}_2 - H_2 \hat{\boldsymbol{x}} = \boldsymbol{0} \tag{9}$$

Rozwiązujemy (8) – (9) względem $\hat{\boldsymbol{x}}$

$$\hat{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 + \left(H_1^T W_1 H_1\right)^{-1} H_2^T \left[H_2 \left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1} \left[\tilde{\boldsymbol{y}}_2 - H_2 \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1\right]$$

Macierz zależna od wartości funkcji bazowych (wejść) i wag pomiarów – macierz stała

Optymalne wartości estymowane nieznanych parametrów wyznaczone w oparciu o pomiary niedokładne

Wynik rozwiązania zadania (4)-(5):

$$\hat{\boldsymbol{x}} = \bar{\boldsymbol{x}} + K\left(\tilde{\boldsymbol{y}}_2 - H_2\bar{\boldsymbol{x}}\right) \tag{12}$$

gdzie:

$$\bar{\boldsymbol{x}} = \left(H_1^T W_1 H_1\right)^{-1} H_1^T W_1 \tilde{\boldsymbol{y}}_1 \tag{13}$$

$$K = \left(H_1^T W_1 H_1\right)^{-1} H_2^T \left[H_2\left(H_1^T W_1 H_1\right)^{-1} H_2^T\right]^{-1} \tag{14}$$

K – macierz wzmocnień

Optymalne wartości estymowane nieznanych parametrów wyznaczone w oparciu o pomiary niedokładne

Wartości y mierzone dokładnie

Predykcja wartości y z wykorzystaniem wartości estymowanych nieznanych parametrów wyznaczonych w oparciu o niedokładne pomiary

Dziękuję
– koniec materiału prezentowanego podczas wykładu

POLITECHNIKA GDAŃSKA

HISTORIA MĄDROŚCIĄ
PRZYSZŁOŚĆ WYZWANIEM